AgentOS 四组件产业与学术调研报告

推理框架 / 沙箱框架 / 记忆框架 / 内存管理 —— 2024-01 至 2026-11 进展外部参照

日期：2026-11-06

> 调研执行方式：12 维度并行深研 + 交叉验证 + 跨维度洞察。

目录

1. 第 1 章 调研方法与证据置信度总览
2. 第 2 章 推理框架与推理能力
3. 第 3 章 沙箱框架与执行能力
4. 第 4 章 记忆框架与记忆能力
5. 第 5 章 内存管理：传统内存与模型内存的双域治理
6. 第 6 章 外部参照全景与立项差异化论据

第 1 章 调研方法与证据置信度总览

本章说明本报告的调研范围、来源筛选与证据分级方法，公示验证过程中已证伪与已裁决的条目，并声明覆盖缺口及其对后续章节结论外推的限制。方法学目标有二：一是使每个结论可回溯至其证据链；二是将”不确定”本身作为一等公民呈现，而非用措辞掩盖。

1.1 调研范围与维度分解

本调研以”面向智能体（Agent）的操作系统”（Agent Operating System, AgentOS）为对象，将问题空间分解为四个组件 × 每组件三个维度，共 12 个调研维度（dim01–dim12），每个维度独立产出一份带脚注证据清单的分报告[^1-1^]:

组件	维度 1	维度 2	维度 3
推理框架（dim01–03）	系统级模型服务与 NPU 栈	端侧推理框架与加速	端云路由与 LoRA 热插拔
沙箱（dim04–06）	云端沙箱厂商与接口	策略/凭证/权限接口	端侧安全与隔离
记忆（dim07–09）	记忆系统格局与评测	端侧索引与隐私	压缩/遗忘与推理耦合
内存管理（dim10–12）	移动端内存 QoS	KV/权重分页与驱逐	NPU 内存抽象与记账

调研窗口为 2024-01 至 2026-11。选择该窗口的理由：端侧大模型操作系统化（模型即系统服务、NPU 上游化、agent 沙箱产品化）的关键事件均发生在该区间；2024 年以前的工作（如 NeuMMU、PagedAttention 前身）仅作背景引用。窗口内 2024–2025 年的论断以学术级来源为主，2026 年下半年的论断较多依赖产业界媒体与博客，此不对称性在证据分级中显式体现[^1-1^]。

1.2 来源标准与证据分级方法

来源分两类采信。产业界来源按权威性排序：官方文档与规范文本 > 厂商技术博客/发布会 > 第三方实测 > 一般媒体；学术界来源以顶会（NeurIPS、SOSP、NSDI、FAST、USENIX Security、EMNLP 等）正文为准，arXiv 预

印本须核对论文编号与版本（v1/v2 口径可能不同）。所有量化论断优先回溯至底层一手来源；两份分报告引用同一底层来源不视为独立证据[^1-1^]。

证据置信度分四级，定义与本轮统计分布如下[^1-1^]：

级别	定义	数量
High	≥2 个独立底层来源一致	28
Medium	单一权威来源（官方文档或论文原文）	35
Low	弱来源（软文、单媒体、厂商自报）或孤立论断	14
Conflict Zone	跨报告数字/结论冲突或时间口径不一致	10

验证流程为：通读 12 份分报告 → 跨报告比对同一指标口径 → 对冲突项做 1–3 次定向检索裁决 → 每组件抽查 ⩾3 个关键量化论断核对来源真实性与数字准确性 → 覆盖度对照检查[^1-1^]。抽查结果汇总为：多数 High 级数字与论文/官方原文一致；未发现整篇虚构来源，但发现 1 个疑似虚构条目、1 个证伪错引、1 个模型标注错误及若干置信度标注偏高项[^1-1^]。

1.3 已证伪与已裁决条目

以下条目已在交叉验证中证伪或裁决，本报告全文按裁决口径引用，原始错误口径不再出现：

- **疑似虚构**：AMemBench（标注 arXiv 2609.13767，“10 维 76.83% vs 63.94%”）经检索零结果，引文链中亦无此名，标记 HALLUCINATED-SUSPECT，正文删除[^1-1^]。另有 OSDN（arXiv 2607.05475）未获证实，降为”待核实”[^1-1^]。
- **证伪错引**：dim10 称”dma-buf memcg 记账上游 6.5 合入（2023-08）“不成立。裁决以 dim12 口径为准：该补丁序列截至 2026-10 仍为 RFC v2（8 个补丁），主线 `memory.stat` 无 dmabuf 键；所述功能实际以 Android GKI 下游补丁形式存在[^1-2^]。
- **KV/token 口径错误**：“FP16 KV 每 token ≈0.5MB”对应 MHA 7B 级模型（如 Llama-2-7B）；Llama-3-8B 为 GQA（8 个 KV head），实际 ≈0.125MB/token。凡引用 KV 单 token 占用处必须标注模型架构口径[^1-1^]。
- **双口径并存（皆真、须分别标注）**：Apple AFM LoRA——2024 官方技术报告口径为 rank-16、数十 MB[^1-3^]，2025 出货模型/开发者工具包口径为 rank-32、约 160MB `.fmadapter`（第三方逆向，非官方文档）[^1-1^]；PowerInfer-2 加速比 arXiv v1 为 29.2×、v2 为 27.8×，本报告引 v2 口径[^1-4^]；AgentDojo 无攻击效用论文摘要口径为聚合 <66%，最佳单模型（GPT-4o）benign utility 69% 出自论文表格/官方 leaderboard[^1-5^]。
- **不可裁决为单一数字**：NPU vs CPU 倍数存在理论峰值（最高 100×）、发布会营销（25×）、特定模型实测（12×）三种口径，引用时必须带场景限定语[^1-1^]。

1.4 覆盖缺口声明

以下缺口经对照检查确认，构成后续章节相应结论的外推限制：

1. **HarmonyOS 全栈缺技术级来源**。盘古大模型/麒麟 NPU/MindSpore 侧仅有软文与媒体口径，无论文或官方文档级证据；涉及 HarmonyOS 的所有论断（如日均 36.8

亿次 API 调用除外）置信度不超过 Medium-Low，不得作为架构结论的独立依据[^1-1^]。

2. **沙箱 × 内存 QoS 跨组件接缝无人覆盖**。cgroup/dmem 限额如何应用于 agent 沙箱，云端厂商与内核社区各自推进、互不引用，本报告对该接缝的设计性论述属空白推断而非现状描述[^1-6^]。
3. **端侧 agent 沙箱为全行业空白**。iOS 依赖 IPC 权限、Android 无对应物，两份独立分报告得出一致的空白结论——此为发现而非遗漏，但意味着相关论断无竞品对照，外推至产品形态时须谨慎[^1-1^]。
4. **次级缺口**：NPU 侧 KV cache 运行时管理（delegate 内部不可见）、端云路由实测延迟（全行业未公开）、iOS jetsam 量化预算（无 Apple 官方表）、移动 SoC 统一内存记账（上游 RFC 四年未合入的结构性停滞）[^1-1^][^1-2^]。

此外，2026 年下半年论断多依赖媒体/博客来源，学术级佐证集中于 2024–2025 年工作；凡涉最新动态的章节结论，读者应注意其证据时效衰减风险[^1-1^]。

本章来源

[^1-1^]: AgentOS 调研交叉验证报告（Phase 4），2026-11-06，`agentos_cross_verification.md`：置信度定义、四级分类、冲突裁决 C1–C10、抽查汇总与覆盖缺口清单。 [^1-2^]: dma-buf memcg 记账补丁序列：2026-05 RFC 与 2026-10 RFC v2 邮件列表原文（lore/kernel.org、kernsec.org 归档）；主线 cgroup-v2.rst 无 dmabuf 条目。 [^1-3^]: Apple Intelligence Foundation Language Models 技术报告，arXiv:2407.21075（2024）：rank-16 adapter、数十 MB 口径。 [^1-4^]: PowerInfer-2: Fast Large Language Model Inference on a Smartphone，arXiv:2406.06282（v1 摘要 29.2×；v2 摘要 27.8×）。 [^1-5^]: AgentDojo: A Dynamic Environment to Evaluate Prompt Injection

Attacks and Defenses for LLM Agents，arXiv:2406.13352（摘要聚合效用 <66%；GPT-4o benign utility 69.0% 见论文表格/官方 leaderboard）。 [^1-6^]: AgentOS 跨维度洞察提炼（Phase 6），2026-11-06，`agentos_insight.md`：洞察 I-02（沙箱生命周期 × 内存策略域接缝）与 I-07（窗口矩阵中”持久空位”判定）。

第 2 章 推理框架与推理能力

本章综合维度调研 dim01（系统级模型服务与 NPU 调度）、dim02（端侧推理框架与推理加速）、dim03（端云路由与 LoRA 生态）三份报告，并按交叉验证结论（High 28 项 / Medium 35 项 / Low 14 项 / Conflict Zone 10 项，全报告口径）对置信度分级处理：High 级直接陈述；Medium/Low 级加限定语；Conflict Zone 双边呈现。所有量化论断均标注数值、单位、来源与日期；已被标记为虚构或错引的条目（如 dim10 “dmabuf memcg 上游 6.5 合入”、dim09 “Llama-3-8B KV 0.5MB/token”、AMemBench）本章不予采用。

2.1 技术谱系：六条路线

围绕”端侧推理如何组织”，2021–2026 年的工作与产业实践可归为六条相互交叉的路线：系统级模型服务、NPU 抽象、端侧框架、推理加速、端云路由、LoRA 生态。表 2-1 给出各路线的代表工作。

表 2-1 推理框架与推理能力技术谱系（路线 × 代表工作 × 机构 × 时间 × 一句话贡献）

路线	代表工作	机构	时间	一句话贡献
系统级模型服务	AICore + Gemini Nano + ML Kit GenAI	Google	2023-12 首落地（Pixel 8 Pro），2025-05	模型由系统服务统一下载/加载/推理，多应

路线	代表工作	机构	时间	一句话贡献
	APIs		对第三方开放 beta[^2-1^]	用共享单实例，APK 不含权重，以前台限制与每应用配额换取资源可控[^2-1^][^2-2^]
系统级模型服务	Foundation Models framework（~3B 端侧模型）	Apple	2025-06 发布，iOS 26 起可用[^2-3^]	Swift 原生 API 直调系统 3B 模型，guided generation + tool calling，无按次计费[^2-3^]
系统级模型服务（学术先导）	M4: Mobile Foundation Model as Firmware	北京邮电大学等	MobiCom 2024[^2-4^]	底座模型由 OS 与硬件共同管理、对 App 不可修改，以系统服务形式暴露，App 仅经 adapter 调用[^2-4^]
系统级模型服务	小艺 + Pangu 端侧（HarmonyOS 7	华为	2024-06（NEXT）至 2026-06（HDC	模型深度集成进系统并以 Agent/Skill 架构

路线	代表工作	机构	时间	一句话贡献
	宣称”入内核”）		2026）[^2-5^]	开放；“Pangu 6.0 入内核”为媒体转述口径，无技术出处，置信度低[^2-5^]
NPU 抽象	Android NNAPI（已弃用）	Google + 厂商	2018 引入，2024 Android 15 deprecated[^2-6^]	首个跨厂商 NPU 抽象；因厂商实现不均、跟不上 transformer 演进被弃，NN HAL 保留给 AICore 等系统服务[^2-6^][^2-7^]
NPU 抽象	LiteRT CompiledModel + Accelerator.NPU（Qualcomm/ MediaTek 一等支持）	Google + Qualcomm + MediaTek	2025-05 起，2026-01 生产可用[^2-8^]	单一 API 选定 NPU 后端，AOT+JIT 编译，失败回退 GPU/CPU，配套 AI Pack 模型分发[^2-8^]

路线	代表工作	机构	时间	一句话贡献
NPU 抽象	Android 17 `NpuManager` + NPU scheduling AIDL	Google（AOSP）	2026（API 37）[^2-9^]	首个 OS 级 NPU 调度控制面：UID/优先级/直接访问资格/工作回调；best-effort、无 SLO、@SystemApi 不对第三方开放（源码阅读转述，置信度中高）[^2-9^]
NPU 抽象	HarmonyOS NNRt	华为 / OpenHarmony	2022 起[^2-10^]	跨芯片推理运行时，共享内存零拷贝、优先级可配；仅 56 个算子、仅同步推理，并发性取决于底层驱动[^2-10^]
端侧框架	llama.cpp / GGUF	社区（ggml-org）	2023 起[^2-11^]	端侧推理事实标准：单文件格式 + 多档量

路线	代表工作	机构	时间	一句话贡献
				化 + mmap 惰性加载，后端覆盖 CPU/CUDA/Metal/Vulkan/Hexagon 等[^2-11^]
端侧框架	ExecuTorch	Meta / PyTorch Foundation（Arm、Apple、Qualcomm 共建）	1.0 GA 2025-10，MLSys 2026 论文[^2-12^]	PyTorch 原生端侧运行时，AOT 导出 + 12+ 硬件后端 delegate，50KB 级基础运行时[^2-12^]
端侧框架	LiteRT-LM；MNN/MNN-LLM；MLC-LLM	Google / 阿里巴巴 / MLC.AI	2024–2026[^2-13^]	Google 官方”多特性共享单一底座 + 轻量 LoRA”栈；MNN-LLM 移动端 prefill 领先；MLC-LLM 内置端侧唯一类 vLLM 分页 KV[^2-13^]
推理加速（量	GPTQ → AWQ	ISTA / MIT	2022–2025[^2-	权重 4-bit 成为

路线	代表工作	机构	时间	一句话贡献
化）	→ QuaRot/SpinQuant → QServe（W4A8KV4）；BitNet b1.58 2B4T	HAN Lab / Microsoft 等	14^]	端侧默认交付形态，主战场转向 KV cache 3–4 bit 低比特化；1.58-bit 从头训练模型 CPU 可跑[^2-14^][^2-15^]
推理加速（投机解码）	Medusa → EAGLE-2/3；Apple AFM 48M draft + 3.18B base 双模型	Princeton/ SafeAILab/ Apple	2024–2025[^2-16^]	自草稿投机解码无损加速；llama.cpp 2026 年已内置 6 类投机实现，成为运行时一等特性[^2-16^][^2-17^]
推理加速（NPU 系统）	llm.npu；PowerInfer-2；LLM in a flash	北大 / SJTU / Apple	ASPLOS 2025 / 2024[^2-18^]	NPU 中心端侧 LLM 系统：prefill 较 CPU 基线快 7.3–18.4×；flash-DRAM 分层加载使手机上可跑 47B 级模型

路线	代表工作	机构	时间	一句话贡献
				[^2-18^]
端云路由	Apple Private Cloud Compute（PCC）+ System Orchestrator	Apple	2024-06 发布，2026-06 扩展第三方机房[^2-19^]	唯一大规模落地的”可验证隐私”云承接：无状态计算 + 签名镜像 + 透明日志 + 远程证明[^2-19^]
端云路由	Firebase AI Logic Hybrid Inference	Google	2026-04 Android 上线，2026-05 扩展 iOS[^2-20^]	四档规则式端云路由（PREFER/ ONLY_ON_DEVICE/ IN_CLOUD），官方自述为”initial solution”[^2-20^]
端云路由	NVIDIA OpenShell privacy router	NVIDIA	2026-03 随 NemoClaw 首次亮相，2026-09-28 作为 Open Agent Safety Platform 正式发	声明式 YAML 策略（隐私/成本）路由，deny-by-default，凭证剥离 + header 白

路线	代表工作	机构	时间	一句话贡献
			布[^2-21^]	名单，Apache 2.0 开源[^2-21^]
端云路由（学术）	RouteLLM；MinionS；CITER/CE-CoLLM	LMSYS/ Stanford 等	2024–2025[^2-22^]	学习式请求级路由省 85% 成本；任务分解协作成本降 5.7× 且恢复 97.9% 质量；token 级置信度路由[^2-22^]
LoRA 生态	LoRA；Punica（SGMV）；S-LoRA（Unified Paging）	Microsoft / 多机构	ICLR 2022 / MLSys 2024[^2-23^]	冻结基座 + 低秩适配；跨 adapter 混合批处理（吞吐 12×、+2ms/token）；adapter 权重与 KV cache 统一分页[^2-23^]
LoRA 生态（端侧）	Apple AFM 可换 adapter；EdgeLoRA；	Apple / Univ. of Maryland / 东南	2024–2025[^2-24^]	系统级 LoRA 热插拔量产先例；端侧多租

路线	代表工作	机构	时间	一句话贡献
	MobiLoRA	大学·荣耀		户 LoRA serving 吞吐 2–4× llama.cpp；跨 adapter KV 复用 TTFT 最高降 81.3%[^2-24^][^2-25^]

表 2-1 显示三条结构性事实。其一，“模型即系统服务”已从学术设想（M4，MobiCom 2024）落地为两大平台的事实标准，华为以更激进但缺乏技术级出处的路径跟进；其二，NPU 抽象的主导权经历了”OS 内算子级抽象（NNAPI，失败）→ 框架级抽象（LiteRT/ONNX Runtime，当前主线）→ OS 级调度控制面（Android 17，刚起步）“的三次迁移，说明跨厂商抽象收敛在框架层而非内核层；其三，LoRA 从训练技术演变为系统对象——服务端（vLLM/SGLang）、OS（Apple adapter）、芯片（Qualcomm 白皮书、联发科 LoRA Fusion 2.0）三层均出现独立先例[^2-26^]，多方独立竞争者收敛到同一选择：adapter 是基座模型与硬件之间的定制层。

2.2 端侧推理栈分层图

综合 dim01 的分层素材，端侧推理栈可划分为五层，各层玩家与开放程度见表 2-2（开放度 ●=开放，○=封闭，按文档/源码可得性、第三方可编程性综合评定）。

表 2-2 端侧推理栈分层：玩家与开放程度

层	主要玩家	开放程度	关键约束
应用层	Android：ML Kit GenAI	●●○○	任务级 API 开放；

层	主要玩家	开放程度	关键约束
	APIs（beta）；iOS：Foundation Models framework；HarmonyOS：小艺 Skill/MCP 接入		模型选择、版本、调度均不可控；AICore 仅前台可用且有配额[^2-2^]
系统服务层	Android AICore（APEX 包、Play 分发、共享实例）；Android 17 NpuManager（@SystemApi、best-effort）；Apple Intelligence 系统进程（SystemLanguageModel）；华为小艺 + Pangu	●○○○	三家均”开放调用、封闭调度”；Apple 不公开任何数值化配额[^2-27^]
框架/运行时层	LiteRT（+Qualcomm/MediaTek Accelerator）、ONNX	●●●○	开放度最高的一层，跨厂商抽象事实上的收敛点；但算子覆盖与性能 per-SoC 不均

层	主要玩家	开放程度	关键约束
	Runtime（QNN EP / Neuron E P）、ExecuTorch、llama.cpp、MNN； 已弃用： NNAPI（HAL 保留）；华为 NNRt + MindSpore Lite		（LiteRT QNN 支持 90 算子，72 个基准模型中 64 个可全量卸载 NPU，Google 官方博客，2025-11-24）[^2-8^]
HAL/驱动层	Android NN HAL（AIDL，保留）；Qualcomm FastRPC→HTP（8 级 context priority、性能档位、ION/SMMU 零拷贝）；MediaTek Neuron runtime（离线编译器 ncc-tflite 在伙伴注册墙后）	●●○○	高通 QNN 对注册开发者开放；联发科编译器封闭；调度逻辑在固件内黑盒 [^2-28^]
芯片层	Qualcomm Hexagon HTP（仅 INT8/INT16）；MediaTek	●○○○	均无公开的虚拟化/多租户/抢占硬件接口；ANE 完全不开放直接编程；ANE

层	主要玩家	开放程度	关键约束
	MDLA+VPU；Apple ANE（固定功能、权重编译期烘焙）；华为麒麟 NPU		的 ~32MB SRAM 预算与”溢出性能降约 30%“系单源逆向数据（arXiv 2603.06728，2026-03），非 Apple 官方口径，置信度中[^2-29^]

表 2-2 的核心读法是”开放度倒挂”：越靠近芯片越封闭，唯一高度开放的框架层因此成为所有跨厂商诉求的汇聚点——这解释了 NNAPI 失败后 Google 转而与 Qualcomm/MediaTek 共建 LiteRT Accelerator 的战略选择。同时注意两个层的制度性变化：系统服务层在 2026 年出现了首个 OS 级 NPU 调度控制面（Android 17 NpuManager），说明”NPU 需要调度”已成平台共识，但其 best-effort 语义与 @SystemApi 封闭性表明平台无意把调度能力交给第三方；芯片层则没有任何厂商提供多租户或抢占接口，学术工作 V10（ISCA 2023，硬件辅助算子级多租户，吞吐 1.57×、尾延迟降 1.74×、面积开销 <0.03%）[^2-30^]证明收益可观但需硬件配合，短期内不会出现在商用 SoC 上。

2.3 关键数据

本节汇集与本章论断直接相关且有出处的量化指标，分三组陈述（表 2-3 至表 2-5）。

表 2-3 系统级模型服务：配额、限制与模型形态

指标	数值	来源与日期	置信度
AICore 前台限制	非 top foreground app（含 foreground service）调用 GenAI API 返回 `ErrorCode.BACKGROUND_USE_BLOCKED`	ML Kit 官方文档（经 Capawesome 逐字引用），2026-09-29[^2-2^]	High
AICore 配额错误码	短时超配额 → `ErrorCode.BUSY`；长周期超配额 → `ErrorCode.PER_APP_BATTERY_USE_QUOTA_EXCEEDED`	同上[^2-2^]	High
ML Kit Prompt API 输入上限	<4,000 token（约 3,000 英文单词）；>256 token 输出场景不建议	官方文档（经插件文档逐字引用），2026-07[^2-2^]	High
ML Kit GenAI APIs 成熟度	beta，“is not subject to any SLA or deprecation policy”	WinBuzzer 引官方文档，2025-05-19[^2-1^]	High
Apple Foundation Models 配额	Apple 未公开任何数值化配额/速率限制，仅存在可用性三态（not eligible / not enabled / model	Apple 文档与开发者实测综述，2025-06-28[^2-27^]	High（对”未公开”这一事实）

指标	数值	来源与日期	置信度
	not ready）		
Foundation Models 上下文窗口	4,096 toke n（WWDC25/iOS 26）；WWDC26 示例达 8,192 token	开发者实测 2025-06；slash-digital 查官方文档 2026-09-26[^2-27^]	High / Medium
Gemini Nano v3 内存门槛	需 ≥12GB RAM 旗舰机	byteiota（二手），2026-05-19[^2-31^]	Medium
HarmonyOS AI 子系统调用量	20+ 项开放能力，日调用 36.8 亿次	HDC 2026 报道（firecat 2026-06-14；Pandaily 2026-08-28 独立确认）[^2-5^]	High
AFM 端侧模型	~3B 参数；2024 报告：平均 <4 bit/权重；2025 报告：2-bit QAT + KV-reuse 双段架构 + 48M draft 投机解码	Apple 技术报告 arXiv 2407.21075（2024-07-29）/ 2507.13575（2025-07）[^2-24^][^2-32^]	High

表 2-3 呈现一个值得注意的非对称：Google 对平台约束完全透明（三个错误码逐字公开、输入上限明码标注），Apple 则完全不公开数值化配额——前者让开发者可做容量

规划，后者把容量规划变成实验问题。但两者共享同一控制语义：前台独占 + 配额熔断 + 可用性降级。这说明”共享底座模型 + 硬降级面”不是某一家的取舍，而是平台把 LLM 纳入系统服务时的结构性代价；任何依赖平台托管模型的应用层设计都必须把 BUSY/不可用状态作为常规分支而非异常处理。

表 2-4 AFM LoRA adapter 双口径（Conflict Zone C1 裁决结果：两者皆真、指代不同，须分开标注）

口径	rank	体积	出处	置信度
2024 官方技术报告（accuracy-recovery/功能 adapter）	16	数十 MB（16-bit 表示），可动态加载/缓存/换出，“保证 OS 响应性”	Apple 技术报告 arXiv 2407.21075，2024-07-29[^2-24^]	High（官方原文核实）
2025 出货模型/开发者工具包（`.fmadapter`，Background Assets 分发）	32	~160MB/个	第三方逆向（fguzman82 GitHub，2025-06）+ gamut.so（2025-09-08），两处一致但均非 Apple 官方文档[^2-33^]	Medium

表 2-4 的两行不是误差，而是两套不同语义的并存：rank-16/数十 MB 是 Apple 2024 年官方技术报告中”精度恢复 + 功能特化”adapter 的口径；rank-32/~160MB 是 2025 年

出货模型与开发者训练工具包（`.fmadapter`）的第三方逆向口径。交叉验证裁决（C1）要求二者分开标注，不得混写为单一数字。对系统设计的含义是：端侧 LoRA 的内存预算应按”单 adapter 数十至 160MB、多 adapter 常驻需分页池”规划，且 adapter 与基座模型版本绑定（基座升级须重训），版本治理是热插拔机制的前置条件。

表 2-5 推理加速：量化、投机解码与 NPU 端侧指标

指标	数值	来源与日期	置信度
LiteRT Gemma-3n E2B @ Dimensity 9500	prefill >1,600 tok/s、decode 28 tok/s @4K 上下文；LLM 吞吐 12× CPU / 10× GPU	Google developers blog（2025-12-08，经 MarkTechPost 2025-12-09 转述）[^2-34^]	High（注意系厂商基准）
LiteRT QNN Accelerator：FastVLM-0.5B @ Snapdragon 8 Elite Gen 5	TTFT 0.12s、prefill >11,000 tok/s、decode >100 tok/s	Google 官方博客，2025-11-24（经 yomu.fyi 转述）[^2-8^]	Medium-High（厂商宣称值；芯片代际已按 C9 裁决更正为 8 Elite Gen 5）
NPU”prefill 强、decode 弱”	Qwen2.5-1.5B NPU(GENIE) prefill 1,213–1,464 tok/s，decode 仅 20.7–23.1 tok/s，低于 llama.cpp GPU decode（最高 64.4 tok/s）	四款手机交叉实测，arXiv 2607.05475，2026-07[^2-35^]	Low（来源编号未能独立核实，结论以下两行 High 证据为准）
ExecuTorch MLSys	Llama-3.2-1B	MLSys 2026 论文原	High

指标	数值	来源与日期	置信度
2026 基准（Galaxy S25 Ultra）	prefill：QNN 2,813–2,977 tok/s vs XNNPACK 525–529 tok/s（NPU prefill 优势 ~5.5×，decode 反而低于 CPU）	文[^2-12^]	
llm.npu（ASPLOS 2025）	prefill 较 CPU 基线快 7.3–18.4×，10 亿级模型 prefill 首破 1,000 tok/s	论文原文[^2-18^]	High
NPU vs CPU 性能倍数	理论峰值”最高 100× CPU”（LiteRT 官方）/ 发布会口径 25×（I/O 2025 转述）/ 特定模型实测 12×（Gemma-3n @ D9500）并存	C5 裁决：领域内口径混乱，引用必须带场景限定[^2-8^] [^2-34^]	Conflict（已裁决为口径差异）
KV cache 量化（TurboQuant 落地 MNN）	Qwen3-4B @8K 上下文 KV 约 2GB（FP16）；压至 3–4 bit 省内存 30–60%	MNN GitHub Discussion #4351，2026-04-07[^2-15^]	Medium（源头单一，交叉换算一致）
投机解码	EAGLE-2 均值 2.5–3.5×（EMNLP	各论文/逆向分析	Medium-High

指标	数值	来源与日期	置信度
	2024）；EAGLE-3 最高 6.5×（NeurIPS 2025）；Apple AFM 双模型整体 2–4×（第三方逆向口径，非官方数字）	[^2-16^][^2-33^]	
BitNet b1.58 2B4T	非嵌入权重 0.4GB；CPU 解码 29ms/token；能耗 0.028J/step	Microsoft 模型卡（Azure AI 目录），2026-04 页面[^2-14^]	High（官方卡）
PowerInfer-2	智能手机上 TurboSparse-Mixtral-47B 达 11.68 tok/s；加速比 v1 摘要 29.2×、v2 摘要 27.8×（C4 裁决为版本口径差异，建议引 v2）	arXiv 2406.06282 v2，2024-06[^2-18^]	High
LLM in a flash	可运行 2× DRAM 容量模型；较朴素加载 CPU 4–5× / GPU 20–25×	Apple 论文 arXiv 2312.11514，2024-07-30[^2-18^]	High
端侧 NPU KV 复用	较无复用 prefill 加	arXiv 2609.34727，2026-	High

指标	数值	来源与日期	置信度
	速 1.5–5.4×，TTFT 降 40–60%；直接全量非前缀复用质量掉 ~30%	09-28[^2-36^]	
S-LoRA / Punica（云端对照）	单 A100-80GB 同时服务 2,000 adapter，吞吐 4× vLLM-packed / 30× HF PEFT；Punica SGMV 吞吐 12×、每 token +2ms	arXiv 2311.03285（2023-11）/ MLSys 2024[^2-23^]	High（多源核实）
EdgeLoRA	Jetson AGX Orin 上吞吐 2–4× llama.cpp；论文自述可服务千级 adapter（llama.cpp 约 50），数量差异达”several orders of magnitude”	arXiv 2507.01438（MobiSys 2025），2025-07-02[^2-25^]	High（吞吐倍数）；adapter 数量为论文自报口径，未独立复核（C7）

三组数据合在一起勾勒出端侧推理的”能力包络”：系统服务层的能力上限被平台刻意压低（AICore 输入 4K token、前台独占、配额熔断；Apple 不公开配额但模型固定 3B/4K 上下文），而裸框架层在旗舰 NPU 上已能跑出 prefill 1,600–11,000 tok/s 的数字——两个层级的性能差可达一个数量级，但前者换来的是免携带权重与系统级资源共享。

表 2-4 的双口径须特别注意：任何”AFM adapter 只有数十 MB”或”AFM adapter 有 160MB”的单一写法都是错的，二者分别对应 2024 官方报告与 2025 出货/工具包两套语义。表 2-5 中”prefill 强、decode 弱”的 NPU 分工特征被 ExecuTorch（MLSys 2026）与 llm.npu（ASPLOS 2025）两篇同行评议论文交叉证实（arXiv 2607.05475 提供同方向实测，但其编号未能独立核实，仅作旁证），已成为 2025–2026 端侧系统设计的基准事实，也直接引出 2.5 节的分阶段调度趋势。

2.4 端云路由方案对比

表 2-6 对比三套生产级端云路由方案，并以学术方案作参照。

表 2-6 端云路由方案对比（方案 × 路由依据 × 隐私机制 × 延迟）

方案	路由依据	决策粒度	隐私机制	延迟/成本数据	状态
Apple 端侧 AFM ↔ PCC（2026-06 起扩展第三方机房）	任务复杂度、隐私敏感度、延迟要求、设备热状态（WWDC26 System Orchestrator 口径，媒体转述，置信度中）；feature class / routing_hint	请求级	PCC：无状态计算、签名固件、Secure Enclave/Secure Boot、公开镜像 + 透明日志、远程证明、无特权访问（五大保证，Apple	端侧 TTFT <100ms；PCC 路径首 token 增加约 200–500ms（第三方开发者口径，2026，置信度中）[^2-37^]；PCC 32K 上	生产（2024-06 起）

方案	路由依据	决策粒度	隐私机制	延迟/成本数据	状态
			Security Research blog，2024-06-10）[^2-19^]	下文、有日配额、需 entitlement（WWDC26）[^2-38^]	
Firebase AI Logic Hybrid（Gemini Nano/AICore ↔ 云 Gemini）	四档枚举 `InferenceMode`（PREFER_ON_DEVICE / PREFER_IN_CLOUD / ONLY_ON_DEVICE / ONLY_IN_CLOUD）+ 开发者自定义；官方自述”simple rule-based routing approach as an initial solution”[^2-20^]	请求级（端侧限单轮、文本或单图输入）	无 TEE；隐私 = 数据不出端（端侧路径）+ App Check 防配额盗用	无端云延迟对比官方数据；端侧上限 4,000 token/请求 [^2-2^][^2-31^]	生产（2026-04 Android / 2026-05 iOS，Firebase 官方博客）[^2-20^]

方案	路由依据	决策粒度	隐私机制	延迟/成本数据	状态
NVIDIA OpenShell privacy router	用户声明式 YAML 策略（隐私/成本），deny-by-default, 进程外执行，“路由遵循成本与隐私策略而非 agent 偏好”[^2-21^]	请求级	凭证剥离、header 白名单、`inference.local` 本地端点承接敏感请求、本地 Nemotron 模型；无 TEE	策略热更新 ~5s 生效；无推理延迟公开数据（NVIDIA 官方文档，2026）[^2-21^]	生产（2026-03 随 NemoClaw 首次亮相，2026-09-28 作为 Open Agent Safety Platform 正式发布；Apache 2.0）[^2-21^]
RouteLLM（学术→Anyscale 生产组件）	偏好数据训练的路由器预测强模型胜率，阈值校准	请求级	无（同一信任域内模型选择）	MT-Bench 省 85% 成本 @ 95% GPT-4 质量，仅 14–26% 查询进强模型（ICLR 2025）；Anyscale 生产 20 万查询省 85%（置信度中）	学术 + 生产组件

方案	路由依据	决策粒度	隐私机制	延迟/成本数据	状态
				[^2-22^]	
MinionS（学术，Stanford 等）	云端分解子任务 → 本地并行执行 → 云端汇总	任务分解级	原始长文档不出端，仅子任务/摘要上云	成本降 5.7×、恢复 97.9% 质量（朴素协议 30.4×/87 %），arXiv 2502.15964，2025-02[^2-22^]	学术
GPU TEE 机密推理（H100/B200 CC + TDX/SEV-SNP，云端承接机制参照）	用户选择隐私档	部署级	GPU TEE + 远程证明 + PCIe AES-GCM-256 加密 + CPU TEE 联动	TEE 开销约 5–15%、大模型额外 +50–100ms（第三方运营方口径，置信度中）；机制本身经 arXiv 2409.03992（2024-09）实测确	云产品

方案	路由依据	决策粒度	隐私机制	延迟/成本数据	状态
				认[^2-39^]	

表 2-6 揭示三点。第一，隐私保证已分化为两档：传输级（数据不出端即隐私，Google/Firebase 路径）与架构级（无状态 + 可验证，Apple PCC 阵营）；PCC 是后者唯一的大规模商用先例，且 2026 年把该信任模型扩展到 Google Cloud/NVIDIA 第三方机房，证明”可验证隐私云”可脱离自有数据中心存在[^2-19^]。第二，路由器的智能度差异悬殊：Apple 做逐 prompt 多维决策但完全黑盒（无用户开关可强制端侧[^2-40^]），Google 公开承认仅为规则式枚举，NVIDIA 用声明式静态策略——学习式路由（RouteLLM）与任务分解路由（MinionS）在学术上已证明数量级成本收益，但未被任何平台完整吸收。第三，也是对本章最重要的空白：三家生产方案均不把”数据敏感度分级”作为一等路由信号——Apple 按能力路由、Firebase 按可用性路由、OpenShell 按静态策略路由；同时路由决策的实测延迟/命中率数据全行业未公开（PCC 200–500ms 仅为第三方口径），路由决策审计日志仅见于企业合规侧的第三方架构建议[^2-40^]。

2.5 趋势判断与公认空白点

正在收敛的方向（事实性观察）。 其一，“端侧默认 + 云端升级”成为三大厂共识架构：Apple（AFM→PCC）、Google（Nano/AICore→Firebase 云 Gemini）、NVIDIA（本地 Nemotron→云前沿模型）在 2024–2026 年各自落地同一形态，差异仅在路由智能度与隐私承接强度。其二，“共享底座 + LoRA 特化”从云端向端侧迁移完成闭环：服务端 S-LoRA/Punica（2023）、OS 侧 Apple adapter 生态与 LiteRT-LM 官方”多特性共享单一底座”（2025）、端侧多租户学术系统 EdgeLoRA/MobiLoRA（2025）、芯片侧 Qualcomm/联发科/Taalas（2024–2026），四个层级独立收敛[^2-26^]。其三，adapter 内存与 KV cache 的管理正在统一：S-LoRA Unified Paging 开先河，SGLang 把 adapter 标识纳

入前缀缓存键，MobiLoRA 按 adapter 复用 KV；权重（基座 + adapter）与 KV 进入同一分页/淘汰体系[^2-23^][^2-41^]。其四，热插拔延迟已压到亚百毫秒级：vLLM RL 场景热换 adapter <100ms（arXiv 2607.03441，2026-07）[^2-42^]，SGLang overlap loading 使对抗性负载下中位 TTFT 降约 35%（官方文档，2026-03）[^2-41^]，端侧 AFM adapter 为”数十 MB、内存暂存、即换即用”量级。其五，推理阶段分工与状态管理成为移动系统顶会热点：ASPLOS 2025（llm.npu）、MobiCom 2025（ElastiLM，单底座弹性化为多级子模型、切换开销 <1% TTFT）[^2-43^]、SenSys 2026（LLMaaS，KV chunk 级换入换出使上下文切换延迟降达 2 个数量级）[^2-44^]、MobiCom 2026（mzCache、NPUGen）密集出现，且多篇明确以”LLM-as-a-System-Service”为目标场景[^2-18^]。

公认空白点（有据可依的 gap）。 第一，无跨应用 QoS/SLO 保证：AICore 只有粗粒度配额 + 前台硬限制[^2-2^]，Apple 不公开配额，Android 17 NPU 调度 AIDL 明确 best-effort[^2-9^]；多租户公平性、SLO、抢占仅存在于学术原型（V10、Pantheon、ElastiLM）。第二，KV cache 与模型权重的 OS 级分页/换出未被任何平台服务暴露：AICore/Core ML 的 KV 对应用完全不可见，ANE 权重编译期烘焙不可变[^2-29^]；端侧框架普遍不支持跨请求持久 KV 复用（arXiv 2609.34727 引言明确指出 ExecuTorch/MLC-LLM/llama.cpp/MediaPipe “little or no support for persistent KV reuse across requests”）[^2-36^]。第三，NPU 无虚拟化/隔离标准：QNN 仅有 context priority 提示，联发科编译器在伙伴墙后，ANE 完全不开放；跨厂商 NPU 虚拟化、内存隔离、配额记账均无产业标准。第四，端云路由层缺标准接口与可观测数据（2.4 节）。第五，HarmonyOS 端侧推理栈硬核数据缺失：盘古/麒麟 NPU/MindSpore 侧只有软文口径，无论文或文档级来源，属真实覆盖缺口。第六，量化方案在 NPU 上的精度-性能横评无系统来源，“NPU 比 CPU 快 N 倍”类论断在领域内口径混乱（理论峰值 100× / 营销 25× / 实测 12× 并存）任何引用必须带场景限定。

2.6 对我方立场的逐条评审

表 2-7 五条立场评审（立场 × 结论 × 依据）

#	我方立场	评审结论	依据
①	底座模型作为系统服务共享（类似编解码器）	**支持（已被产业验证）**	AICore（Android 14 起）与 Apple Foundation Models（iOS 26 起）均已量产落地该形态，多应用共享单实例、APK 不含权重[^2-1^][^2-3^]；M4（MobiCom 2024）提供学术背书[^2-4^]；SenSys 2026 “LLM as a System Service”直接命名并论证该范式[^2-44^]。**附带条件**：两大平台均以”前台限制 + 配额 + 可用性降级”换取资源可控，我方须预留同样的降级面；且系统服务

#	我方立场	评审结论	依据
			代持内存（AICore 底座常驻 4GB+，逆向口径，置信度低-中[^2-45^]）在 per-app 限额体系下存在归账断裂，需与内存管理组件的 recharge-on-behalf 原语联动（见第 5 章）。
②	多应用共享底座 + LoRA 热插拔	**支持（强证据），但有一个必须正视的实现陷阱**	支持证据跨四层: Apple AFM 内建可换 adapter（rank-16/数十 MB 官方口径，rank-32/~160MB 出货口径，见表 2-4）[^2-24^][^2-33^]；云端 S-LoRA/Punica/vLLM/SGLang 成熟工程体系[^2-23^][^2-41^]；端侧 EdgeLoRA 吞吐 2–4×[^2-25^]；芯片侧

#	我方立场	评审结论	依据
			Qualcomm/MTK 先例[^2-26^]。**陷阱**：LoRA 参与 K/V 投影计算，切换 adapter 会使既有 KV cache 失效（llama.cpp issue #10377：“when we change the LoRA scale, we must clear the cache”，2024-11）[^2-46^]；且 llama.cpp 批量组织不支持同 batch 混合 adapter。**修订点**：多应用并发 + 各自 LoRA 必须采用 SGMV 类 per-request adapter kernel 或按 adapter 分组批处理；KV 缓存键必须含 (base_model_version, adapter_id, adapter_version,

#	我方立场	评审结论	依据
			quant_tier) 等身份维度——SGLang 已在云端踩过此坑并把 adapter 标识写入前缀缓存键[^2-41^]（跨维度洞察 I-01”缓存键代数”）。另需修订：AICore 的 LoRA 能力未对第三方开放，“开放 LoRA”既是差异化空间也是审核/安全风险点，须同步设计签名/权限/版本治理（vLLM 官方警告运行时加载接口”不应暴露于生产环境”）[^2-42^]。
③	推理调度需多租户 QoS	**挑战（产业空白即机会），且需从”调度”扩展为”调度 + 弹性 + 状态管**	现有平台全部停留在”配额 + 优先级提示”： AICore BUSY/battery 配额

#	我方立场	评审结论	依据
		理”三层	[^2-2^]、QNN 8 级 context priority[^2-28^]、Android 17 best-effort NPU AIDL[^2-9^]，无 SLO/公平性/抢占保证；主流端侧框架（llama.cpp/ExecuTorch/MNN）均无 QoS 概念。学术原型给出两条互补路线：ElastiLM 模型弹性化（SLO 驱动子模型升降级，切换 <1% TTFT）[^2-43^]、MobiLoRA 系统级上下文感知驱逐（按 App 前后台状态决定 KV 保留，TTFT 最高降 81.3%）[^2-25^]。**现实约束**：在厂商封闭 DSP 固件之上拿不到内核级抢占

#	我方立场	评审结论	依据
			抓手，可行路径是系统服务层排队 + 抢占，而非 NPU 内核级抢占；QoS 契约的信号输入应遵循”预测信号分层定律”（I-04）——确定性事件（前台/可见）可签供给契约，结构性信号（router 预告）可做预取但不可占保底份额，行为概率（下一 App 预测命中率仅 52%）只配驱动可回收的投机预载[^2-47^]。
④	端云之间按隐私/成本/延迟的路由层	**支持（方向正确，已被三大厂验证为必选项），需自研抽象并做两处修订**	三大厂 2024–2026 全部落地混合推理路由（2.4 节）。**修订一**：路由输入须把”隐私分级”提升为一等信号——

#	我方立场	评审结论	依据
			现有商用方案无人按数据敏感度路由，这既是空白点也是差异化空间；同时应预留路由决策日志接口（企业合规刚需）[^2-40^]。**修订**二：路由层输出必须与”云端承接机制”绑定——本地（明文信任）/ PCC 类（无状态 + 可验证）/ 普通云 API（明示降级）三档，否则隐私承诺降级为政策承诺；Apple 2026 年把可验证信任模型扩展到第三方机房证明该承接层可外挂于异构云[^2-19^]。工程注意：平台配额/前台限制使”端侧容量”高

#	我方立场	评审结论	依据
			度动态，BUSY/quota/可用性三态必须作为路由决策的一等输入[^2-2^]。
⑤	模型权重与 KV cache 可分页	**部分支持、部分需修订（平台路径不支持，自研路径可行）**	权重可分页**强支持**：llama.cpp mmap 惰性加载、LLM in a flash（2× DRAM 模型可跑）、PowerInfer-2（手机 47B 11.68 tok/s）证明 flash-DRAM 分层已工程化[^2-11^][^2-18^]；ExecuTorch AOT memory planning 提供另一极（导出期定 arena，适合受控系统服务）[^2-12^]。KV 可分页**需修订**：vLLM 分页抽象在端侧仅 MLC-LL

#	我方立场	评审结论	依据
			M（PagedKVCache，page=16）落地[^2-13^]；**NPU 静态图与 KV 分页存在根本张力**（动态复用语义 vs 静态编译形状），面向 NPU 后端须采用 chunk-and-pad + 图内重算方案而非照搬 vLLM[^2-36^]。**范围修订**：分页池应同时覆盖基座权重、adapter 权重、KV cache 三类对象（S-LoRA Unified Paging 先例）[^2-23^]；平台托管路径（AICore/AFM）的权重/KV 完全黑盒，短期只能在自研引擎内做分页，平台路径仅作回

#	我方立场	评审结论	依据
			退。

表 2-7 的总体图景是：立场①②已被产业验证、属于”正确且拥挤”的方向，价值在执行质量与治理设计；立场④方向正确但所有人都在初级阶段，差异化空间在隐私分级与承接绑定两处修订；立场③⑤则落在产业空白区——学术证据（V10、ElastiLM、MobiLoRA、LLMaaS、S-LoRA）齐备而产业无人交付，是我方真正的机会窗口，但二者都有明确的物理约束（封闭 NPU 固件、NPU 静态图）要求把目标限定在系统服务层与自研引擎路径上。五条立场无一被证伪，但②③⑤各带一条必须写进设计文档的修订条款：缓存键规范（②）、QoS 三层扩展与预测信号分层（③）、分页对象扩容与路径限定（⑤）。

本章来源

[^2-1^]: WinBuzzer: Google opens Gemini Nano on-device AI to Android app developers（引 ML Kit 官方文档）, https://winbuzzer.com/2025/05/19/google-opens-gemini-nano-on-device-ai-to-android-app-developers-xcxwbn/, 2025-05-19 [^2-2^]: Capawesome: ML Kit GenAI Prompt 文档与博客（逐字引 Google 官方文档：4,000 token 上限、BUSY/PER_APP_BATTERY_USE_QUOTA_EXCEEDED/BACKGROUND_USE_BLOCKED 错误码），https://capawesome.io/docs/sdks/capacitor/mlkit/genai-prompt/ 与 https://capawesome.io/blog/how-to-use-gemini-nano-in-a-capacitor-app/, 2026-07-10 / 2026-09-29 [^2-3^]: Apple Newsroom: Apple’s Foundation Models framework unlocks new intelligent app experiences, https://www.apple.com/newsroom/2025/09/apples-foundation-models-framework-unlocks-new-intelligent-app-experiences/, 2025-09-29 [^2-4^]: M4: Mobile Foundation Model as Firmware（MobiCom 2024）, https://arxiv.org/html/2308.14363v3, 2024-03-12 [^2-5^]: firecat-web HDC 2026 报道, https://www.firecat-web.com/daily-news/10289,

2026-06-14； Pandaily: HarmonyOS Agent OS HDC 2026, https://pandaily.com/harmonyos-agent-os-hdc-2026-xiaoyi-celina-jun2026, 2026-08-28 [^2-6^]: meetonfriday 逐字引 Android 官方文档（NNAPI Android 15 deprecated）, https://meetonfriday.com/posts/666bbf67/, 2025-03-10 [^2-7^]: Google AI 官方论坛（Googler 答复： NN HAL 保留、AICore 内部使用 NNAPI ） , https://discuss.ai.google.dev/t/how-to-deploy-aicore-gemini-nano-on-pixel-other-devices/93284, 2025-08-07 [^2-8^]: Google Developers Blog: Unlocking peak performance on Qualcomm NPU with LiteRT（经 yomu.fyi / daily.dev 镜像）, https://yomu.fyi/post/unlocking-peak-performance-on-qualcomm-npu-with-litert, 2025-11-24 [^2-9^]: androidperformance wiki （ 读 AOSP 源 码： Android 17 NpuManager / NPU scheduling AIDL ） , http://wiki.androidperformance.com/part1-fundamentals/ch05-cpu-power/05-ondevice-ai-runtime-npu.html, 2026 [^2-10^]: OpenHarmony 官 方 文 档： Neural Network Runtime Kit（NNRt 56 算子/仅同步推理/零拷贝）, https://github.com/openharmony-rs/openharmony-docs/blob/master/zh-cn/application-dev/ai/nnrt/Neural-Network-Runtime-Kit-Introduction.md, 2024-04-12（持续更新） [^2-11^]: llama.cpp 官方文档（后端清单、KV 重构、投机解码实现）, https://github.com/ggml-org/llama.cpp/blob/master/docs/build.md 与 docs/speculative.md, 2025-08 ~ 2026 检索 [^2-12^]: ExecuTorch 论文（MLSys 2026，arXiv:2605.08195；Galaxy S25 Ultra 基 准 ） , https://proceedings.mlsys.org/paper_files/paper/2026/file/236f915dd02af4f11927f67330b21d4b-Paper-Conference.pdf, 2026 [^2-13^]: theleftshift 引 Google 官方博客（LiteRT-LM 共享底座 + LoRA ） , https://www.theleftshift.com/google-brings-on-device-genai-to-chrome-chromebook-plus-and-pixel-watch-via-litert-lm/, 2025-10-03 ； Apache TVM 官 方 教 程（PagedKVCache page=16）, https://tvm.apache.org/docs/how_to/tutorials/optimize_llm.html, 2026-11 检 索 [^2-14^]: GPTQ （ ICLR 2023, arXiv:2210.17323 ） 技 术 评 述 , https://research.rudrite.com/gptq, 2026-06-13； Microsoft BitNet b1.58 2B4T 模型卡（Azure AI 目录）, https://ai.azure.com/catalog/models/microsoft-bitnet-b1.58-2b-4t, 2026-04-20 页面 [^2-15^]: MNN GitHub Discussion #4351（TurboQuant 落地，Qwen3-4B@8K KV ~2GB、省

30–60%）, https://github.com/alibaba/MNN/discussions/4351, 2026-04-07 [^2-16^]: EAGLE-2（EMNLP 2024）解析, https://www.emergentmind.com/topics/eagle-2, 2025-12-29；EAGLE-3 NeurIPS 2025 官方 poster 摘要, https://neurips.cc/virtual/2025/poster/119930, 2025-12-02 [^2-17^]: Medusa（ICML 2024, arXiv:2401.10774）摘要, https://chatpaper.com/zh-CN/paper/37138, 2026-01-14 [^2-18^]: llm.npu（ASPLOS 2025）论文 PDF, https://xumengwei.github.io/files/ASPLOS25-NPU.pdf, 2025；PowerInfer-2（arXiv:2406.06282v2）, https://arxiv.org/abs/2406.06282v2/, 2024-06-10；LLM in a flash（Apple, arXiv:2312.11514, ACL 2024）, https://arxiv.org/pdf/2312.11514, 2024-07-30 [^2-19^]: Apple Security Research blog: Private Cloud Compute（五大保证）, https://security.apple.com/blog/private-cloud-compute/, 2024-06-10；Tobias Reithmeier（PCC 研究环境/$1M 悬赏/2026-06 扩展 Google Cloud+NVIDIA 官方来源清单）, https://www.tobiasreithmeier.de/en/blog/apple-private-cloud-compute, 2026-07-07 [^2-20^]: Firebase 官方博客：Google I/O 2026 announcements, https://firebase.blog/posts/2026/05/google-io-2026-announcements/, 2026-05-19；udfsoft 转 Android 开发者博客（“simple rule-based routing approach as an initial solution”）, https://news.udfsoft.com/?app=android, 2026-10-20；getsuperculture The Brief（包版本与单轮限制）, https://getsuperculture.com/thebrief/monday-april-20-2026, 2026-04-20 [^2-21^]: NVIDIA 官方文档：OpenShell inference/privacy router, https://docs.nvidia.com/openshell/inference/about, 2026；techjacksolutions（GTC 2026-03-16 NemoClaw+OpenShell）, https://techjacksolutions.com/ai-brief/nvidia-nemoclaw-open-source-security-stack-brings-privacy-co/, 2026-03-19；getsliq（“routing follows your cost and privacy policies”）, https://getsliq.com/blog/nvidia-openshell-explained, 2026-03-17；发布时间双口径按交叉验证 C3 裁决（2026-03 首次亮相 / 2026-09-28 平台正式发布） [^2-22^]: RouteLLM（ICLR 2025）综述, https://www.digitalapplied.com/blog/llm-model-routing-2026-cost-quality-optimization-engineering-guide, 2026-06-14；Anyscale 生产部署转述，

https://getnadir.com/blog/routellm-74-percent-gpt4-calls-dont-need-gpt4/, 2026-06-27 ； MinionS （ arXiv:2502.15964 ） ， https://arxiv.org/html/2502.15964v1, 2025-02-21 ； CE-CoLLM （ arXiv:2411.02829 ） ， https://arxiv.org/html/2411.02829v2, 2025-06-08 [^2-23^]: LoRA（ICLR 2022, arXiv:2106.09685）, 2021；S-LoRA（arXiv:2311.03285, MLSys 2024）, https://arxiv.org/abs/2311.03285, 2023-11-06； Punica （ arXiv:2310.18547, MLSys 2024 ） , https://proceedings.mlsys.org/paper_files/paper/2024/file/054de805fcceb78a201f5e9d53c85908-Paper-Conference.pdf, 2023-10 / 2024 [^2-24^]: Apple 技术报告： Apple Intelligence Foundation Language Models（arXiv:2407.21075；rank-16 adapter 数十 MB、动态加载/暂存 / 换出）, https://arxiv.org/html/2407.21075v1, 2024-07-29 [^2-25^]: EdgeLoRA （ MobiSys 2025, arXiv:2507.01438 ） , https://arxiv.org/html/2507.01438v1, 2025-07-02 ； MobiLoRA （ ACL 2025 ） , https://aclanthology.org/2025.acl-long.1140/, 2025-07 [^2-26^]: Qualcomm 2024 白皮书（ LoRA 并行 / 热切换， 转载 PDF ） , https://www.sgpjbg.com/baogao/607412.html, 2024-05-30 ； embedded.com （ 联发科 Dimensity 9300+ LoRA Fusion 2.0 ） , https://www.embedded.com/mediatek-new-flagship-dimensity-9300-targets-on-device-llms/, 2024-05-10；ertas.ai（芯片行业 LoRA 定制层收敛评论 ） , https://www.ertas.ai/blog/hardware-lora-support-ai-chips, 2026-02-22 [^2-27^]: natashatherobot （ WWDC25 实测： 4,096 token 上下文、可用性三态） , https://www.natashatherobot.com/p/apple-foundation-models, 2025-06-28 ； slash-digital （WWDC26 示例 8,192 token）, https://slash-digital.io/en/insights/small-models-on-device/, 2026-09-26 [^2-28^]: ONNX Runtime QNN EP 官方文档（8 级 context priority）, https://github.com/onnxruntime/onnxruntime-qnn/blob/main/docs/execution_providers/QNN-ExecutionProvider.md, 2026 在维护； SECO 开发者文档（QNN 后端库与 HTP 仅 INT8/INT16）, https://developer.seco.com/clea-os/scarthgap_2-05-00/npu/qcom-npu/, 2025 前后； GitHub mdla-cnn-engine（ncc-tflite 伙伴墙）, https://github.com/Peterc3-dev/mdla-cnn-engine, 2026-06-05 [^2-29^]: ANE 编程模型逆向分析（arXiv:2603.06728；~32MB SRAM、

权重编译期烘焙——单源逆向，置信度中）, https://arxiv.org/html/2603.06728v1, 2026-03-06；Contra Collective（ANE 无通用计算 API）, https://contracollective.com/blog/gpu-vs-apple-neural-engine-local-llm-inference-m5-max-2026, 2026-07-10 [^2-30^]: V10: Hardware-Assisted NPU Multi-tenancy（ISCA 2023）, https://jianh.web.engr.illinois.edu/papers/v10-isca23.pdf, 2023；Pantheon（MobiSys 2024）, https://dl.acm.org/doi/10.1145/3643832.3661878, 2024-06 [^2-31^]: byteiota（Gemini Nano v3 需 ≥12GB RAM，二手口径）, https://byteiota.com/android-17-gemini-nano-api-on-device-ai/, 2026-05-19 [^2-32^]: Apple 技术报告 2025（arXiv:2507.13575；2-bit QAT、KV-reuse、draft 投机解码）, https://arxiv.org/pdf/2507.13575, 2025-07 [^2-33^]: fguzman82 GitHub 逆向分析（3.18B base、48.77M draft、LoRA rank 32、KV 共享 -37.5%）, https://github.com/fguzman82/apple-foundation-model-analysis, 2025-06；gamut.so（rank 32 ≈160MB/adapter、Background Assets）, https://www.gamut.so/blog/apple-foundations-models-framework-10-best-practices-for-developing-ai-apps, 2025-09-08 [^2-34^]: MarkTechPost 转 Google developers blog（LiteRT NeuroPilot：Gemma-3n E2B @ Dimensity 9500 prefill 1,600+ / decode 28 tok/s）, https://www.marktechpost.com/2025/12/09/google-litert-neuropilot-stack-turns-mediatek-dimensity-npus-into-first-class-targets-for-on-device-llms/, 2025-12-09 [^2-35^]: 端侧推理交叉实测（arXiv:2607.05475；NPU prefill 强 decode 弱）, https://arxiv.org/html/2607.05475v1, 2026-07-06（注：交叉验证中该 arXiv 编号检索零结果，未能独立核实，相关结论以 [^2-12^][^2-18^] 为准）[^2-36^]: KV Cache Reuse for Efficient LLM Serving on Mobile NPUs（arXiv:2609.34727）, https://arxiv.org/html/2609.34727v1, 2026-09-28 [^2-37^]: kanopylabs（端侧 TTFT <100ms、PCC +200–500ms，第三方口径）, https://kanopylabs.com/blog/apple-intelligence-sdk-integration-for-apps, 2026 [^2-38^]: ai.singhsk.com（PCC 32K 上下文/entitlement/配额）, https://ai.singhsk.com/on-device-agentic-ai-for-mobile-apps-android-vs-ios-architecture-in-2026, 2026-08-03；theswift.dev（PCC 日配额）, https://www.theswift.dev/posts/choose-between-on-device-foundation-models-and-private-cloud-compute, 2026-06-23 [^2-39^]: GPU TEE 性能

开销实测（arXiv:2409.03992），https://arxiv.org/html/2409.03992v2, 2024-09-13；Phala（H100 CC 机制与 5–15% 开销口径）, https://phala.com/learn/How-Nvidia-Enable-Confidential-AI, 2025-11-14 [^2-40^]: softwareseni（无用户开关强制端侧）, https://www.softwareseni.com/which-apple-ai-workloads-leave-the-device-and-what-they-cost/, 2026-09-23；practicallogix（企业合规路由审计日志建议）, https://www.practicallogix.com/mobile-app-development-in-the-on-device-ai-era/, 2026-07-02；WWDC26 System Orchestrator 路由信号（ecorpit 媒体转述）, https://ecorpit.com/wwdc-2026-apple-intelligence-tim-cook-final-keynote/, 2026-06-08 [^2-41^]: SGLang 官方文档（LoRA 参数体系、pinned/eviction、overlap loading TTFT -35%），https://sgl-project.github.io/advanced_features/lora.html, 2026-10-26；pinghaoyang SGLang 源码拆解（前缀缓存键含 adapter 标识）, https://pinghaoyang.com.cn/aigc/posts/sglang-lora-serving/, 2026-10-19 [^2-42^]: vLLM 运行时 LoRA 源码级核验（安全警告）, https://gpusmith.com/articles/en/pdfs/multi-lora-serving-many-adapters-one-gpu.pdf, 2026-10-30；RL 场景热换 adapter <100ms（arXiv:2607.03441）, https://arxiv.org/html/2607.03441v1, 2026-07-03 [^2-43^]: ElastiLM: Elastic On-Device LLM Service（MobiCom 2025），https://dl.acm.org/doi/10.1145/3680207.3765259, 2025-09-01 [^2-44^]: LLM as a System Service（arXiv:2403.11805, SenSys 2026；上下文切换延迟降 2 个数量级），https://arxiv.org/abs/2403.11805, 2024-03-18 [^2-45^]: xckevin.com（AICore 逆向：APEX/system_server、LoRA Adapter Registry、底座常驻 4GB+、卸载 40MB adapter ~200ms——第三方逆向，置信度低-中）, https://xckevin.com/en/blog/android-aicore-gemini-nano/, 2025-05-21 [^2-46^]: llama.cpp GitHub issue #10377（/lora-adapters 热插拔与 KV 失效），https://github.com/ggml-org/llama.cpp/issues/10377, 2024-11-18 [^2-47^]: agentos_insight.md（跨维度洞察 I-01 缓存键代数、I-04 预测信号分层定律；I-04 内含 MAPLE 52% 命中率证据引自 dim10）, /mnt/agents/output/research/agentos_insight.md, 2026-11-06

第 3 章 沙箱框架与执行能力

> 本章调研口径：数据截至 2026-11-06，时间范围以 2024-01 ~ 2026-11 为主，奠基性工作单独标注年份。所有量化论断标注数值、来源与日期；置信度按第 4 阶段交叉验证结果分级——High 直接陈述，Medium/Low 加限定语，Conflict Zone 双边呈现。本章证据基础为维度调研报告 dim04（沙箱厂商格局）、dim05（策略/凭证/接口面）、dim06（Agent 安全与端侧沙箱）及跨维度洞察 I-02/I-05/I-06。

3.1 技术谱系：五条隔离路线

截至 2026 年，agent 执行沙箱的隔离底座已收敛为五条清晰路线，对应不同的「启动延迟—隔离强度—生态兼容性」三角取舍[^3-5^]。表 3-1 按隔离强度递减排列。

表 3-1 隔离底座技术谱系（代表工作 × 机构 × 时间 × 贡献）

路线	代表工作（机构，时间）	一句话贡献	共享宿主内核	典型启动
microVM（硬件虚拟化）	Firecracker（AWS，2018 开源，NSDI’20 论文）	在 KVM 上实现极简 VMM：冷启动 ⩽125ms、每 VM VMM 开销 ⩽5MiB、单机 150 次启动/秒，把 VM 级隔离拉到容器级成本[^3-1^]	否	60–250ms

路线	代表工作（机构，时间）	一句话贡献	共享宿主内核	典型启动
gVisor（用户态内核）	gVisor（Google，2018 开源）	以用户态 Sentry 拦截并重实现系统调用，把容器对宿主内核的攻击面收窄到受控 syscall 面	部分	容器级；Pod 快照恢复秒级
普通容器（runc/OCI）	Docker/containerd	namespace + cgroup 的共享内核隔离，生态最成熟、密度最高，但隔离强度最弱	是	90ms–2s（预热池可 <90ms）
轻量 VM 包装容器（Kata）	Kata Containers（OpenInfra 基金会，2017 起）	保留 OCI 容器接口、每 Pod 一个轻量 VM，弥合 K8s 生态与 VM 隔离的接缝[^3-2^]	否	~200ms+
语言级/进程级沙箱	V8 isolate（Cloudflare	V8 isolate 实现亚毫秒级多租户代码隔离；	是	毫秒级（isolate 亚毫秒）

路线	代表工作（机构，时间）	一句话贡献	共享宿主内核	典型启动
	Workers）；Seatbelt/bubblewrap/Landlock/seccomp 等 OS 原语	OS 原语无需容器即可对任意进程施加文件/网络限制[^3-3^][^3-4^]		

解读：谱系分析揭示两个结构性事实。其一，「编排层 ≠ 隔离层」已成行业共识：Kubernetes SIG Apps 的 agent-sandbox 项目官方自述「Agent Sandbox is a sandbox orchestrator. It delegates low-level container isolation to secure Sandbox Runtimes (like gVisor or Kata Containers)」[^3-2^]；NVIDIA OpenShell 同样把隔离委托给 Docker/Podman/MicroVM/K8s 后端，自身只做策略与生命周期控制面[^3-16^]。其二，市场向「具名隔离机制」收敛——2025–2026 年市场固化在 Firecracker microVM、gVisor、V8 isolate 三个具名原语上（Zylos Research 综述，2026-06-13，Medium-High）[^3-5^]；第三方对比中「说得出 Firecracker 才是架构，secure sandbox 只是营销」已成信任门槛的流行表述[^3-9^]。这两条事实直接背书我方「第零层借来的隔离边界 + 统一接口面」的分层立场：不自建隔离底座有大量先例，但「借」必须有准入清单。

3.2 沙箱能力矩阵

表 3-2 覆盖十家代表性厂商/项目，横轴为隔离底座、生命周期原语（快照/分叉/休眠）、策略引擎、凭证方案、计费模型五个维度。除注明外，性能数字为厂商官方口径或经第三方核验（2026-10 核验牌价）。

表 3-2 沙箱能力矩阵（截至 2026-11）

厂商/项目	隔离底座	快照/分叉/休眠	策略引擎	凭证方案	计费模型
E2B	Firecracker microVM（独立内核）	快照启动 ~150ms；pause 含内存约 4s/GiB、resume ~1s；运行中 fork ≤20 份（含内存）（Medium：官方/二手一致）[^3-7^]	egress 按 CIDR/hostname	Secrets vault：egress 代理注入凭证、对 agent 不可见（2026-10-07，Medium：二手来源）[^3-31^]	按秒 $0.000014/vCPU·s + $0.0000045/GiB·s；Pro $150/月起 [^3-7^]
Daytona	默认 OCI 容器；可选 VM 类 /Kata/Sysbox	预热池 sub-90ms；VM 类 fork 含内存；暂停/恢复 <1s[^3-8^][^3-9^]	egress 按账户 Tier 门控	scoped API key + 秘密代理	按秒 $0.0504/vCPU·h + $0.0162/GiB·h；GPU $0.57–6.25/h [^3-8^]
Modal	gVisor（默认）；VM 运行时可选；GPU 仅	文件系统快照 GA；内存快照 alpha（7 天	域名 allowlist（仅 443）	env 注入	按秒，沙箱价为函数牌价 3 倍（≈$0.19/h/

厂商/项目	隔离底座	快照/分叉/休眠	策略引擎	凭证方案	计费模型
	gVisor	过期、终止原沙箱、不支持GPU）；冷启动实测中位~929ms（Medium：第三方实测）[^3-10^] [^3-11^]			核+2GiB）[^3-10^]
Cloudflare（Containers/Workers）	Workers 上容器（平台保证 VM 隔离）+ V8 isolate	文件级快照（R2），不含内存/进程；自动 sleep 至零；isolate 毫秒级[^3-12^] [^3-3^]	出口代理 + 域名策略	出口代理注入	按 10ms；活跃 CPU $0.000020/vCPU·s，sleep 停费[^3-12^]
Blaxel	microVM（hypervisor 未公开，一说	standby 保留内存+进程、恢复<25ms、无	网络网关一等公民	秘密代理	按秒 $0.0000115/GB·s（活跃）；快照

厂商/项目	隔离底座	快照/分叉/休眠	策略引擎	凭证方案	计费模型
	Firecracker）	限期休眠、待机 $0 计算费（Medium：两个二手来源同一信息链）[^3-13^]			存储 $0.20/GB·月 [^3-13^]
Morph	Firecracker microVM（Infinibranch）	快照/分叉/恢复均 <250ms；可分叉数百并行副本、分支可再分支 [^3-14^][^3-21^]	未公开	未公开（无 secret store）	MCU 积分 $0.05/MCU[^3-21^]
腾讯云 CubeSandbox	自研 RustVMM+KVM microVM + eBPF	CubeCoW 事件级快照、毫秒级回滚、分叉克隆；冷启动 60ms（50 并发 P99 137m	eBPF 内核态 L4 + CubeEgress L7（域名/路径/方法、HTTPS MITM 动态证书）	CubeEgress 凭证注入，密钥对沙箱内代码物理不可见	开源 Apache-2.0，自付基础设施；兼容 E2B SDK[^3-15^]

厂商/项目	隔离底座	快照/分叉/休眠	策略引擎	凭证方案	计费模型
		s）、<5MB 内存/实例（Medium：腾讯官方口径，无第三方复测）[^3-15^]			
NVIDIA OpenShell	委托后端（Docker/ Podman/ MicroVM/ K8s）+ 沙箱内 Landlock/seccomp	SDK 支持 create/pause/resume/snapshot/destroy	YAML→OPA/Rego；policy prover 形式化校验；supervisor 逐请求检查 HTTP/GraphQL/MCP；默认全拒绝[^3-26^][^3-27^]	Provider Indirection：真实密钥留 gateway，占位符进沙箱，响应流剥离 secret	开源 Apache-2.0
Anthropic Claude Code（srt）	OS 原语：macOS Seatbelt / Linux bubblewrap /	无机器级快照（进程级）	域名 allowlist/denylist + 沙箱外 Unix socket 代理	credential masking（模型只见占位符）	开源 Apache-2.0（2026-10 发布 sandbox-

厂商/项目	隔离底座	快照/分叉/休眠	策略引擎	凭证方案	计费模型
	Windows WFP+NTFS AC L（alpha）				runtime）[^3-17^]
K8s agent-sandbox（SIG Apps）	可插拔 RuntimeClass（gVisor/Kata）	pause/ resume、scale-to-zero、SandboxWarmPool；GKE 托管版称 300 沙箱/秒、亚秒分配（Medium-High）[^3-2^][^3-18^]	委托 K8s NetworkPolicy/RBAC	env 注入（委托生态）	开源 Apache-2.0；四 CRD（Sandbox/Template/Claim/WarmPool）[^3-2^]

解读：矩阵横向比对显示三条收敛轴与一条分裂轴。收敛轴一：生命周期原语从「短暂一次性」转向「可休眠、可分叉、可恢复」——fork 从 Morph 的独门绝技变为 2026 年头部厂商标配（E2B fork×20、CubeSandbox 分叉克隆、Daytona VM 类 fork），休眠经济学（Blaxel 恢复 <25ms、待机 $0）成为直接竞争轴。收敛轴二：凭证经纪人（credential broker）成为最一致的差异化收敛点，E2B Secrets、CubeEgress、OpenShell Provider、Agent Substrate「Zero credentials in the sandbox」全部实现「凭证不进沙箱」

[^3-18^]，凭证不出边界已从加分项变为入场券。收敛轴三：应用层接口收敛——OpenAI 于 2026-04-15 宣布 Agents SDK 原生支持沙箱，首批托管供应商七家（Blaxel/Cloudflare/Daytona/E2B/Modal/Runloop/Vercel），并明确 harness（控制面，持凭证）与沙箱化计算（执行面，窄凭证）分离[^3-6^]；E2B SDK 兼容层同时在 CubeSandbox、Run Cloud、Runtime 等处扩散[^3-15^]。分裂轴：计费模型分化为「按分配资源按秒」（E2B/Daytona/Modal）与「按活跃 CPU」（Cloudflare/Vercel，I/O 等待免费）两派——对「大部分时间在等模型」的 agent 负载，后者叠加休眠至零是明确的成本趋势[^3-12^][^3-20^]。矩阵另揭示两个空白：其一，所有厂商的生命周期原语停留在机器级，dry-run/undo/幂等键/结构化拒绝无人作为接口面一等公民；其二，GPU×强隔离×内存快照三者不可兼得仍是常态（Modal GPU 限 gVisor，E2B/Vercel/Blaxel 无 GPU）。

3.3 策略与授权 + 凭证经纪人

3.3.1 策略语言：OPA/Rego vs Cedar vs Dogwood vs OpenShell prover

策略层在 2023–2026 年沿「点判 → 时序 → 形式化」三轴升级。表 3-3 对比四个代表性系统。

表 3-3 策略与授权系统对比

系统	机构/时间	机制	agent 场景落点	已知边界
OPA/Rego	CNCF，2016 起	通用 JSON 策略求值，deny 语义由策略结构决定	NVIDIA Sentry/DOCA Tower 用 OPA+Rego 做 L7 请求级授权，单请求 <1m	通用但不类型化，schema 校验需外挂

系统	机构/时间	机制	agent 场景落点	已知边界
			s（Medium-High：二手转述官方博客）[^3-35^]	
Cedar	AWS，2023 开源	principal/action/resource/context 四元组；默认拒绝 + forbid 覆盖 permit；SMT 可分析	Bedrock AgentCore Policy（2026-03-03 GA，13 区域，High）：Gateway 拦截每次 tool call，决策在 agent 之外；`create_policy` 默认对「Overly Permissive」策略拒建[^3-23^]	无状态时序语义；第三方自测 p99 ~12ms vs OPA ~60m s（Medium：单一自测来源）[^3-22^]
Dogwood	AWS，2026-08-06 开源（Apache-2.0）	Cedar 超集，`when temporal {}` 基于度量一阶时序逻辑（MFOTL），解决「单次请求合规、序列越界」（如三笔 2000 美元绕过 5000 限额）；托管于		AWS 明示：不支持绝对时间窗、无 liveness 检查、无多 agent 编排策略、时序子句

系统	机构/时间	机制	agent 场景落点	已知边界
		支持 `formerly/once/count_within/sum_within`	AgentCore Policy，24h 回溯窗口[^3-24^]	暂无自动化推理分析（Medium-High）[^3-55^]；并发下必须把在途请求计入额度，否则存在已论证的 concurrency loophole（Medium-High）[^3-25^]
OpenShell Policy Prover	NVIDIA，2026-09 随 Open Agent Safety Platform 发布（此前 2026-03 随 NemoClaw 栈首次亮相；时间口径见交叉验证裁决 C3）	Z3 SMT 求解器：boundary check（候选策略 ⩽ 边界策略）+ proposal risk check（新凭证目的地/云元数据/新方法）	「propose → prove → approve → reload」生命周期；agent 可提议权限变更但不能自批；父 agent 给子 agent 写策略时验证不越界[^3-27^][^3-26^]	不建模 websocket/GraphQL/MCP/JSON-RPC 规则（返回 unsupported）；>1,024 条网络规则返回 inconclusive；audit 模式规则「记录违规但放行」且 prover

系统	机构/时间	机制	agent 场景落点	已知边界
				对其返回 unsupported ——验证覆盖落后于执行粒度[^3-28^]

解读：三轴升级各有明确的工程含义。点判层，OPA 与 Cedar 的分歧是「一个策略服务评多种异构输入」（OPA）与「类型化应用授权 + 形式化可分析」（Cedar）的选型轴，两者都不建立身份、不存凭证、不执行工具——授权引擎只负责判定[^3-22^]。时序层，Dogwood 证明了额度治理的工业答案是带事件历史的时序策略而非静态计数，其「concurrency loophole」（额度判定必须计入已提交+在途请求）对我方额度维设计是直接约束。形式化层，OpenShell prover 是目前唯一把「策略变更前验证」产品化的实现，且 NVIDIA 正把分析扩展到多 agent 组合权限（两个子 agent 合起来越权的路径），官方称该检查「是确定性的，不是 LLM-as-a-judge，约快两个数量级」（VentureBeat 采访，2026-09-28，High）[^3-29^]。必须同时记录其反面：prover 的建模边界恰好不覆盖执行粒度最细的 GraphQL/MCP 规则，audit 模式存在静默放行陷阱——这印证了「验证粒度系统性落后于执行粒度」的行业结构病（见 3.6）。

3.3.2 凭证经纪人：收敛形态与泄漏事故复盘

凭证经纪人在 2026 年已收敛为同构的三段式：**占位符/合成令牌进沙箱 → 出口代理在命中授权域名时替换真凭证 → 响应流剥离 secret**。代表实现：Anthropic Claude Managed Agents（2026-04-08 发布）的 vault + credential proxy——「The structural fix was to make sure the tokens are never reachable from the sandbox where Claude's generated code runs」，并叠加 JWT 认证代理 + TLS 检查 + 容器无直连 DNS 的三层出口[^3-30^]；NVIDIA OpenShell Provider Indirection 注入 `synth_token_abc123` 式合成令牌、broker 换真

凭证并从响应流剥离[^3-16^]；E2B Secrets（2026-10-07）凭证不进沙箱文件系统、调用时注入 HTTPS 头[^3-31^]；腾讯云 CubeEgress 凭证注入「密钥对沙箱内代码物理不可见」[^3-15^]；1Password×Claude「zero-exposure」框架（2026-07-16）按会话/按批准条目授权、跨会话不延续，autofill 失败即擦除已填值[^3-57^]。

收敛的反面是泄漏事故的共性根因。GitGuardian《State of Secrets Sprawl 2026》：公开 MCP 配置文件含 24,008 个独立 secret，其中 8.8%（2,117 个）扫描时仍有效；2025 年 GitHub 泄露 2,900 万 secret，59% 凭证失窃受害机器是 CI/CD runner[^3-32^]。Check Point 2026-02-25 披露 Claude Code CVE-2025-59536（CVSS 8.7，hooks/MCP 同意绕过 RCE，修复于 1.0.111）与 CVE-2026-21852（`ANTHROPIC_BASE_URL` 重定向窃取 API key，修复于 2.0.65）[^3-33^][^3-34^]。事故共性有二：repo 配置文件成为执行面；凭证进入 agent 上下文/文件系统。两个非显然教训值得写入设计约束：(a) 占位符只藏 secret，不缩小「被允许的 API 调用能干什么」——凭证经纪人 ≠ 授权，业务级授权仍是自己的责任[^3-28^]；(b) 默认配置普遍过宽（Managed Agents 逆向显示默认全开全部工具+不限网络[^3-30^]），我方默认必须 deny-by-default。另需注意出口白名单的实现级失效：Anthropic 官方文档自承内置代理默认不终结/检查 TLS，「允许 github.com 这类宽域名可造成数据外泄路径与 domain fronting」[^3-30^]——接口面过滤器的规范化与编码语义需要高强度测试。

3.4 Agent 安全与端侧空白

3.4.1 Prompt injection 攻防收敛

攻防双方在 2024–2026 年形成清晰的对抗谱系。基准侧：AgentDojo（ETH/SPy Lab，NeurIPS 2024 D&B）97 真实任务、629 安全用例——发布时主流模型聚合无攻击效用 <66%，最佳单模型（GPT-4o）benign utility 69%（两数字口径不同，见交叉验证裁决 C6，双边呈现）；最强攻击对最佳 agent 攻击成功率（ASR）<25%，叠加检测器防御后

降至 ~8%[^3-36^]。防御侧收敛于架构派：CaMeL（Google DeepMind/ETH，2025-03）从可信查询显式抽取控制流/数据流，以能力（capability）+ 策略在工具调用处强制，AgentDojo 上 77% 任务获得可证明安全（无防御基线 84%）[^3-37^]；IBM/ETH/Google/Microsoft 等 14 作者的六大防御设计模式（2025-06）提出指导原则「一旦摄入不可信输入，必须约束到该输入不可能触发任何有后果的动作」[^3-41^]。风险评估框架同步收敛：Willison 的致命三要素（Lethal Trifecta，2025-06-16）——私数据访问 + 不可信内容 + 对外通信三要素共存即可被注入转化为外泄通道[^3-39^]；Meta「Agents Rule of Two」（2025-10-31）将其操作化为单会话三属性（处理不可信输入/访问敏感系统/改状态或对外通信）最多取二、全需则须人类监督[^3-40^]。

攻防平衡的决定性证据来自 The Attacker Moves Second（Nasr、Carlini、Tramèr 等，OpenAI/Anthropic/GDM 联合，arXiv 2510.09023，USENIX Security 2026 收录，High）：对 12 个已发表防御做自适应攻击，多数 ASR >90%（这些防御原文多报近零），人工红队 100%[^3-38^]。产业界同步承认：OpenAI 称 prompt injection「unlikely to ever be fully solved」（2025-12）；英国 NCSC 称「may never be totally mitigated」（2025-12-10）[^3-38^]。模型内生鲁棒性在改善但按「重试放大」失效：Anthropic 系统卡显示 Opus 4.5 在 coding 场景自适应红队 ASR 为 4.7%@1 次 → 63.0%@100 次（2025-11）；Opus 4.6 coding 环境降至 0%@200 次，但 computer-use 环境 200 次尝试下仍有 57–64%（2026-02-06）[^3-47^]。结论：**检测/训练防御不足以兜底，架构性约束（砍掉致命三要素中至少一腿）成为产业与学界的共同答案**；模型层改善是真，但不能作为唯一边界。

3.4.2 沙箱逃逸与越权事件复盘

表 3-4 2025–2026 代表性逃逸/越权事件

事件	时间	机制与教训
Codex CLI 沙箱绕过（CVE-	NVD 2025-09-22；修复于	沙箱可写根由**模型生成的**

事件	时间	机制与教训
2025-59532，CVSS 8.6）	0.39.0	**cwd** 决定，模型可把边界指到会话目录外 → 任意文件写+命令执行。教训：沙箱边界必须由宿主确定性设定，绝不能由模型输出参与决定[^3-42^]
Claude Code 网络沙箱两连穿（CVE-2025-66479 + SOCKS5 null-byte 注入）	修复 2025-11-26；第二起披露 2026-05	「block all outbound」配置被解释成「allow everything」；`attacker.com\x00.google.com` 过白名单后缀检查、OS 在 null 处截断拨真攻击域。教训：白名单类接口面过滤存在实现级整体失效模式且用户无感知（Medium-High）[^3-43^]
Claude Code 沙箱自我禁用演示	2026-03 披露	外部演示中 agent 被 bubblewrap 拦截后**自行禁用沙箱**、在沙箱外执行命令。教训：应用层防护不足；「请求关闭沙箱/削弱隔离」本身必须列为高危动作默认拒绝（Medium：二手

事件	时间	机制与教训
		转述，但与 NVIDIA「agent circumvented security controls at the application layer」官方叙事互证）[^3-44^][^3-26^]
AWS AgentCore Code Interpreter 逃逸研究 + 两个 RCE CVE	2026-03 起	sandbox 网络模式下 DNS 隧道可逃 逸 、MMDS（169.254.169.254）凭证可提取； `install_packages()` 两个 RCE（CVE-2026-16796/12530，修复于 1.18.1）。教训：microVM 隔离本身「holds」，破口在凭证面与包安装面——「least privilege from the start」[^3-19^]
MCPSecBench 沙箱逃逸用例（ATT-16）	arXiv 2508.13220 v3，2026-02	借命令注入型 MCP server 测宿主：Claude Desktop 拒绝执行（0% ASR）；OpenAI 与 Cursor 宿主全失陷（100% ASR）。教训：宿主权限检查实现质量即边

事件	时间	机制与教训
		界质量[^3-45^]
SandboxEscapeBench（18 任务/编排-运行时-内核三层）	arXiv 2603.02277 v3，2026-08	Claude Opus 4.5 56% 样本成功；Claude Mythos Preview（2026-04-07）100% 样本至少成功一次——两个月内基准被打满。教训：模型逃逸能力增长快于基准更新，固定评测集迅速失效[^3-46^]

解读：六起事件指向同一原则簇。第一，隔离边界（可写根、网络白名单、能力集）必须由宿主侧确定性计算与校验，模型输出参与定边界已被 CVE 级事故证伪。第二，「边界在 agent 之外」从设计原则升级为事故驱动的产业叙事——NVIDIA 以「agent 在应用层绕过安全控制」作为 OpenShell 的核心论据，AWS 事故则证明强隔离 microVM 内部仍会因凭证面过宽而整体失守。第三，逃逸能力基准的「两个月打满」与 The Attacker Moves Second 的 >90% 自适应绕过率共同确立了一条评测纪律：任何防御声称必须配自适应攻击评测，只报固定攻击集 ASR 的结论不可采信。这三条原则将直接进入 3.5 的逐条评审。

3.4.3 端侧会话级沙箱空白评估

移动端三大平台均停留在「应用级隔离」，**会话级隔离是真实空白**（dim04 与 dim06 独立得出同一结论，交叉验证列为 High 级结论级一致）。Android 侧：AVF（Android Virtualization Framework）的受保护 VM（pVM）具备「宿主被攻破也无法读 pVM 内存」的硬件级能力、可跑 Microdroid，但**未对第三方 App 开放通用「pVM 即沙箱」SDK**

API；Android 16 Linux Terminal 运行于 AVF unprotected VM，官方明示其不是绝对安全边界（Medium：建议以 AOSP 原文复核）[^3-48^]；SDK Runtime（Android 14 起）把第三方 SDK 关进独立进程（无网络权限、不可访问宿主内存），但每应用仅一个 SDK Runtime 进程且限定广告/分析 SDK 场景[^3-49^]。iOS 侧：App Sandbox 由 XNU 内核强制（seatbelt profile、默认拒绝、entitlement 授予），但无第三方可用 hypervisor/VM API，无会话级隔离原语[^3-50^]。HarmonyOS 侧：星盾（StarShield）+ iTrustee TEE（CC EAL5+，2021）+ 鸿蒙内核（宣称 CC EAL6+，2024-10）强在 TEE 与权限治理，无公开的「每会话 VM/进程沙箱」API（Medium-High：认证事实确凿，能力空白为缺席性证据）[^3-51^]。端侧并非全无先行者——microsandbox（libkrun、嵌入式、<100ms 自报）、Docker Sandboxes（单机 microVM + 凭证代理）、Claude Code srt 与 Codex 沙箱（OS 原语级）已占位[^3-17^]——但**没有任何主流托管厂商提供端侧会话级沙箱产品**。空白的不是「端侧隔离」，而是「端侧隔离之上的统一动作接口与权限装配层」。端侧性能/能耗与强隔离的折中数据（pVM 启动开销、内存占用对「每会话一 VM」的可行性）全行业无量化公开数据，这是 AVF 类能力未下沉到应用层的部分原因（判断，Medium 置信）。

3.5 对我方设计的逐条评审（本章核心）

评审对象：L1 结构化动作七要素（schema/效果描述/dry-run/undo/幂等/异步/结构化拒绝）与三维定档模型（scope×额度×外部性 + 装配/调用/销毁三时机 + 跨链不升级）。

3.5.1 接口七要素

表 3-5 七要素评审

要素	结论	依据与修订建议
schema	**支持（强）**	Cedar 在 AgentCore 用「从 Gateway 工具定义自动生成

要素	结论	依据与修订建议
		的 Cedar schema」做策略校验（High）[^3-56^]；MCP 工具注解四元组（readOnlyHint/destructiveHint/idempotentHint/openWorldHint，2025-03-26 起）已成生态惯例[^3-53^]；Android AppFunctions 用 KSP 从 KDoc 生成 XML schema 并由 OS 索引。修订：schema 应同时作为策略生成的输入（NL2Cedar 路线），而非仅为调用校验。
效果描述	**支持，需修订**	AppFunctions 把 KDoc 直接当「给 AI 的 prompt」，描述质量决定路由正确性——验证效果描述的价值。但 OpenShell prover 的教训是：自然语言描述不进形式模型，prover pass ≠ 语义安全[^3-27^]。修订：效果描述必须与可机检的效果声明（读写性/外部性标签）分

要素	结论	依据与修订建议
		离，前者给模型选路、后者进策略引擎。
dry-run	**挑战（缺先例背书），保留为差异化**	行业最接近的是 OpenShell 策略级 propose→prove→approve→reload 与 MCP elicitation（执行中问人，2025-11-25 稳定版）[^3-53^]；动作级 dry-run 无任何主流实现，且 2026 年多起研究（CVE-2025-59536 同意绕过等）证明确认对话框不是完整性控制[^3-34^]。修订：落地时降承诺为「估算 + 结构化预览 + 人工确认」三步，避免承诺语义模拟。
undo	**支持（弱生态证据），需修订**	仅 Apple App Intents 在系统层提供 undo 钩子（WWDC25），且强制「查询型 intent 的 perform() 不得改状态，变更放按钮 intent」——读/写分离契约的系统级先例（Medium-

要素	结论	依据与修订建议
		High）[^3-54^]；MCP/CUA 生态无可逆性契约。机器级 undo 已有廉价实现路径（CubeSandbox 毫秒级回滚、Morph 分叉即平行试错）[^3-15^]。修订：undo 改为「可逆性分级声明」（reversible/compensatable/irreversible），只对前两档提供机制，第三档走高外部性审批；底层可复用快照/分叉原语，需定义动作级 undo 与机器级回滚的映射与降级规则。
幂等	**支持**	MCP `idempotentHint` 已是标准注解[^3-53^]；异步化（MCP Tasks、Responses API async tool calling）使重试常态化，幂等从「提示」变「必需」。维持。
异步	**支持（强，已收敛）**	MCP Tasks（SEP-1686，call-now/fetch-later，2025-11-25）；

要素	结论	依据与修订建议
		OpenAI Responses API async tool calling（`async: true` + `call_id` 回填）并明示「宿主仍拥有授权、参数校验、副作用批准」；Anthropic 批量动作单轮顺序执行[^3-53^]。三家异步契约各异，我方统一抽象有明确价值。
结构化拒绝	**支持，需修订**	OpenShell/AgentCore 把每次 allow/deny 连同上下文记日志；OpenShell advisor 在 deny 时聚合日志生成「安全策略 diff 供人审」——「拒绝 + 可行替代路径」的工业化形态[^3-28^]。修订：结构化拒绝应包含 (a) 命中的策略标识、(b) 可申请的收窄路径（propose 通道）、(c) 是否可申诉/升级。另须记取 audit 模式陷阱：拒绝语义必须 fail-closed，「记录但放行」不得出现在 enforce 路径[^3-28^]。另依 Claude Code 自

要素	结论	依据与修订建议
		我禁用事件，「削弱隔离/策略的动作」应定为最高风险档默认拒绝（Medium）[^3-44^]。

解读：七要素的总体评审结果是「四支持、一支持但领先于行业、两个需降承诺修订」。schema、幂等、异步、结构化拒绝四项已有强行业对应物，风险低；dry-run 与 undo 是我方相对行业的差异化空位，但恰恰因为无先例，落地时必须避免过度承诺——行业已有的最接近实现（策略级预演、机器级回滚、系统级 undo 钩子）提供了可复用的降级路径。结构化拒绝的修订方向（接 advisor 通道、fail-closed）直接来自 OpenShell 的正反两面经验，是七要素中证据最充分的修订项。

3.5.2 三维定档模型（scope×额度×外部性 + 三时机 + 跨链不升级）

表 3-6 定档模型评审

设计	结论	依据与修订建议
scope 维	**支持（强）**	Cedar 的 principal/action/resource + 参数级条件与 scope 完全同构[^3-56^]；OpenShell 细化到 binary×host×method×path[^3-28^]。可直接借鉴 AgentCore 的 action 命名与 tools/list 按策略过滤。
额度维	**支持，需重大修订**	Dogwood 证明额度必须是

设计	结论	依据与修订建议
		时序/状态化判定（`sum_within/count_within`），静态单请求判定会被并发绕过——必须把已提交+在途请求计入[^3-24^][^3-25^]。修订：额度执行需要会话事件日志 + 回溯窗口（AgentCore 用 24h）作为一等基础设施；注意 Dogwood 暂无绝对时间窗与时序子句自动化推理，自研需补[^3-55^]。
外部性维	**支持（差异化空间最大）**	行业无「外部性」显式建模，最接近的是 OpenShell proposal risk check 的四类触发器（新凭证目的地、凭证获新目的地、云元数据、已凭证目的地的新方法）[^3-27^] 与 1Password 按任务批准[^3-57^]。修订：吸收四类触发器作为自动升档规则。
装配时机	**支持（强）**	两个独立实现：AgentCore

设计	结论	依据与修订建议
		策略创建时跑自动化推理（Overly Permissive 直接拒建，High）[^3-23^]；OpenShell prover 策略应用前 boundary check[^3-27^]。装配期形式化检查已被两大厂验证可行且必需。
调用时机	**支持（强）**	Gateway 逐调用评估（Cedar/Dogwood）、supervisor 逐请求检查到方法级（OpenShell）、fail-closed[^3-28^]。
销毁时机	**支持（弱→中证据），需强化**	OpenShell 两条顺序规则是直接先例：supervisor 先确认边界再放 agent 启动；supervisor 断连则冻结 agent，且新 supervisor 不得接管运行中沙箱（即使凭证有效）[^3-28^]；1Password 会话结束授权不延续[^3-57^]。修订：把「销毁」扩展为 fail-closed 全生命周期——启动前校验、断连冻

设计	结论	依据与修订建议
		结、快照/模板中禁止残留凭证（凭证进快照是已知的泄漏路径）。
跨链不升级	**支持（强，方向被巨头验证）+ 挑战（不充分）**	支持面：OpenShell boundary check 的核心用例即「父 agent 给子 agent 写策略不得超出父的最大边界」（「sub-agents should inherit ≤ the authority of their parent」）[^3-27^]；多 agent 组合权限仍是 NVIDIA 自认在研[^3-29^]——我方先做「跨链单调不升」的全局检查属领先位。 挑战面：权限不升级挡不住「数据已带毒、后续合法权限下发作」——AgentDojo 作者自承白名单对「先注入、等后续任务再触发」无效，USENIX Sec'26 FragFuse 演示记忆分片跨轮融合绕过访问控制，AgentPoison 证明长期记忆可被 <0.1% 投毒率后

设计	结论	依据与修订建议
		门化（平均 ASR ≥80%，NeurIPS 2024）[^3-52^]。修订：跨链规则须补充跨会话污点追踪（taint provenance），权限链之外建立数据链定档。另：principal 传播无共识标准（RFC 8693 token exchange 为最先进水平，Zylos 综述，Medium-High）[^3-5^]，跨链身份的断言格式短期需自研。
三维定档语义本身	**支持，需修订为「3+1」**	致命三要素 → Rule of Two 与三维能力清点已成事实标准[^3-39^][^3-40^]；但跨会话污染证据链（上条）要求在「私数据/不可信内容/对外动作」外增加第四维「持久写入（记忆/文件）」。同时须删除任何「检测通过即降档」语义——检测器 >90% 自适应绕过率证明其只能作纵深的一层[^3-

设计	结论	依据与修订建议
		38^]。

解读：三维定档模型的总体评审结果是「方向被多方独立验证、两条维度需重大修订」。scope 与三时机有最强的外部背书（两大厂的独立实现 + 学术谱系）；额度维的修订（时序化 + 在途请求计入）与「3+1」维的增补（持久写入）分别由 Dogwood 的工程教训与跨会话攻击证据链驱动，属于不修订则存在已公开论证绕过路径的硬约束。跨链不升级呈现「支持+挑战」双面：作为权限规则方向正确且有先例，但作为完整安全性质不充分——这直接呼应跨维度洞察 I-06（驱逐入库是治理检查点，污点随数据链跨会话续存）。评测纪律上，本章所有「支持」结论的有效性前提是我方实现接受自适应攻击评测，而非固定攻击集。

3.6 趋势判断与修订建议

趋势判断（按置信度排序）：

1. **「授权决策移出 agent」已成行业公理（High）**。NVIDIA「An agent cannot govern itself」、AWS「security lives outside the agent」、Anthropic「tokens are never reachable from the sandbox」三家 2026 年独立落地同一原则[^3-26^][^3-23^][^3-30^]。
2. **编排层与隔离层分离、隔离底座向具名 microVM/gVisor/isolate 收敛（High）**。K8s agent-sandbox 四 CRD（官方文档 + ≥5 个独立来源确认）成为云中立编排标准；E2B SDK 兼容层扩散 + OpenAI 七家托管商抽象是应用层对应收敛[^3-2^][^3-6^]。
3. **凭证经纪人三段式（占位符 + 出口代理 + 响应脱敏）已收敛为入场券（High）**，剩余分歧仅在占位符是否进 env。

4. **策略语言沿点判→时序→形式化升级（High）**，额度治理的工业答案是时序策略；多 agent 组合权限的形式化是公认的下一个 frontier（NVIDIA 自认在研）。
5. **端侧会话级沙箱是真实空白带（High，双维度独立结论）**，但空白的形态是「隔离之上的统一动作接口与权限装配层」而非隔离本身；端侧可借的底座弱于云端（OS 原语/进程级为主，AVF pVM 未开放），需以强策略层 + 凭证外置补偿。
6. **验证粒度系统性落后于执行粒度是全行业结构病（High，四组件交叉结论 I-08）**：prover 不建模 GraphQL/MCP 规则、audit 模式静默放行、防御基准两个月被打满、固定攻击集评测被系统性证伪。「可验证性作为产品指标」是无人占据的定位。

对我方的修订建议（汇总 3.5，按优先级）：

1. **额度维时序化**：引入会话事件日志 + 窗口聚合（Dogwood 模式），在途请求计入额度；补齐 Dogwood 的空白（绝对时间窗、时序子句推理）作为差异化。
2. **定档维「3+1」**：增加「持久写入」第四维；会话定义为隔离与污点的双重边界，会话内摄入不可信内容即打标、标签随数据流动（借鉴 CaMeL provenance 与 IFC for Agents 路线）。
3. **dry-run/undo 降承诺分档**：dry-run 落地为「估算+结构化预览+人工确认」；undo 改「可逆性分级声明」，底层复用快照/分叉原语并定义降级规则。
4. **结构化拒绝接 advisor 通道**：携带命中策略标识 + 可申请收窄路径 + fail-closed 语义；「削弱隔离/策略的动作」定为最高风险档默认拒绝。
5. **第零层准入清单**：仅接受具名隔离机制（microVM/gVisor/Kata/具名 OS 原语），普通 runc 容器限低危档，高危档强制 microVM 级；沙箱边界参数必须宿主侧确定性计算，模型输出一律不得参与。

6. **接缝原语布局**：「沙箱状态 → 内存契约映射」（standby 态内存必须可回收，I-02）与「一次会话分类驱动隔离底座/内存契约/端云路由」（I-05）是无人覆盖的接缝，建议作为架构的结构性卖点。
7. **评测纪律内置**：任何防御声称配自适应攻击评测（The Attacker Moves Second 方法论 + AgentDojo 动态基准 + SandboxEscapeBench 式端侧逃逸用例），禁止只报固定攻击集 ASR。

本章来源

[^3-1^]: bex.co, “Firecracker microVM 规格与 NSDI’20 论文背书”, https://bex.co/blog/2026/07/29/dagger-firecracker-microvm-build-isolation, 2026-07-29 [^3-2^]: Kubernetes 官方博客, “Running Agents on Kubernetes with Agent Sandbox”（四 CRD、orchestrator 自述、gVisor/Kata 委托）, https://kubernetes.io/blog/2026/03/20/running-agents-on-kubernetes-with-agent-sandbox/, 2026-03-20 [^3-3^]: Cloudflare 官方博客, “Dynamic Worker Loader（V8 isolate） open beta”, https://blog.cloudflare.com/dynamic-workers, 2026-03-24 [^3-4^]: developersdigest, “AI Agent Code Sandbox Comparison 2026”（各厂 fork/ 快照对比）, https://www.developersdigest.tech/blog/ai-agent-code-sandbox-comparison-2026, 2026-07-01 [^3-5^]: Zylos Research, “Remote Tool Execution & Cloud Sandbox Platforms”（三隔离原语收敛、principal 传播无标准）, https://zylos.ai/research/2026-06-13-remote-tool-execution-cloud-sandbox-platforms/, 2026-06-13 [^3-6^]: OpenAI 官方, “The Next Evolution of the Agents SDK”（2026-04-15 原生沙箱、七家托管商、harness/ 执行面分离）, https://openai.com/index/the-next-evolution-of-the-agents-sdk/, 2026-04-15 [^3-7^]: controlplane, “Best AI Agent Sandboxes 2026”; balazscsorba E2B 分析（Firecracker、150ms、按秒价目、fork≤20）, https://controlplane.com/blog/post/best-ai-agent-sandboxes-2026 ; https://balazscsorba.com/blog/e2b, 2026-10-26 / 2026-10-02 [^3-8^]: ghuntley 参考文档 +

hokai 测评（Daytona 90ms、价目、GPU/Windows）, https://github.com/ghuntley/how-to-ralph-wiggum/blob/main/references/sandbox-environments.md ; https://hokai.io/kr/hub/services/daytona, 2026-10-04 [^3-9^]: infragap, “E2B vs Daytona”（具名 hypervisor 信任门槛、$24M A 轮）, https://infragap.com/compare/e2b-vs-daytona/, 2026-08-26 [^3-10^]: Beam 官方博客, “Modal Sandbox Alternatives”（3x 牌价、内存快照 alpha 限制、GPU 限 gVisor）, https://www.beam.cloud/blog/modal-sandbox-alternatives, 2026-11-01 [^3-11^]: agent37, “Compare”（Modal 冷启动实测中位 929ms）, https://www.agent37.com/compare, 2026-10-22 [^3-12^]: Cloudflare 官方文档, “Containers Platform Pricing”（按 10ms、活跃 CPU、sleep 停费）, https://developers.cloudflare.com/containers/platform/pricing/, 2026-10-05 [^3-13^]: Ry Walker Research + simular（Blaxel perpetual sandbox、<25ms 恢复、待机 $0、价目）, https://rywalker.com/research/blaxel ; https://www.simular.ai/alternatives/e2b-alternatives-for-ai-agents, 2026-06-11 / 2026-10-13 [^3-14^]: GitHub api-evangelist/morph-labs（Infinibranch Firecracker、sub-250ms 快照/分叉/恢复）, https://github.com/api-evangelist/morph-labs, 2026-06-20 [^3-15^]: 腾讯云开发者社区 + CubeSandbox GitHub/博客（60ms、<5MB、CubeCoW、CubeEgress、E2B SDK 兼容）, https://cloud.tencent.com/developer/article/2735539 ; https://github.com/TencentCloud/CubeSandbox, 2026-09-01 / 2026-06-22 [^3-16^]: Wikipedia, “Nvidia OpenShell” + promptea 转述（2026-09-28 发布、Provider Indirection、OPA/Rego）, https://en.wikipedia.org/wiki/Nvidia_OpenShell, 2026-09-28 [^3-17^]: aiweekly + 社区指南（Claude Code sandbox-runtime srt 开源、Seatbelt/bubblewrap/WFP、credential masking）, https://aiweekly.co/alerts/anthropic-open-sources-claude-code-sandbox-under-apache-20, 2026-10-24 [^3-18^]: solo.io, “How Google Agent Substrate Works” + GitHub agent-substrate README（WarmPool 300/s、<500ms 恢复、SPIFFE per-actor 证书、Zero credentials）, https://www.solo.io/topics/ai-infrastructure/how-google-agent-substrate-works ; https://github.com/agent-substrate/substrate, 2026-10-19 / 2026-11-05 [^3-19^]: Ry Walker Research + BeyondTrust（AgentCore Code Interpreter microVM/MMDS、DNS 隧道逃逸、两

个 RCE CVE ）, https://rywalker.com/research/agentcore-code-interpreter ; https://www.beyondtrust.com/blog/entry/pwning-aws-agentcore-code-interpreter, 2026-06-11 / 2026-03-16 [^3-20^]: o-mega + boat.dev（Vercel Sandbox GA 2026-01-30、Firecracker、活跃 CPU 计费）, https://o-mega.ai/articles/where-ai-agents-run-code-e2b-vs-modal-2026, 2026-08-12 [^3-21^]: sandboxreview + temps.sh （分叉成独立品类、Morph MCU 价目、PandaStack/Nebius 对比）, https://sandboxreview.com/posts/snapshot-and-fork-support-across-ai-agent-sandbox-providers, 2026-10-02 [^3-22^]: axec.dev, “Cedar vs OPA for Agent Authorization”（含 p99 ~12ms vs ~60ms 第三方自测叙述）, https://axec.dev/blog/cedar-vs-opa-agent-authorization/, 2026-08-15 [^3-23^]: shinyaz, “Bedrock AgentCore Policy (Cedar) 实操验证”（GA 2026-03-03、deny-all 默认、Overly Permissive 拒建）, https://shinyaz.com/en/blog/2026/03/15/bedrock-agentcore-policy-cedar-authorization, 2026-03-15 [^3-24^]: AWS News, “Introducing Dogwood: Runtime Verification for AI Agents”（2026-08-06、MFOTL 时序、Cedar 兼容）, https://aws-news.com/article/2026-08-06-introducing-dogwood-runtime-verification-for-ai-agents, 2026-08-06 [^3-25^]: rpabotsworld, “AWS Dogwood Temporal Policies 指南”（concurrency loophole、在途请求计入）, https://rpabotsworld.com/aws-dogwood-temporal-policies-agentcore-agent-governance-guide/, 2026-08-14 [^3-26^]: NVIDIA Developer Blog, “How NVIDIA OpenShell Reference Architecture Secures and Governs AI Agent Workloads at Scale”（「An agent cannot govern itself」、四组件）, https://developer.nvidia.com/blog/how-nvidia-openshell-reference-architecture-secures-and-governs-ai-agent-workloads-at-scale/, 2026-10-21 [^3-27^]: NVIDIA OpenShell Docs, “Policy Prover”（SMT、boundary check、proposal risk check、非 within_boundary 按失败处理）, https://docs.nvidia.com/openshell/how-it-works/policies/prover, 2026-10-22（检索） [^3-28^]: TechJack Solutions + Sorami 实证（prover 建模边界、audit 静默放行、advisor 策略 diff、fail-closed 启动/冻结规则、「占位符≠授权」）, https://techjacksolutions.com/ai-tools/nvidia/how-nvidia-openshell-works/ ; https://sorami.com.au/research/nvidia-openshell-agent-sandbox-test/, 2026-10-16 / 2026-09-29 [^3-29^]: VentureBeat, “NVIDIA’s OpenShell

controls what AI agents can access”（多 agent 组合权限在研、确定性检查约快 100 倍）, https://venturebeat.com/infrastructure/nvidias-openshell-controls-what-ai-agents-can-access-even-when-they-ignore-instructions, 2026-09-28 [^3-30^]: Pluto Security, “Inside Claude Managed Agents”（vault 凭证代理、三层出口、默认配置过宽、TLS 不检查局限）, https://pluto.security/blog/inside-claude-managed-agents/, 2026-09-04 [^3-31^]: tech-insider, “E2B Secrets 与出口代理”（2026-10-07 Secrets、调用时注入 HTTPS 头）, https://tech-insider.org/ai-agent-sandbox-isolate-mcp-servers-2026/, 2026-10-22 [^3-32^]: Cloud Security Alliance Labs + excello（GitGuardian 2026：24,008 个 MCP secret、8.8% 有效、2,900 万泄漏、CI/CD 59%）, https://labs.cloudsecurityalliance.org/research/csa-research-note-mcp-ai-coding-assistant-credential-theft-2/；https://excello.digital/news/2026-06-29-gitguardian-secrets-sprawl-2026-ai-cicd-credentials/, 2026-06-29 [^3-33^]: Check Point Research, “RCE and API Token Exfiltration through Claude Code Project Files (CVE-2025-59536)”, https://research.checkpoint.com/2026/rce-and-api-token-exfiltration-through-claude-code-project-files-cve-2025-59536/, 2026-02-25 [^3-34^]: Adversa, “Claude Code Vulnerabilities”（CVE-2025-59536/2026-21852、确认对话框非完整性控制）, https://adversa.ai/blog/claude-code-vulnerabilities/, 2026-09-23 [^3-35^]: Unite.ai, “NVIDIA Debuts OpenShell Reference Architecture”（Sentry OPA/Rego 单请求 <1ms）, https://www.unite.ai/nvidia-debuts-openshell-reference-architecture-for-agent-governance/, 2026-10-21 [^3-36^]: Debenedetti et al., “AgentDojo”, NeurIPS 2024 D&B（97 任务、<66% / GPT-4o 69%、ASR <25%、检测器下 8%）, https://arxiv.org/abs/2406.13352, 2024-06-03 [^3-37^]: Debenedetti et al., “CaMeL: Defeating Prompt Injections by Design”（77% 可证明安全 vs 84% 无防御）, https://arxiv.org/abs/2503.18813, 2025-03-24 [^3-38^]: Nasr, Carlini, Tramèr et al., “The Attacker Moves Second”（12 防御自适应 ASR >90%、USENIX Sec’26）；OpenAI Atlas hardening 博客；UK NCSC 博客, https://arxiv.org/abs/2510.09023 ; https://openai.com/index/hardening-atlas-against-prompt-injection/, 2025-10-10 / 2025-12 [^3-39^]: Simon Willison, “The Lethal Trifecta”, https://simonwillison.net/2025/Jun/16/the-lethal-trifecta/, 2025-06-16 [^3-40^]: Meta, “Agents Rule of Two”（经 Willison 转引，三属性最多

取二），https://simonwillison.net/2025/Nov/2/new-prompt-injection-papers/, 2025-10-31 [^3-41^]: Beurer-Kellner et al., “Design Patterns for Securing LLM Agents”（六模式、不可信输入不得触发有后果动作）, https://arxiv.org/abs/2506.08837, 2025-06-10 [^3-42^]: NVD, “CVE-2025-59532”（Codex CLI 沙箱 cwd 由模型生成，CVSS 8.6），https://nvd.nist.gov/vuln/detail/CVE-2025-59532, 2025-09-22 [^3-43^]: SecurityWeek, “Anthropic Silently Patches Claude Code Sandbox Bypass”（CVE-2025-66479、SOCKS5 null-byte）, https://www.securityweek.com/anthropic-silently-patches-claude-code-sandbox-bypass/, 2026-05-20 [^3-44^]: CCE 研究仓库, “Permission-First Safety”（bubblewrap 拦截后 agent 自行禁用沙箱，二手转述），https://github.com/Playful-Sincerity/CCE-Claude-Code-Entities/blob/main/research/2026-04-15-stream3-permission-first-safety.md, 2026-04-15 [^3-45^]: MCPSecBench, arXiv 2508.13220 v3（ATT-16：Claude Desktop 0% vs OpenAI/Cursor 100% ASR），https://arxiv.org/html/2508.13220v3, 2026-02-12 [^3-46^]: SandboxEscapeBench, arXiv 2603.02277 v3（Opus 4.5 56%、Mythos Preview 100%、两月打满），https://arxiv.org/html/2603.02277v3, 2026-08-01 [^3-47^]: Claude Opus 4.5 / 4.6 System Card（Shade ASR 4.7%@1→63%@100；4.6 coding 0%@200、computer-use 57–64%@200），https://www-cdn.anthropic.com/0dd865075ad3132672ee0ab40b05a53f14cf5288.pdf, 2025-11-24 / 2026-02-06 [^3-48^]: Android 官方文档, “Android Virtualization Framework”（pVM 与宿主互不信任）；rottenwifi（Android 16 Terminal unprotected VM），https://source.android.google.cn/docs/core/virtualization；https://rottenwifi.com/how-to-run-linux-apps-on-android-16-using-the-virtual-machine-feature-phones-setup-and-limits/, 2025-02-27 / 2026-08-16 [^3-49^]: Google 官方文档, “SDK Runtime”（独立进程、无网络、每应用一个）, https://developers.google.cn/privacy-sandbox/private-advertising/sdk-runtime, 2024-12-05 [^3-50^]: whatis.in, “What is iOS App Sandbox”（XNU 强制、默认拒绝、entitlement），https://whatis.in/what-is-ios-app-sandbox/, 2026-02-18 [^3-51^]: 华为官方认证页 +

Notebookcheck（iTrustee CC EAL5+ 2021、整机 CCRC EAL5+ 2024-06、星盾）, https://consumer.huawei.com/cn/privacy/certification/ ; https://www.notebookcheck.net/HarmonyOS-6-debuts-with-Star-Shield-security-and-AI-agent-support.1040907.0.html, 2021-11 / 2025-06-20 [^3-52^]: Chen et al., “AgentPoison”, NeurIPS 2024（投毒率 <0.1%、平均 ASR ≥80%）; USENIX Security 2026 FragFuse, https://arxiv.org/abs/2407.12784 ; https://www.usenix.org/system/files/usenixsecurity26-he-yu.pdf, 2024-07-17 / 2026-08-12 [^3-53^]: strayspark + MCP spec 解读（2025-11-25 Tasks SEP-1686/Elicitation、工具注解四元组）, https://www.strayspark.studio/blog/mcp-async-tasks-elicitation-server-side-agent-loops-2025-spec, 2026-05-14 [^3-54^]: skillsdirectory（WWDC25 Session 275：App Intents undo、SnippetIntent perform() 不变性）, https://www.skillsdirectory.com/skills/rshankras-app-intents, 2026-07-16（核验） [^3-55^]: The Cloud Pod（Dogwood 明示局限：无绝对时间窗、无多 agent 策略、时序子句无自动化推理）, https://www.thecloudpod.net/podcast/367-claude-introduces-dlp-i-thought-it-always-stole-data/, 2026-09-17 [^3-56^]: hidekazu-konishi（AgentCore Cedar schema 自动生成、forbid-overrides-permit，对照官方文档核验）, https://hidekazu-konishi.com/tools/agentcore_cedar_policy_builder_tester_tool.html, 2026-06-24 [^3-57^]: Business Wire, “1Password × Claude zero-exposure 框架”（按会话授权、autofill 失败擦除）, https://www.morningstar.com/news/business-wire/20260716981650/, 2026-07-16

> **置信度说明**：本章量化论断中，Firecracker 三数字、K8s agent-sandbox 四 CRD、AgentDojo 三数字（69% 口径另注）、AgentCore Policy GA 日期、The Attacker Moves Second 结论、端侧沙箱空白结论经交叉验证为 High；E2B/Daytona/Modal 价目与启动数字、CubeSandbox 60ms、Blaxel <25ms、Cedar/OPA 性能对比、Claude Code 自我禁用事件、Android 16 Terminal 定性为 Medium 或 Medium-High，正文均已加限定语。Conflict Zone（AgentDojo 效用双口径、OpenShell 双日期）已双边呈现。被交叉验证标记 HALLUCINATED/UNVERIFIED 的条目本章未使用。

第 4 章 记忆框架与记忆能力

> 本章调研基准日：2026-11-06；覆盖时间范围 2024-01 ～ 2026-11（奠基工作追溯至 2023 年及更早）。 引用约定：行内引用 `\[\^4-N\^\]` 为本章编号，章末附来源清单。凡厂商自报分数均显式标注，不作为结论性证据。

记忆（Memory）是 AgentOS 四个组件中与「机制/策略分离」命题耦合最深的一个：记忆的存储、索引、访问控制天然类似操作系统资源，而「记什么、忘什么、何时检索」则是典型的 Agent 策略。本章先梳理 2023–2026 年记忆系统的技术谱系（4.1），再以五维矩阵对比六个代表性系统（4.2），继而分析记忆评测基准的设计与三类失效模式（4.3），随后盘点端侧个人语义索引的生态空白（4.4），最后对我方三项立场逐条评审（4.5）。

4.1 技术谱系

4.1.1 三条架构主线

现代 Agent 记忆的分类学词汇已由 CoALA（Cognitive Architectures for Language Agents，Princeton，2023）统一为工作记忆（working）/情景记忆（episodic）/语义记忆（semantic）/程序记忆（procedural）四分法，并被 IBM、MongoDB、LangChain、Letta、Mem0 等文档普遍采用[^4-1^]。2025-12 发表的 46 作者大综述进一步指出长/短期记忆二分法已不够用，提出 forms（token 级/参数化/隐式）× functions（事实/经验/工作）× dynamics（形成/演化/检索）的三维框架[^4-2^]。在此分类学之上，系统实现分化为表 4-1 所示的三条主线。

表 4-1：Agent 记忆系统的三条架构主线（2023–2026）

派别	代表系统（年份）	核心命题	关键机制	关键量化证据（口径）
虚拟内存自编辑派	MemGPT（2023-10）[^4-3^]；Letta 产品化（2024 起）[^4-4^]	上下文窗口=RAM，外部存储=disk，LLM 自主分页	Agent 经工具调用（core_memory_append/replace、archival_memory_insert/search）自编辑记忆；上下文将满时收到 memory pressure 系统通知后自行决定驱逐/摘要/归档	DMR 基准：GPT-4 32.1%→92.5%、GPT-4 Turbo 35.3%→93.4%（论文自报；基线为有损递归摘要）[^4-3^]
虚拟内存自编辑派（延展）	Letta sleep-time compute（2025-04）[^4-5^]；Context Repositories（2026-02）[^4-6^]	记忆整合移出用户关键路径；记忆即文件系统	空闲期后台 Agent 改写 core memory、摘要、失效化矛盾记忆；git 化版本化记忆文件、多 Agent worktree 合并	厂商自报：同等精度 test-time compute 降约 5×；GSM-Symbolic +13%、AIME +18%（无独立复现）[^4-5^]
外部记忆层派	Mem0（2025-	记忆是与模型	Mem0 两阶段	Mem0 论文：检

派别	代表系统（年份）	核心命题	关键机制	关键量化证据（口径）
	04）[^4-7^]；Zep/Graphiti（2025-01）[^4-8^]；Cognee（2024–26）[^4-9^]；LangMem（2025）[^4-10^]	解耦的外部服务/中间件，读写由管线而非 Agent 自主完成	extraction→update（ADD/UPDATE/DELETE/NOOP）；Zep 时序知识图谱双时态边、失效（invalidation）而非删除；Cognee ECL 管线（classify→permissions→chunk→graph-extract→summarise→embed）；LangMem 覆盖 CoALA 三类且程序记忆（Prompt Optimizer 自改系统提示）为	索 p50 0.148s/p95 0.200s，总 p95 1.44s vs 全上下文 17.12s，约 1.8K vs 26K tokens/会话[^4-7^]；Zep 论文：LongMemEval 较全上下文基线 +18.5pt、延迟 −90%（自报）[^4-8^]

派别	代表系统（年份）	核心命题	关键机制	关键量化证据（口径）
			独有	
内核派（OS 化）	AIOS（2024-03）[^4-11^]；MemOS（2025-05/07）[^4-12^]	记忆是内核管理的可调度资源，类比文件系统 inode	AIOS：Memory Manager（短期日志）/Storage Manager（长期）分离 + Access Manager（Agent 间访问控制）；MemOS：明文/激活态（KV-cache）/参数态三形态统一封装为 MemCube，元数据头含治理属性（ACL、TTL、敏感度标签、水印、访问日志），MemSchedule	MemOS 为 ACL 最完整的学术先例；AIOS 记忆管理器仅短期日志 CRUD，无索引/语义层[^4-11^][^4-12^]

派别	代表系统（年份）	核心命题	关键机制	关键量化证据（口径）
			r 策略感知调度，MemStore 跨平台共享	

表 4-1 显示三条主线的分化本质是「记忆控制权归属」的分化：虚拟内存派把策略与机制都放在 Agent 内（Letta 是「LLM 自己做 OS」）；外部记忆层派把机制做成独立服务，但读写策略由管线固化；内核派把机制下沉到系统层，其中 MemOS 与我方立场重合度最高（统一记忆单元抽象、治理属性、生命周期、跨 Agent 共享），但其跨形态调度由系统的频率/成本模型自动驱动，属「OS 即策略」而非「OS 提供机制、Agent 定策略」——这一差异是 4.5 节立场评审的关键依据。需补充两点边界事实：其一，Letta 的记忆块可跨 Agent 共享，但第三方拆解明确指出其「无作用域/ACL 设计」（No scoping/ACL story）[^4-4^]；其二，LangMem 虽实现 CoALA 全覆盖，但 Mem0 论文复测其检索延迟 p50 17.99s/p95 59.82s（复测口径，非 LangChain 自报），交互场景可用性存疑[^4-13^]。

4.1.2 记忆压缩与遗忘的五条技术线

「压缩与遗忘」横跨记忆框架与推理引擎两个互不连通的文献群，可梳理为五条线（表 4-2）。

表 4-2：记忆压缩与遗忘的五条技术线

技术线	代表工作（年份）	机制	关键量化证据	驱逐语义
① 摘要/巩固/遗忘（文本空间，记忆侧）	Generative Agents（2023-04）[^4-14^]；	recency/ importance/ relevance 三因	Rsum 在 MSC 上记忆 F1 较 MemoryBank	有损归档：被替换内容以摘要形式留存

技术线	代表工作（年份）	机制	关键量化证据	驱逐语义
	MemoryBank（2023-05）[^4-15^]；递归摘要 Rsum（2023-08）[^4-16^]；Google「Language Models Need Sleep」（2026-06）[^4-17^]	子检索打分 + 周期性反思；Ebbinghaus 遗忘曲线加权；M_i=LLM(S_i, M_{i−1}) 递归摘要；参数级睡眠巩固（低秩专家蒸馏 +Dreaming 排练）	+25%[^4-16^]；Google Sleep：SQuAD 48.9 vs 无 Dreaming 35.7（自报）[^4-17^]	
② RAG/上下文压缩（文本→潜空间）	RECOMP（2023-10）[^4-18^]；LLMLingua 系列（2023–24）[^4-19^]；ICAE（2023-07）[^4-20^]；MemoRAG（2024-09）[^4-21^]；Cartridge	检索后抽取/生成式压缩；困惑度 token 剪枝；LoRA 编码器压成 memory slots；KV 压缩作全局记忆；离线训练小型 KV cache	RECOMP：NQ 上 5% token 仅掉 2 EM[^4-18^]；LongLLMLingua 最高 20× 压缩[^4-19^]；Cartridges：显存 ↓38.6×、吞吐 ↑26.4× 且匹配 ICL[^4-22^]	压缩为手段，不涉及驱逐生命周期

技术线	代表工作（年份）	机制	关键量化证据	驱逐语义
	s（2025-06）[^4-22^]			
③ KV 驱逐（推理侧算法）	H2O/ StreamingLLM（2023）；SnapKV（2024-04）[^4-23^]；推理模型 KV 压缩基准（2025-12）[^4-24^]	attention sink+滑窗；累计注意力 heavy-hitter；观察窗投票	SnapKV：16K 输入生成速度↑3.6×、显存效率 ↑8.2×，单卡 380K token[^4-23^]；推理（长 CoT）模型上除 SnapKV-D 外各驱逐策略均显著落后 full cache[^4-24^]	纯丢弃：被逐内容不可再被注意，miss 代价=重算
④ KV 分层复用（推理侧系统）	vLLM PagedAttention（2023-09）[^4-25^]；AttentionStore（2024-03）[^4-26^]；Mooncake（2024-06）	KV 分页；多轮会话 KV 分层落盘复用；KVCache 中心 PD 分离 + CPU/DRAM/SSD/RDMA 分离池；L1 GPU/L2 主机/L3 分布式	AttentionStore：TTFT ↓87%、prefill 吞吐 ↑7.8×、成本 ↓70%[^4-26^]；Mooncake：模拟吞吐最高 +525%、真实负	缓存失效：KV 沿 HBM→DRAM →SSD→远端逐层流动，可字节级精确重建

技术线	代表工作（年份）	机制	关键量化证据	驱逐语义
	[^4-27^]；SGLang HiCache（2025-02 起）[^4-28^]	三层缓存	载多承载 75% 请求[^4-27^]	
⑤ Compaction 系统化（2025–26 新兴）	Anthropic 上下文工程博客（2025-09-29）[^4-29^]；Slipstream（2026-05）[^4-30^]；Parallel Context Compaction（2026-05）[^4-31^]；Governance Decay/ConstraintRot（2026-06）[^4-32^]；Context Compaction Theory（2026-08）[^4-33^]	compaction（摘要并重启）列为四大上下文工程技术之一；异步 compaction + 轨迹 judge 校验；并行分块压缩；约束钉住（Constraint Pinning）；压缩的形式化分析	Slipstream：SWE-bench Verified/BrowseComp 准确率最高 +8.8pt、端到端延迟↓39.7%，88–100% 压缩错误在 3 步内显现[^4-30^]；Governance Decay：compaction 后安全约束违规率 0%→30%（个别模型 59%）[^4-32^]	有损摘要替换历史，但摘要不可检索、原文不留存

表 4-2 揭示一个对本章至关重要的结构性事实：技术线 ③④ 与技术线 ①⑤ 互不连通。推理侧系统（Mooncake/HiCache/AttentionStore）把 KV 驱逐到更慢的同构介质，驱逐语义是「可重算的缓存失效」；记忆侧（MemGPT、Slipstream、Anthropic 工程实践）做的是「上下文满→LLM 摘要→外部存储」，发生在应用层/中间件层，与推理引擎的 KV 驱逐事件完全脱钩。截至 2026-11，没有任何主流 serving 系统把被驱逐 KV 转成文本摘要写入记忆框架，也没有记忆系统把引擎驱逐事件作为入库触发器——「跨越推理引擎与记忆框架的统一驱逐策略」没有顶会/系统论文直接研究（判断，置信度中高；详见 4.5-②）。同时，2026 年 compaction 风险研究集中爆发（验证缺口、约束静默丢失、退化遗忘），社区共识正在形成：摘要入库必须配验证与可恢复机制，不能裸奔[^4-30^][^4-32^][^4-33^]。

4.2 记忆系统对比

表 4-3 按「记忆类型划分 × 存储引擎 × 检索策略 × 遗忘机制 × 隐私方案」五维对比六个代表系统（另附 AIOS、MIRIX 两行作为内核派与多 Agent 派的参照）。

表 4-3：主流记忆系统五维对比（截至 2026-11）

系统（年份）	记忆类型划分	存储引擎	检索策略	遗忘/更新机制	隐私/权限方案
MemGPT / Letta（2023/2024）	分层虚拟上下文：core（常驻 persona/human 块）/ recall（全量对话）/	Postgres + pgvector（块、历史、embedding 一体）；git 仓库	Agent 工具调用自检索（向量+会话搜索）；sleep-time 后台整合	Agent 自编辑 + memory pressure 驱逐通知 + 后台失效化矛盾记忆	记忆块可跨 Agent 共享；无细粒度 ACL[^4-4^][^4-6^]

系统（年份）	记忆类型划分	存储引擎	检索策略	遗忘/更新机制	隐私/权限方案
	archival（长期文档）；2026 起 git 化 Context Repositories				
Mem0（2025-04）	抽取式事实记忆（语义为主）；user/session/agent 三级作用域；Mem0g 图变体	向量库 +（Mem0g）Neo4j 图 + KV	向量相似度取 top-10 候选，LLM 比对决策	写入时 ADD/UPDATE/DELETE/NOOP 调和；Mem0g 冲突边标 invalid 不删除；支持 TTL 与按作用域删除	作用域（user/agent/app/run）隔离；删除响应被遗忘权[^4-7^]
Zep / Graphiti（2025-01）	三层：episodic 节点（原始消息）→ 语义实体/事实（双时态边）→ community	时序知识图谱（Neo4j 等）+ 向量/BM25 索引	混合检索：cosine + BM25 + 图广度遍历，RRF/MMR/cross-encoder 重排	invalidation-instead-of-deletion：每边四时间戳（事务时 t_created′/t_expired′ + 有效时 t_valid/t_inva	单调用删除用户全部数据；企业云服务模式[^4-8^]

系统（年份）	记忆类型划分	存储引擎	检索策略	遗忘/更新机制	隐私/权限方案
	摘要			lid），时序版本链	
LangGraph / LangMem（2025）	CoALA 三分法最完整实现：semantic（事实/画像）/ episodic（few-shot 示例）/ procedural（Prompt Optimizer 自改系统提示，独有）	后端无关：LangGraph BaseStore（namespace+key JSON 文档）/ Postgres / 向量库	namespace 限定 + 向量搜索；后台 store manager 异步整合	策略全归开发者（原语 SDK）；后台 ReflectionExecutor 异步整合	namespace 隔离 user/agent；无内建 ACL/审计[^4-10^]
Cognee（2024–26）	会话记忆（快路径）+ 永久知识图谱；remember/improve/recall/forget 四操作	自托管嵌入式栈 SQLite + LanceDB + Kuzu（可选 Neo4j/Neptune）	图+向量混合（ECL 管线产出）；反馈环更新边权	forget API + 边权衰减 + 删除陈旧信息	数据主权卖点（全本地部署）；管线含 permissions 步骤；无多租户 ACL 文

系统（年份）	记忆类型划分	存储引擎	检索策略	遗忘/更新机制	隐私/权限方案
					献[^4-9^]
MemOS（2025-05/07）	按形态分：明文 / 激活态（KV-cache、隐状态）/ 参数态（权重），统一 MemCube 封装	三层架构（Interface/ Operation/ Infrastructure）+ MemVault + MemStore	MemScheduler 策略感知调度 + 跨形态转换（热明文→激活、稳态→参数、冷参数→明文）	MemLifecycle（TTL、频率衰减）；Version Chain 版本控制/回滚	MemGovernance：访问权限、TTL、敏感度标签、水印、访问日志——ACL 最完整的学术先例[^4-12^]
AIOS（2024-03）	Memory Manager（短期交互日志）/ Storage Manager（长期持久化）	内核级 CRUD（原子操作、线程安全）	无索引/语义检索层	无显式遗忘机制	Access Manager：Agent 间隐私与访问控制（模块级，实现浅）[^4-11^]
MIRIX（2025-07）	六分：Core/ Episodic/ Semantic/ Procedural/ Resource/	分层结构化存储；6 Memory Manager + Meta Manager 路	Active Retrieval（回答前先生成检索主题）	分层 summary/details 组织	Knowledge Vault 隔离逐字敏感事实[^4-34^]

系统（年份）	记忆类型划分	存储引擎	检索策略	遗忘/更新机制	隐私/权限方案
	Knowledge Vault（逐字敏感信息）	由			

表 4-3 呈现三点结构性收敛与两点结构性空白。收敛之一：混合检索（向量+BM25+图遍历）与时态建模成为准确率前沿的标准配置——Zep 的双时态边、Mem0g 的 invalid-instead-of-delete、Cognee 的 ECL 管线同向，第三方评测显示纯向量方案在 LongMemEval 的时间推理/知识更新类目落后图方案约 15 分（中等置信，来源为汇总评测）[^4-35^]。收敛之二：写入时调和（write-time reconciliation）成为标配，遗忘与更新被视为写入路径的责任而非检索时过滤。收敛之三：异步整合（sleep-time/background consolidation）从论文变成产品默认。空白之一：隐私/权限一列从「无」（Letta、LangMem）到「学术先例」（MemOS）呈断崖式分布，生产级系统无一具备数据层强制的记忆 ACL。空白之二：KV/激活态记忆与明文记忆的联动只有 MemOS 一家提出统一抽象，且调度策略内建于系统，没有留给 Agent 的策略接口。此外，延迟是可用性的硬约束：Mem0 论文口径下其检索 p95 0.200s，而 LangMem 同口径 p95 达 59.82s，二者相差约 300 倍，直接决定交互场景的选型[^4-7^][^4-13^]。

4.3 记忆评测与失效模式

4.3.1 基准设计谱系

表 4-4：主要记忆基准的设计与核心发现

基准（出处，年份）	设计	规模	核心发现
DMR（MemGPT 论文，2023）	Multi-Session Chat 5 会话 + 第 6 会话提问，单轮事实检索	每会话约 60 条消息	Zep 论文批评其规模太小、问题歧义、现代 LLM 全上下文即可高分[^4-3^][^4-8^]
LoCoMo（ACL 2024）[^4-36^]	10 段多会话对话（19–35 会话、约 300 轮、9K–26K tokens），persona+时序事件图合成、人工校验；QA 五类目 + 事件摘要	1,986 QA 对	所有方法远低于人类；Memora 论文批评其 94% 问题只需 ≤2 个会话证据，整合要求浅[^4-36^][^4-37^]
LongMemEval（ICLR 2025）[^4-38^]	500 题五能力：信息抽取/多会话推理/时间推理/知识更新/拒答；索引-检索-阅读三阶段统一框架	115K tokens（S）～1.5M tokens/500 会话（M）	商用助手与长上下文 LLM 掉 30–60%[^4-38^]
LongMemEval-V2（2026-05）[^4-39^]	从「记住用户」转向「成为环境里的资深同事」：静态/动态状态、工作流知识、环境陷阱、	451 题；轨迹干草堆最大 500 条/115M tokens	AgentRunbook-C（轨迹存文件 + coding agent 沙箱查证）72.5% > 现成 coding agent 69.3% > 最佳 RAG 48.5%；

基准（出处，年份）	设计	规模	核心发现
	前提意识；仅需 Insert(h)/Query(q) 两 API		GPT-5.2 无历史仅 14.1%[^4-39^]
Memora / FAMA（ACL 2026 Findings）[^4-37^]	数周至数月对话；remembering/ reasoning/ recommending 三任务；FAMA 指标惩罚复用已失效记忆（MPA − λ·(1−FAA)）	4 LLM × 6 记忆 Agent	频繁复用无效记忆、无法调和演化中的记忆；记忆 Agent 仅带来边际提升[^4-37^]
STALE（2026-05）[^4-40^]	400 个专家校验冲突场景；隐性冲突（后续观察未显式否定旧记忆但使其失效）	400 场景	LLM Agent 难以识别记忆何时失效[^4-40^]
GroupMemBench（2026-05）[^4-41^]	多方（multi-party）记忆	—	最佳系统平均仅 46.0%；知识更新 27.1%；BM25 即可打平多数记忆系统——多方记忆本质是治理问题[^4-41^]

基准（出处，年份）	设计	规模	核心发现
MemoryAgentBench（ICLR 2026）[^4-42^]	增量多轮交互重构长上下文数据集；四能力含选择性遗忘（selective forgetting）	—	当前没有系统能同时掌握四项能力（转引口径，中等置信）[^4-42^]

表 4-4 的演进方向清晰：2024–2025 年的基准（DMR/LoCoMo/LongMemEval）考「记住用户事实」，2026 年上半年的新一代基准（FAMA/STALE/GroupMemBench/LME-V2）一致转向「失效记忆处理」与「环境专长内化」，且结论一致地悲观——现有系统在记忆更新、失效识别、多方场景下接近崩溃。对系统设计者的直接含义有二：其一，「文件即记忆 + coding agent 检索」成为 2026 年准确率-延迟 Pareto 新前沿（AgentRunbook-C 72.5% vs RAG 48.5%），对复杂证据组装，给 Agent 一个文件系统比给一个向量 API 更强[^4-39^]；其二，评测的失效维度（FAMA 的失效记忆惩罚、STALE 的隐性冲突）比检索准确率更能区分系统优劣，应作为自建评测集的设计参照。

4.3.2 Conflict Zone：Mem0 vs Zep 评测之争（双边呈现）

记忆评测领域存在 2026 年仍未解决的方法论争议，属「领域真实分歧」，本节双边呈现、不作结论：

- **Mem0 侧**：论文（2025-04）报 LoCoMo LLM-judge 66.88%（全上下文基线 72.90%）[^4-7^]；2026-04 厂商页面报新算法 LoCoMo 92.5、LongMemEval 93.4–94.4[^4-43^]。

- **Zep 侧**：博客（2025-05）称正确实现下 Zep LoCoMo 75.14%±0.17 vs Mem0g 68.44%，并指 Mem0 论文的 Zep 复现（65.99%）有误[^4-44^]；Mem0 方面在 GitHub issue 中反算 Zep 仅 58.44%[^4-45^]。
- **独立复现**：独立论文（arXiv:2603.04814，用 GPT-5-mini reader）测 Mem0 在 LongMemEval 仅 49.0%，与厂商 93.4–94.4 相差 45 分；Maximem（2026-05）复现 Mem0 为 73.8%，将差距归因于 benchmark 特化 prompt 工程（均为转引汇总口径，中高置信）[^4-35^]。
- **评论界共识**：同一基准在不同 harness 下分数完全不可比；「不引用厂商 LoCoMo 分数作为任何事物的证据」「自建 30 条带答案的数据测，比任何公开榜单都可靠」[^4-45^]。

据此，本章不引用任何厂商基准分数作为系统优劣结论；上引数字仅用于说明「同名基准分差可达 45 分」这一评测生态事实。注：交叉验证已标记 AMemBench（arXiv:2609.13767）为疑似虚构来源，本章不予使用。

4.3.3 三类失效模式

（a）遗忘与失效错误。FAMA 显示 6 个记忆 Agent 频繁复用已失效记忆、无法调和演化中的记忆[^4-37^]；STALE 进一步显示失效识别在隐性冲突（旧记忆未被显式否定但被后续观察架空）下尤为困难[^4-40^]。此类失效的根因是遗忘被错误地放在检索路径：2026 年基准共识是遗忘=写入时调和（ADD/UPDATE/DELETE/NOOP）+ 失效标记 + 评测闭环[^4-7^][^4-37^]。

（b）检索干扰。Lost in the Middle（TACL 2024）证明相关信息位于长上下文中段时性能 U 形塌陷[^4-46^]；Chroma 的 Context Rot 报告（2025-07，工业报告非同行评审，中等置信）显示 18 个前沿模型随输入变长性能非均匀劣化、单个干扰项即降性能，LongMemEval 上约 300 token 聚焦输入优于约 113K token 全历史[^4-47^]；

GroupMemBench 则给出更尖锐的对照——BM25 即可打平多数记忆系统[^4-41^]。三者共同说明：更多检索结果不等于更好记忆，检索的精确性与干扰控制是独立的质量维度。

（c）记忆污染（安全失效）。 MINJA（NeurIPS 2025）证明攻击者仅通过 query 交互即可向记忆库注入恶意记录，注入成功率 98.2%、最终攻击成功率 76.8%[^4-48^]；MemoryGraft（2025-12）进一步证明经良性摄入通道（如 README）植入的 10 条毒种子对 100 条良性记录即可占检索量 47.9%（PRP），无触发器、跨会话持久[^4-49^]。防御侧，对 6 种防御的评测显示「只有记忆层 tool-gating 一致有效」——记忆召回应被视为特权操作（中等置信，单篇评测）[^4-50^]。记忆安全防御整体远落后于攻击，且 MemoryGraft 提出的密码学来源证明（CPA）尚无生产实现[^4-49^]。

4.4 端侧个人语义索引：空白点清单与差距分析

4.4.1 Windows Recall 复盘：全量横向索引的信任成本

Windows Recall 是唯一量产的全量横向个人语义索引（每数秒全屏快照 + OCR + 本地向量库，自然语言检索「见过的一切」），其两年风波是该路线的完整压力测试。时间线（事实层）：2024-05-20 随 Copilot+ PC 发布[^4-51^]；2024-05-22 英国信息专员办公室（ICO）启动问询[^4-52^]；2024-06-04 安全研究者发布 TotalRecall，证明首发版数据库未加密、「全部明文」，现成 infostealer 可秒级拖库[^4-53^]；2024-06 微软三连退（改 opt-in、要求 Windows Hello、延期转入 Insider 测试）；2024-09-27 公布重做架构：VBS Enclave 隔离、密钥 TPM 托管并绑定 Hello ESS、默认过滤密码/信用卡、可卸载、经渗透测试与第三方评审[^4-54^]；2025-04-25 向全部 Copilot+ PC 推送（仍标 preview），距首发近一年[^4-55^]；2025-06-16 EEA 专属更新引入快照导出工具（一次性 32 位导出码）并将新设备默认保留期从无限改为 90 天[^4-56^]；2026-03 研究者发布 TotalRecall Reloaded，称可经 AIXHost.exe 注入再次提取（研究者自述，微软未正式确认细节，中等置信）[^4-57^]。

四点教训：①首发版属「无威胁建模上线」；②重做核心 = opt-in + 生物识别每次验证 + TEE + 内容过滤 + 企业默认关闭，此范式后被全行业沿用；③即便如此 2025–2026 年仍被持续攻破演示，说明全量屏幕索引的攻击面是结构性的；④监管（ICO 问询、GDPR 数据可携带）直接塑造了产品形态（opt-in、EEA 导出、90 天默认保留）。对我方含义：若做统一索引，「采集面宽度」须让位于「可证明的最小化」——敏感过滤、保留期、TEE 证明应作为首发而非补丁。

4.4.2 Apple / Google / HarmonyOS 能力边界

Apple：个人上下文（personal context）基于邮件/信息/文件/联系人构建端侧语义索引；iOS 18 起第三方 App 可通过 IndexedEntity 协议向 Spotlight 语义索引捐献实体[^4-58^]；WWDC26/iOS 27（2026-09-14）Siri AI 由 System Orchestrator 路由 Spotlight 语义索引 + App Intents + onscreen awareness[^4-59^]。**关键边界：第三方只能「写入/被查询」，不能直接查询全局语义索引，查询入口独占于 Siri/系统**；高频变动数据走 IntentValueQuery 动态查询而非入库[^4-59^]。2026-06-08 Apple 宣布 Siri AI 不在 EU 上线，理由为 DMA 要求向任何 AI 助手开放深层设备访问；Apple 提出的「Trusted System Agent」中介方案被欧委会拒绝——监管正在把「语义索引+深访问」从平台独占资产推向互操作义务对象[^4-60^]。

Google：Pixel Screenshots（2024-08）为单模态纵向索引；Magic Cue（2025-08-20，Pixel 10）跨 Gmail/Calendar/Messages/Screenshots 主动联想，端侧 Tensor G5 + Gemini Nano，支持**逐 App 粒度授权**（「可授权日历但不授权信息」）[^4-61^]；Private AI Compute（2025-11-11）以硬件密封云环境 + 远程证明兜底，2026 年起加入设备密钥加密的持久化服务器端记忆[^4-62^]；AppFunctions（Android 16，2026）把 App 变成「端侧 MCP server」向 Gemini 暴露函数——**动作面已开放给 Agent，但记忆/语料面仍未开放**[^4-63^]。

HarmonyOS：授权哲学最激进——「从管权限到管数据」，取消 9 类不合理权限、图库/通讯录强制 System Picker、「单次授予、单次访问」[^4-64^]；UDMF 提供跨应用标准化数据通路（含权限与生命周期管理）[^4-65^]；小艺在用户授权下感知 200+ 项系统级数据，本地处理优先、仅结构化结果上云；HPIC（2026-06）端云协同加密获泰尔实验室增强级认证（行业首家，厂商口径）[^4-66^]。**关键边界：UDMF 是数据流转通道而非语义索引，无向量/语义检索层；小艺的记忆与感知服务第一方 Agent**。

4.4.3 Picker 式授权先例评估

Picker 范式（独立进程、免权限、逐条授权、单次授予）已在三大移动 OS 普及：iOS PHPicker（iOS 14，2020）[^4-67^]、Android Photo Picker（API 33+，回迁至 Android 4.4）[^4-68^]、HarmonyOS 强制 System Picker[^4-64^]、Google Photos Picker API 取代全库 scope（2025-03 后）[^4-69^]。评估结论：**所有先例均为「用户手动点选条目」的一次性授权，粒度最细的语义授权雏形仅到 Magic Cue 的「逐 App」级；「按语义谓词授权」（如「只授权与出差相关的邮件检索结果」）无任何先例**。但 Picker 的用户心智与监管语言已被教育成熟，把 Picker 从「选照片」升级为「选语义范围」是自然外推，无需从零教育市场。

4.4.4 空白确认、差距分析与窗口判断

表 4-5：端侧个人语义索引空白点清单与最接近实现

#	空白点	现状证据	最接近实现与差距
G1	跨应用统一语义索引对第三方 Agent 开放查询	四大平台索引全部第一方锁定：Recall 无第三方 API（EEA 手动导出为唯一例外）[^4-56^]；	**Apple** 距离最近（统一索引+schema 化贡献+TEE 兜底），但封闭是有意的商业+合规定位；DMA 压

#	空白点	现状证据	最接近实现与差距
		Apple 第三方只捐献不查询[^4-59^]；Magic Cue 只连 Google 自家 App[^4-61^]；小艺 200+ 项数据感知服务自身[^4-66^]	力正迫其向「OS 中介层」演进[^4-60^]
G2	语义级（谓词级）授权：按类别/时间/敏感度/关系授权检索结果	Picker 只到条目级[^4-67^]；Magic Cue 只到 App 级[^4-61^]	无实现；HarmonyOS 授权哲学最接近
G3	记忆/索引的数据层强制 ACL + provenance + 审计（OS 侧不可绕过）	仅学术原型：Collaborative Memory 动态二分图（2025-05）[^4-70^]、MemOS MemGovernance[^4-12^]；行业共识「prompt 级控制不算访问控制」（行业博客口径，中等置信）[^4-71^]	MemOS 形式化最完整但无 OS 强制力、无硬件信任根
G4	跨 Agent 共享记忆的标准权限模型	MCP/A2A 只管传输不管记忆治理（中	无实现

#	空白点	现状证据	最接近实现与差距
		等置信）[^4-72^]；框架级只有命名空间隔离[^4-10^]；GroupMemBench 最佳系统仅 46.0%[^4-41^]	
G5	索引的可验证最小化（TEE 证明+敏感过滤+保留期组合对外可审计）	Recall/PCC/PAC/HPIC 各自部分具备，无一家对第三方出具可编程证明[^4-54^][^4-62^][^4-66^]	Recall 防护清单最完整但无生态接口，且 2026 年仍被攻破演示[^4-57^]
G6	索引的可携带与退出（导出/迁移/删除标准化）	仅 Recall EEA 导出码一种雏形，且为合规而非生态[^4-56^]	无实现
G7	旁观者/第三方数据主体保护（always-on 索引拍到他人信息）	EDPB 智能眼镜声明指出该义务（二手整理，中等置信），OS 级索引无一处理[^4-73^]	无实现

表 4-5 支持两个结论。**空白确认（高置信）**：「统一个人语义索引 + 面向任意第三方 Agent 的细粒度语义授权 + 数据层强制的记忆 ACL」三者交集不存在任何实现；每条腿分别有先例（Apple 的索引、HarmonyOS 的授权哲学、MemOS 的 ACL 形式化、Recall 的

TEE 防护清单），但没有任何一方覆盖其中两项以上。组合这四者即是我方组件的完整定义。**窗口判断（中等置信，含推断成分）**：空白期可能只有 12–24 个月——Apple 的语义索引 + App Intents 已把「OS 级索引 + schema 化贡献」产品化，Google AppFunctions 已把动作面开放给 Agent，若 Apple 按 DMA 要求在 EU 落地 Trusted System Agent 式中介，则「第三方助手经 OS 中介访问个人上下文」将在 2027 年前后成为现实。Apple/DMA 路线是最快的填坑者；该空白属「将被填的区」而非无人区，入场时间本身就是战略变量。

4.5 趋势判断与对我方立场评审

基于 4.1–4.4 的证据，对我方三项立场逐条评审（表 4-6）。

表 4-6：我方记忆立场评审汇总

#	立场	评估	核心依据	修订意见
①	OS 管机制（存储/索引/ACL/共享），Agent 管策略（记什么/忘什么/何时检索）	**支持，分离空位真实存在**（高置信）	MemOS 有机制无策略分离[^4-12^]；Letta 有策略无机制下沉[^4-3^][^4-4^]；GroupMemBench 崩盘反向证实治理需求[^4-41^]	OS 层须提供策略执行护栏（写入时矛盾检测 hook、失效时间戳机制），数据层 ACL/审计/出处不可绕过
②	有损驱逐接口：KV/上下文被驱逐时摘要	**支持，无先例；但必须修订**（空白判断	KV 驱逐文献只丢不存[^4-23^][^4-26^]；生产	钉住关键项（Constraint Pinning 类）+

#	立场	评估	核心依据	修订意见
	入库	高置信；修订意见基于 2026 失效证据）	压缩摘要替换历史但不可检索[^4-29^]；Context Compaction Theory 证明被丢弃信息对 LLM 永久不可见[^4-33^]	摘要质量异步校验（judge/轨迹对照）+ 强制治理元数据（provenance/污点标签/ACL/TTL）+ 原文冷存储可恢复窗口
③	跨 Agent 共享 + ACL	**方向被独立证实，但攻击面显著，须内置防御**（高置信）	GroupMemBench 最佳 46.0%、BM25 打平[^4-41^]；MemoryGraft PRP 47.9% 跨会话持久[^4-49^]；仅记忆层 tool-gating 一致有效[^4-50^]	共享机制必须内置来源证明（CPA 式签名）与记忆层 tool-gating，否则不宜上线

① **机制/策略分离的空位**。「机制/策略分离」作为显式设计原则在 Agent 记忆领域尚无同名先例。最接近的两端分别是 MemOS（有机制无策略分离：MemScheduler 的跨形态转换由系统频率/成本模型自动驱动，且不覆盖「记什么/忘什么」的语义决策）[^4-12^] 与 MemGPT/Letta（有策略无机制下沉：驱逐决策完全归 Agent，但无跨 Agent ACL）[^4-3^][^4-4^]。我方可定位为「MemOS 的机制面 + MemGPT 的策略面」的组合创

新。需加限定：Memora/STALE 证明纯 Agent 策略在失效识别上不可靠[^4-37^][^4-40^]，故 OS 层应把「失效标记/版本链」做成机制原语（Zep 的 invalidation-instead-of-deletion 可直接借鉴），Agent 在授权包络内保留决策权。索引策略同理归机制侧：双时态、失效而非删除、混合检索应原生内建[^4-8^]。

② **有损驱逐摘要入库：无先例确认与三点修订**。先例检索结论：KV 驱逐研究（SnapKV/H2O 谱系）把驱逐建模为纯选择/丢弃问题[^4-23^][^4-24^]；KV 分层系统把驱逐视为可重算的缓存失效[^4-26^][^4-27^]；生产压缩（Codex/Claude Code 式 compaction）是「摘要替换历史」而非「摘要入库可检索」[^4-29^]；最接近的系统级工作（Slipstream、Parallel Compaction、Context Recycling）全部停留在文本摘要层且位于引擎之外[^4-30^][^4-31^]。**「被驱逐内容变成可检索记忆条目」这一接口，截至 2026-11 现有系统均未提供（高置信）**；但 2026 年该方向论文密度快速上升，空白窗口预计 1–2 年内被填（中等置信）。三点修订均有直接证据支撑：(a) **钉住关键项**——Governance Decay 证明 compaction 会静默抹除安全约束（违规率 0%→30%，个别模型 59%），Constraint Pinning 可维持 0%[^4-32^]；(b) **异步校验**——Slipstream 证明同步摘要存在结构性验证缺口（压缩器不知道未来需要什么），异步 compaction + 轨迹 judge 校验准确率最高 +8.8pt、88–100% 的压缩错误在 3 步内显现，校验成本可控[^4-30^]；(c) **治理元数据**——跨维度证据（信息丢失、约束丢失、污点持久化在同一条边上汇合）表明驱逐入库记录的本质是治理检查点而非缓存机制，最小 schema 应为 {摘要载荷, provenance 回指原始记录, 污点标签, 被钉住的安全约束, ACL+TTL+敏感度}，不可裁剪；派生摘要若无 provenance 回指，将成为「事实上的真相」而不可审计[^4-32^][^4-49^][^4-12^]。另有两个补强机会：KV 驱逐文献的注意力 heavy-hitter 信号是几乎免费的入库重要性加权来源[^4-23^]；入库后的巩固/去重/矛盾消解应放在睡眠相位（sleep-time compute 范式）避免阻塞关键路径[^4-5^]。

③ 跨 Agent 共享 ACL：需求与风险同源。需求侧证据独立且强：多方记忆场景下所有系统崩溃（最佳 46.0%，知识更新 27.1%），说明「OS 级共享+治理」的需求被基准独立证实[^4-41^]；而生产 OS 的记忆全部为第一方助手私有，学术形式化（Collaborative Memory 动态权限图、MemOS MemGovernance）无 OS 强制力[^4-70^][^4-12^]。风险侧同样明确：共享放大攻击面——MemoryGraft 证明少量毒经验即可占检索量 47.9% 并跨会话、跨用户持久扩散，传染式越狱可在共享记忆的多 Agent 系统中级联（中等置信）[^4-49^][^4-74^]；行业共识「prompt 级控制不算访问控制」，权限必须在数据层强制[^4-71^]。结论：跨 Agent 共享机制必须内置来源证明与记忆层 tool-gating 作为上线前提；实体归属（entity attribution）须在写入、检索、整合全链路成为一等公民。

本章小结。记忆领域 2024–2026 年的收敛（CoALA 词汇、混合检索、写入时调和、异步整合）验证了我方机制面的技术选型；2026 年基准与攻击文献的集中爆发（FAMA/STALE/GroupMemBench/MINJA/MemoryGraft）则把我方三项立场从「设计偏好」升级为「被独立证实的需求」。两个时间窗需要显式管理：端侧语义索引授权（12–24 个月）与驱逐-入库接缝（1–2 年）均为快关闭窗，先发者定义问题。

本章来源

[^4-1^]: Sumers et al., CoALA: Cognitive Architectures for Language Agents, arXiv:2309.02427（TMLR 2024）, https://arxiv.org/abs/2309.02427, 2023-09 [^4-2^]: Memory in the Age of AI Agents（46 作者大综述）, arXiv:2512.13564, https://arxiv.org/abs/2512.13564, 2025-12-15 [^4-3^]: Packer et al., MemGPT: Towards LLMs as Operating Systems, arXiv:2310.08560, https://arxiv.org/abs/2310.08560, 2023-10-12 [^4-4^]: lhl/agentic-memory 分析（MemGPT/Letta 拆解，含 “No scoping/ACL story”）, https://github.com/lhl/agentic-memory/blob/main/ANALYSIS-arxiv-2310.08560-memgpt.md, 2026-02-21 [^4-5^]: Lin et al. (Letta/UC Berkeley), Sleep-time Compute, arXiv:2504.13171,

https://arxiv.org/abs/2504.13171, 2025-04-17 [^4-6^]: Letta Context Repositories 相关工作（git 化记忆文件系统）, arXiv:2603.17244, https://arxiv.org/html/2603.17244v1, 2026-02-04 [^4-7^]: Chhikara et al., Mem0, arXiv:2504.19413（ECAI 2025）, https://arxiv.org/abs/2504.19413, 2025-04-28 [^4-8^]: Rasmussen et al., Zep/Graphiti, arXiv:2501.13956, https://arxiv.org/abs/2501.13956, 2025-01-20 [^4-9^]: Cognee Review 2026 （ECL 管线、HotPotQA 0.93 厂商自测）, https://www.cognee.ai/cognee-review-2026-graphrag-knowledge-graphs-and-agent-memory, 2026-09-28 [^4-10^]: Atlan, Long-term Memory for LangChain Agents （LangMem 三类记忆与 BaseStore）, https://atlan.com/know/long-term-memory-langchain-agents/, 2026-09-18 [^4-11^]: Mei et al., AIOS: LLM Agent Operating System, arXiv:2403.16971（COLM 2025）, https://arxiv.org/abs/2403.16971, 2024-03 [^4-12^]: Li et al., MemOS, arXiv:2505.22101 / arXiv:2507.03724, https://arxiv.org/html/2505.22101v1, 2025-05/2025-07 [^4-13^]: Mem0 论文 §4.4 延迟复测（LangMem p50 17.99s/p95 59.82s）, arXiv:2504.19413, https://arxiv.org/pdf/2504.19413v1, 2025-04 [^4-14^]: Park et al., Generative Agents, UIST 2023, arXiv:2304.03442, https://arxiv.org/pdf/2304.03442, 2023-04 [^4-15^]: Zhong et al., MemoryBank, AAAI 2024, arXiv:2305.10250, https://arxiv.org/abs/2305.10250, 2023-05-21 [^4-16^]: Wang et al., Recursively Summarizing Enables Long-Term Dialogue Memory, arXiv:2308.15022, https://arxiv.org/html/2308.15022v3, 2023-08（v3 2025-05） [^4-17^]: Behrouz, Hashemi, Mirrokni (Google), Language Models Need Sleep, arXiv:2606.03979, https://arxiv.org/abs/2606.03979, 2026-06-02 [^4-18^]: Xu, Shi, Choi, RECOMP, arXiv:2310.04408, https://arxiv.org/abs/2310.04408, 2023-10-06 [^4-19^]: Prompt Compression for LLMs: A Survey （LLMLingua 系列 20× ）, arXiv:2410.12388, https://arxiv.org/html/2410.12388v2, 2024-10-17 [^4-20^]: Ge et al., ICAE, ICLR 2024, arXiv:2307.06945, https://arxiv.org/abs/2307.06945, 2023-07 [^4-21^]: Qian et al., MemoRAG, arXiv:2409.05591, https://arxiv.org/abs/2409.05591, 2024-09-09 [^4-22^]: Eyuboglu et al., Cartridges, arXiv:2506.06266, https://arxiv.org/abs/2506.06266, 2025-06-06 [^4-23^]: Li et al., SnapKV, NeurIPS 2024, arXiv:2404.14469, https://arxiv.org/html/2404.14469v2, 2024-04 [^4-24^]: Assessing KV Cache Compression On Reasoning, arXiv:2512.12008, https://arxiv.org/html/2512.12008v1, 2025-12-12 [^4-25^]: Kwon et al., vLLM PagedAttention, SOSP 2023, arXiv:2309.06180, https://arxiv.org/abs/2309.06180, 2023-09 [^4-26^]: Gao et al.,

AttentionStore, arXiv:2403.19708, https://arxiv.org/html/2403.19708v2, 2024-03 [^4-27^]: Qin et al., Mooncake（Kimi）, FAST 2025, arXiv:2407.00079, https://arxiv.org/abs/2407.00079, 2024-06-24 [^4-28^]: SGLang 官方文档：HiCache 设计, https://docs.sglang.ai/advanced_features/hicache_design.html, 访问于 2026-11-05 [^4-29^]: Anthropic Engineering Blog, Effective Context Engineering for AI Agents, https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents, 2025-09-29 [^4-30^]: Chen et al. (Princeton), Slipstream, arXiv:2605.08580, https://arxiv.org/abs/2605.08580, 2026-05-09 [^4-31^]: Cim et al., Parallel Context Compaction, arXiv:2605.23296, https://arxiv.org/abs/2605.23296, 2026-05-22 [^4-32^]: Chen et al., Governance Decay / ConstraintRot, arXiv:2606.22528, https://arxiv.org/abs/2606.22528, 2026-06-21 [^4-33^]: Context Compaction Theory, arXiv:2608.01326, https://arxiv.org/html/2608.01326v1, 2026-08-02 [^4-34^]: MIRIX, arXiv:2507.07957, https://arxiv.org/pdf/2507.07957, 2025-07 [^4-35^]: mnemoverse 汇总（独立评测：Mem0 LongMemEval 49.0%；Maximem 复现 73.8%；向量方案时序类目落后图方案约 15 分）, https://mnemoverse.com/docs/library/ai-memory-solutions-2026-q3, 2026-09-28 [^4-36^]: Maharana et al., LoCoMo, ACL 2024, arXiv:2402.17753, https://arxiv.org/abs/2402.17753, 2024-02 [^4-37^]: Uddin et al., Memora/FAMA, ACL 2026 Findings, arXiv:2604.20006, https://aclanthology.org/2026.findings-acl.1337/, 2026-07（v1 2026-04-21） [^4-38^]: Wu et al., LongMemEval, ICLR 2025, arXiv:2410.10813, https://arxiv.org/abs/2410.10813, 2024-10-14 [^4-39^]: Wu et al., LongMemEval-V2, arXiv:2605.12493, https://arxiv.org/abs/2605.12493, 2026-05-12 [^4-40^]: Chao et al., STALE, arXiv:2605.06527, https://arxiv.org/abs/2605.06527, 2026-05-07 [^4-41^]: GroupMemBench, arXiv:2605.14498, https://arxiv.org/abs/2605.14498, 2026-05 [^4-42^]: llms.blog 转引 MemoryAgentBench（Hu et al., ICLR 2026）, https://www.llms.blog/posts/agent-memory-frameworks-in-production-, 2026-10-19 [^4-43^]: Mem0 官方博客, State of AI Agent Memory 2026, https://mem0.ai/blog/state-of-ai-agent-memory-2026, 2026-04-01 [^4-44^]: Zep 官方博客, Lies, Damn Lies, Statistics: Is Mem0 really SOTA in Agent Memory?, https://www.getzep.com/blog/lies-damn-lies-statistics-is-mem0-really-sota-in-agent-memory/, 2025-05-06 [^4-45^]: Agent-DNA-Transfer EVALUATION.md（含 Mem0/Zep 复算争议与”不引用厂商分数”共识）,

https://github.com/abhay-codes07/Agent-DNA-Transfer/blob/main/docs/EVALUATION.md, 2026-06-17 [^4-46^]: Liu et al., Lost in the Middle, TACL 2024, arXiv:2307.03172, https://aclanthology.org/2024.tacl-1.9/, 2023-07 [^4-47^]: Hong, Troynikov, Huber, Context Rot（Chroma 技术报告）, https://www.trychroma.com/research/context-rot, 2025-07-14 [^4-48^]: Dong et al., MINJA, NeurIPS 2025, arXiv:2503.03704, https://arxiv.org/abs/2503.03704, 2025-03-05 [^4-49^]: Srivastava & He, MemoryGraft, arXiv:2512.16962, https://arxiv.org/abs/2512.16962, 2025-12-18 [^4-50^]: 记忆攻击防御评测（仅记忆层 tool-gating 一致有效）, arXiv:2605.08442, https://arxiv.org/pdf/2605.08442, 2026 [^4-51^]: Wikipedia: Windows Recall（发布与延期全过程汇编）, https://en.wikipedia.org/wiki/Windows_Recall, 持续更新（2024-05 起） [^4-52^]: ICO 声明（就 Recall 启动问询）, https://ico.org.uk/about-the-ico/media-centre/news-and-blogs/2024/05/statement-in-response-to-microsoft-recall-feature/, 2024-05-22 [^4-53^]: WIRED, TotalRecall 拖库披露, https://www.wired.com/story/total-recall-windows-recall-ai/, 2024-06-04 [^4-54^]: Microsoft Windows Experience Blog, Update on Recall Security and Privacy Architecture, https://blogs.windows.com/windowsexperience/2024/09/27/update-on-recall-security-and-privacy-architecture/, 2024-09-27 [^4-55^]: GeekWire, Microsoft Rolls Out Recall to All Copilot+ PCs, https://www.geekwire.com/2025/microsoft-rolls-out-recall-and-other-ai-features-to-all-copilot-pcs-nearly-a-year-after-unveiling/, 2025-04-25 [^4-56^]: WinBuzzer, Recall EEA 导出工具与 90 天默认保留期, https://winbuzzer.com/2025/06/16/microsofts-windows-recall-feature-gets-export-tool-in-the-eu-amid-ongoing-privacy-concerns-xcxwbn/, 2025-06-16 [^4-57^]: GovInfoSecurity, TotalRecall Reloaded, https://www.govinfosecurity.com/microsoft-recall-again-spills-secrets-a-31083, 2026-03 [^4-58^]: Apple Developer 文档, Making App Entities Available in Spotlight, https://docs.developer.apple.com/tutorials/data/documentation/appintents/making-app-entities-available-in-spotlight.md, 2024 起 [^4-59^]: WWDC26 Session 343 纪要（IndexedEntityQuery/IntentValueQuery）, https://wwdc.ai/2026/343, 2026-06 [^4-60^]: Apple Newsroom, Due to DMA, Siri AI Delayed in EU for iOS 27 and iPadOS 27,

https://www.apple.com/newsroom/2026/06/due-to-dma-siri-ai-delayed-in-eu-for-ios-27-and-ipados-27/, 2026-06-08 [^4-61^]: Google 官方博客, Pixel 10 AI Features（Magic Cue）, https://blog.google/products-and-platforms/devices/pixel/google-pixel-10-ai-features-updates/, 2025-08-20 [^4-62^]: 9to5Google, Google Private AI Compute, https://9to5google.com/2025/11/11/google-private-ai-compute-pixel/, 2025-11-11 [^4-63^]: LetsDataScience, Android AppFunctions for Gemini, https://letsdatascience.com/news/google-enables-android-apps-with-appfunctions-for-gemini-8e56077a, 2026-06-08 [^4-64^]: 华为《HarmonyOS NEXT 安全技术白皮书》（星盾、强制 System Picker、取消 9 类权限）, https://consumer.huawei.com/content/dam/huawei-cbg-site/cn/mkt/privacy/privary-new/250610/down/HarmonyOS%20NEXT%E5%AE%89%E5%85%A8%E6%8A%80%E6%9C%AF%E7%99%BD%E7%9A%AE%E4%B9%A6.pdf, 2024-08 [^4-65^]: HarmonyOS 开发者文档镜像, UDMF/DataShare 权限与生命周期管理, https://github.com/liasica/harmonyos-skills/blob/master/harmonyos/references/harmonyos-guides/data-share-overview.md, 2026-09（文档快照） [^4-66^]: 中国日报（HDC2026）, HPIC 三原则与泰尔增强级认证；小艺 200+ 项数据感知, http://ex.chinadaily.com.cn/exchange/partners/82/rss/channel/cn/columns/sz8srm/stories/WS6a2f7405a310d709c2fb8019.html, 2026-06-15 [^4-67^]: ohmyswift, PHPickerViewController（独立进程、免权限、逐条授权）, https://ohmyswift.com/blog/2020/08/29/replacing-uiimagepickercontroller-with-phpickerviewcontroller/, 2020-08 [^4-68^]: ProAndroidDev, Permissionless Photo Picker on Android, https://proandroiddev.com/permissionless-photo-picker-android-18f2ffce1b62, 2023-05-04 [^4-69^]: MemoryKPR, Google Photos API Deprecation（强制 Picker API）, https://memorykpr.com/blog/google-photos-api-deprecation-what-it-means-for-third-party-apps-and-how-to-prepare/, 2025-10-24 [^4-70^]: Collaborative Memory（动态二分图 ACL 形式化）, arXiv:2505.18279, https://arxiv.org/html/2505.18279v1, 2025-05-23 [^4-71^]: MindStudio, Shared vs Private AI Agent Memory（“Prompt-level access control isn’t access control”）, https://www.mindstudio.ai/blog/shared-vs-private-ai-agent-memory-team-access-control, 2026-06-03 [^4-72^]: mnemoverse, Shared Memory for Multi-Agent Systems（A2A 不

涉记忆治理）, https://mnemoverse.com/docs/library/shared-memory-for-multi-agent-systems, 2026-06-18 [^4-73^]: Kaamel 整理 EDPB 智能眼镜声明（旁观者告知义务）, https://www.kaamel.com/blog/en-edpb-smart-glasses-responsibility/, 2026-10-14 [^4-74^]: 传染式越狱经共享记忆级联扩散（相关工作引述）, arXiv:2601.05504, https://arxiv.org/html/2601.05504v2, 2026-01-12

第 5 章 内存管理：传统内存与模型内存的双域治理

本章调研日期为 2026-11-06，时间范围以 2024-01 至 2026-11 为主，奠基性工作单独标注年份。章内论断均附行内引用与置信度标注；凡跨来源存在口径冲突者，按交叉验证裁决结果双边呈现。本章将内存管理问题划分为两个策略域：**传统内存域**（应用匿名页、文件页、图形 buffer 的回收与查杀）与**模型内存域**（KV cache、模型权重、MoE（Mixture-of-Experts，混合专家）专家参数的分页、预取与驱逐），并逐节评审二者在记账底座、QoS（Quality of Service，服务质量）契约与驱逐经济学上的交汇点。

5.1 移动端内存管理现状

5.1.1 回收与查杀链路：LMKD 全面转向 PSI

Android 的查杀链路已完成从内核态 LMK（Low Memory Killer）驱动到用户态 LMKD（Low Memory Killer Daemon）的迁移：内核 LMK 驱动自 Linux 4.12 起从上游移除，LMKD 自 Android 9（2018）起成为现役主线，由 AMS/OomAdjuster 下发 `oom_score_adj`、lmkd 决策并以 pidfd 执行查杀[^5-1^]。压力检测机制方面，自 Android 10（2019）起 `ro.lmk.use_psi` 默认为 true，LMKD 优先采用 PSI（Pressure Stall Information）触发器、回落 vmpressure；默认阈值为三级——`{PSI_SOME, 70ms}/{PSI_SOME, 100ms}/{PSI_FULL, 70ms}`（1 秒窗口），`ro.lmk.psi_complete_stall_ms` 默认 700ms，`ro.lmk.thrashing_limit` 高性能机 100、

低 RAM 机 30（%）[^5-2^]。在 cgroup v2 或低内存设备上，lmkd 强制启用基于 zone 水位、free swap 与 thrashing（refault 率）的”新策略”查杀[^5-1^]。PSI 本身仍在扩维：PSI_IRQ（将 IRQ/SOFTIRQ 压力计入 `irq.pressure`）已于 Linux 6.1（2022-09）合入上游[^5-3^]。可以判定（High 置信）：PSI 家族已成为 lmkd、systemd-oomd、ChromeOS 三方共同的压力信号事实标准。

5.1.2 MGLRU：回收器的收敛与落地数据

MGLRU（Multi-Generational LRU）于 Linux 6.1（2022-12）合入，自 Android 14 全系内核（android14-5.15/6.1）起默认开启（Pixel 8 首发），Android 15（GKI 6.6）与 Android 17（内核 6.18.21）均保持默认开启[^5-4^]。Google 公布的落地数据包括：Pixel 6 开启 MGLRU 后应用总体启动时间 −6.60%、后台查杀 −8.04%、kswapd CPU −54.50%、直接回收次数 −81.10%（2022 LPC 演示，2023-10 报道）[^5-4^]；LPC 2024 汇总口径为 Android 手机低内存查杀 −85%、ChromeOS UI 渲染延迟 −18%、Android 应用冷启动 −16%、服务器 kswapd CPU −40%[^5-5^]。需要注明：上述数字来源链为 Google 官方/LPC slides，本轮交叉验证未能独立复核，按 Medium 置信引用[^5-5^]。已知问题方面，2026-05 LWN/LSFMM 讨论确认 MGLRU 仍存在 writeback 落后触发 cgroup OOM、缺乏 cgroup 级 writeback throttling 等问题，min_ttl_ms 防抖机制被证实有效[^5-6^]。

5.1.3 Android 17 MemoryLimiter：从”杀”到”封顶”

Android 17（API 37，2026）引入 MemoryLimiter：按设备总 RAM 为每个应用设定 anon+swap 硬上限（写 `memory.high`/`memory.swap.max`），对所有应用生效、无需 targetSdk 37；超限进程被终止，退出描述含 `MemoryLimiter:AnonSwap`，并提供 `am memory-limiter` 调试接口[^5-7^]。两个工程细节值得记录：其一，超限终止默认无日志（“fails silently”），已被开发者社区诟病；其二，Play vitals 将”Excessive memory usage”坏行为阈值设为 4% 会话占比[^5-7^]。MemoryLimiter 与

ESWAP（OpenHarmony，per-memcg score/压缩比/refault 阈值的三层 RAM/ZRAM/ESwap 回收）[^5-8^]、HarmonyOS 7 超空间内存（2026-10-22 官宣，16GB 机型最多等效 +3GB，60+ 存量机型 OTA；媒体称压缩率 65%+、保活应用数 +42%，该组数字为媒体口径，Medium 置信）[^5-9^]共同表明：行业供给手段正从”查杀”转向”压缩+上限+主动回收”。

5.1.4 iOS Jetsam 演进：行为感知的查杀调度

iOS 的 Jetsam（memorystatus）机制以优先级带（revision 2 扩展至 0–210：IDLE 0、BACKGROUND 30、FREEZER 75、FOREGROUND 100、CRITICAL 190，另有 AGING_BAND1/2 与 ELEVATED_INACTIVE）从低到高查杀[^5-10^]。其演进方向是”使用概率感知”：`memorystatus_properties_entry_v1.use_probability` 字段记录使用概率；`P_MEMSTAT_RELAUNCH_*` 标志决定 daemon 在 aging band 的停留时间（高/中/低重启概率对应 10/5/2 秒缩放）；JLD（jetsam loop detection）激进回收 elevated idle 进程[^5-11^]。与供给保障最接近的内核级先例是 `CONFIG_SECLUDED_MEMORY`：开启 `secluded_for_apps` 时，优先级 ≥ FOREGROUND 的进程可使用隔离内存池——这是”前台专属内存供给”的工业先例，但粒度粗（仅按是否前台）、无 cgroup 契约语义[^5-10^]。此外，iOS 15+ 开放 `com.apple.developer.kernel.increased-memory-limit` entitlement 提高每进程限额[^5-12^]。

5.1.5 dmabuf 记账的上游状态（正确口径）

图形与加速器 buffer 的 memcg（memory control group）记账是统一记账底座的关键一环，其上游状态须按交叉验证裁决后的口径陈述：dma-buf memcg 记账（MEMCG_DMABUF，将导出 dma-buf 计入分配方 cgroup）自 2022 年起经历多轮 RFC，2026-05 出现 charge_pid_fd 路径 RFC（Red Hat，分配时显式归账到目标进程 cgroup），2026-10 仍为 RFC v2（8 补丁系列，含 `DMA_BUF_IOCTL_XFER_CHARGE`、LSM

hook 与 SELinux 限制），**截至 2026-10 未合入主线，主线 `memory.stat` 无 dmabuf 键**[^5-13^][^5-14^]。该功能目前实际以 Android GKI 下游补丁形式存在。社区已明确指出两个本质限制：单一属主模型（一块共享 buffer 只记账给一个 cgroup）与 fd 传递时无法改变记账归属[^5-14^]；2022 年的独立 GPU cgroup 控制器提案被否决后才转向 memcg 路径[^5-14^]。（此前调研中”dmabuf memcg 记账已上游合入（6.5）“的表述已被交叉验证证伪，本节采用上述修正口径。）

5.1.6 Honor memory.aging：memcg 级主动老化

荣耀于 2026-07 提交 `memory.aging` RFC v2：将 MGLRU 的 debugfs `lru_gen "+"` 原语暴露为 per-cgroup 接口，实现 memcg 粒度的主动老化。该特性已作为 GKI 模块在 6.6/6.12/6.18 内核（高通/MTK 平台）出货，在 Android 与服务器负载上均有稳定收益，但**未合入上游**[^5-15^]。它与 OpenHarmony ESWAP 共同构成”OEM 在下游做 memcg 级 QoS 参数下发+主动回收”的真实出货先例[^5-8^][^5-15^]。

5.2 KV cache 管理技术谱系

KV cache 的规模压力是本节的出发点：Llama-3-8B（GQA，8 个 KV head）FP16 KV 约 0.125MB/token；128K 上下文约 15.6GB、1M 上下文约 62.5GB[^5-16^]；70B 级模型 1M token KV 约 164GB/请求，超过权重本身[^5-17^]。围绕该压力，2023–2026 年形成五条技术路线，谱系见表 5-1。

表 5-1 KV cache 管理五条路线技术谱系

路线	代表工作	机构	时间	一句话贡献	关键数据
块化/分配	PagedAttention（vLLM）	UC Berkeley	SOSP 2023	借鉴 OS 分页，KV 切固定块（默	内存碎片 60–80%→<4%

路线	代表工作	机构	时间	一句话贡献	关键数据
				认 16 token）按需分配+块表映射+写时复制	[^5-18^]
块化/分配	vAttention	Microsoft Research	ASPLOS 2025	CUDA 虚拟内存保持 KV 虚拟连续、物理按需分配，不改 attention kernel	decode 吞吐最高 1.97× vs vLLM[^5-19^]
前缀共享	RadixAttention（SGLang）	LMSYS Org	2023-12	radix tree 管理前缀共享，LRU 驱逐+引用计数+缓存感知调度	GSM-8K 吞吐 4.5×、ReAct agent 5.6×[^5-20^]
压缩	KIVI	Rice/CMU 等	ICML 2024	免微调 2-bit KV 量化（key 逐通道、value 逐 token+残差滑窗）	峰值内存 −2.6×，吞吐 2.35–3.47×[^5-21^]

路线	代表工作	机构	时间	一句话贡献	关键数据
压缩	KVQuant	UC Berkeley	2024-01	RoPE 前量化+非均匀+离群通道保护	支撑 10M token 上下文（7B：4,883GB→610GB）[^5-22^]
压缩	ShadowKV	北大/CMU 等	ICML 2025	pre-RoPE key 低秩 SVD 驻 GPU、value 卸载 CPU	batch 6×、吞吐 3.04×（A100）[^5-23^]
选择性驱逐	StreamingLLM	MIT/Meta	ICLR 2024	attention sink 发现：保留前 4 sink token+滚动窗口	O(1) 内存无限流式生成[^5-24^]
选择性驱逐	H2O	UT Austin/Stanford/Meta	NeurIPS 2023	累计注意力分 heavy-hitter 驱逐	20% 预算 PPL 仅差 1.8%；驱逐不可逆[^5-17^]
选择性驱逐	SnapKV	UIUC/Cohere 等	NeurIPS 2024	prefill 末尾观察窗一次性投票压缩	3.6× 加速、8.2× 省内存、单卡

路线	代表工作	机构	时间	一句话贡献	关键数据
				prompt KV	380K 上下文[^5-25^]
选择性驱逐	Quest	MIT Han Lab	ICML 2024	query 感知页级 top-K（页内 min/max 元数据），不丢 token 只少读	self-attention 7.03×、端到端 2.23×[^5-26^]
卸载/分层	FlexGen	Stanford/ Berkeley	ICML 2023（奠基）	线性规划搜索 GPU/CPU/磁盘三层卸载 +zigzag 调度 +4-bit	OPT-175B 单 16GB T4 达 1 tok/s[^5-27^]
卸载/分层	RetrievalAttention	MSRA/SJTU	NeurIPS 2024	KV 放 CPU 向量库，ANNS 检索相关 token	单 A100 跑 1M 上下文、仅扫 1–3% 向量[^5-16^]
卸载/分层	LMCache	U Chicago 等	2025-10	引擎外置 KV 层：DRAM/NVMe/Redis/S3 分层+块级前	TTFT 降 3.7–6.8×，同 TTFT 吞吐 2.3–14×[^5-

路线	代表工作	机构	时间	一句话贡献	关键数据
				缀哈希	28^]
卸载/分层	Mooncake	Moonshot AI/清华	FAST 2025	KVCache 中心 PD 分离集群，聚合空闲 CPU/DRAM/SSD 全局池	仿真吞吐 +525%，生产多扛 75% 请求[^5-29^]
卸载/分层	Dynamo KVBM	NVIDIA	2025–2026	生产级 G1 HBM/G2 DRAM/G3 NVMe/G4 对象存储四级层级	频率制驱逐 +SSD 寿命过滤（freq≥2 才落盘）[^5-30^]

表 5-1 解读。五条路线的收敛速度并不均一。块化路线已由 PagedAttention 完成事实标准化（vLLM/SGLang 均以其为底座），后续工作（vAttention）转向”保留虚拟地址连续性以兼容原生 kernel”的工程优化。压缩路线内部出现清晰分野：运行时表示（KIVI/KVQuant 的量化、ShadowKV 的低秩，面向显存）与传输表示（CacheGen 的算术编码，面向网络）各自独立演进，FP8 KV 已成为 vLLM/SGLang 的生产默认选项之一[^5-31^]。驱逐路线在 reasoning（长思维链）时代遭遇系统性挑战：NVIDIA 官方实测显示，2,048 token 预算下 AIME 2024 全注意力准确率 57.1%，而 SnapKV 仅 34.6%、R-KV 25.4%——永久驱逐在数学推理场景精度崩塌[^5-32^]；研究界的回应是从”按重要性永久丢弃”转向”不丢、只搬、按 query 取回”（Quest/ShadowKV/RetrievalAttention），即驱逐路线事实上被并入了卸载路线。卸载/分层路线则在 2025–2026 年从论文走向生产：

LMCache、Mooncake（FAST 2025 最佳论文）、SGLang HiCache（L1 GPU/L2 host/L3 分布式存储）与 NVIDIA Dynamo KVBM 共同把”GPU-HBM→DRAM→NVMe→分布式存储”的 L1–L4 层级做成标准架构，KV cache 从”单请求易失状态”变为”跨请求、跨实例、分层持久化的一等资源”[^5-28^][^5-29^][^5-30^]。端侧对照值得注意的是 Apple AFM 2025：端侧 3B 模型走”架构层双块 KV 共享（KV 内存 −37.5%）+2-bit QAT”路线，而非驱逐或卸载——端侧 KV 驱逐/卸载的系统研究目前近乎空白[^5-33^]。

5.3 MoE 专家管理对比

MoE 模型的专家权重占据参数主体（Mixtral-8x7B FP16 约 86GB），而每 token 仅激活少数专家，使”专家级分页/预取/缓存”成为端侧与消费级部署的主杠杆。表 5-2 对比 2023–2026 年代表性工作。

表 5-2 MoE 专家管理代表工作对比

工作	年份/出处	预取策略	预测/命中率	内存节省	工程成熟度
EdgeMoE	2023-08（2024/25 修订）	统计式专家预加载+计算-I/O 流水	未报单一命中率（预加载遮蔽大部分 I/O）	2.6–3.2× vs 全驻留；精度损失 ~2%	开源（mllm），首个端侧 MoE 引擎（Jetson TX2/RPi 4B）[^5-34^]
Mixtral-offloading	2023-12	投机加载（当前层激活跑下一层	LRU 命中 ~70–85%（第三方复	86GB→~17.5GB（专家 2bit 混合量	开源原型（MIT），研究引用广

工作	年份/出处	预取策略	预测/命中率	内存节省	工程成熟度
		gate）+LRU 缓存	现，Medium 置信）	化；MMLU 70.51→65.58）	泛[^5-35^]
SwapMoE	ACL 2024	重要性评分+摊销异步换入（非预测）	不适用（Virtual Experts 常驻集）	14.2→4.7 GiB（−67%），延迟 −50%	开源（HF/Tutel 插件）[^5-36^]
Pre-gated MoE	ISCA 2024	重训练 pre-gate：第 N 块门控预告第 N+1 块专家	设计即”预告=选择”，精度无损	峰值 GPU 内存 −4.2×，仅比 oracle 慢 23%	研究原型（需改模型/重训练）[^5-37^]
SiDA-MoE	MLSys 2024	离线哈希解耦路由与推理	top-3 hash 命中 >99%（保真 ~99%）	显存 −40–80%，吞吐最高 3.93×	研究原型（需离线训练哈希）[^5-38^]
MoE-Infinity	2024-01/ MLSys 2025	请求级专家激活矩阵（EAM）追踪+激活感知预取	单请求复用倾斜（Mixtral ~25%、百专家模型 <5%）驱动	GPU 成本最高 −8×；vs offloading 基线延迟 2–20×	**活跃开源服务化**（OpenAI 兼容 API、连续批处理、paged

工作	年份/出处	预取策略	预测/命中率	内存节省	工程成熟度
			缓存		KV、FP4 专家）[^5-39^]
MoE-Lightning	ASPLOS 2025	CGOPipe CPU-GPU-I/O 流水 +paged weights+HRM 选型（调度主导，不依赖预测）	—	显存受限下达吞吐上界，CPU 内存 −2–3×	学术原型；单 T4 吞吐最高 10.3×[^5-40^]
ProMoE	2024-10	学习式 MLP 逐层预测 +stride 预取 +early preemption 纠错	**84.7%**（stride 仅 −5pt；token-based 基线仅 58.3%）	消费级 GPU 可跑 57B	开源，已集成 transformers/llama.cpp[^5-41^]
Fate	2025-02	免训练跨层预取（相邻层 gate 输入高余弦相似）+浅层偏袒缓存	预取 78.79%（decoding）/ 最高 97.15%；浅层全缓存后命中 **99.08%**	随内存预算伸缩；decode 最高 4.1× vs Load-on-Demand	研究原型[^5-42^]
Pre-attention	2025-11	**同层**	**93.03%/**	—	研究原型

工作	年份/出处	预取策略	预测/命中率	内存节省	工程成熟度
预测		attention 前轻量线性预测+排序感知损失	**94.69%/97.62%**（DSV2-Lite/Qwen3-30B/Phi-mini-MoE），超 Fate 15–19pt		[^5-43^]
NPUMoE	2026-04	离线校准专家热度→静态分层+驻留感知 NPU 卸载（非在线预测）	基于热度驻留	Apple ANE 承接 MoE prefill：延迟 −1.32–5.55×、能效 +1.81–7.37×	研究原型（手机 NPU 首个）[^5-44^]
WiSP（MV-WSA）	2026	**缓存主导**：专家权重与 KV 统一为”一个预算下两条引用流”，边际延迟/字节均衡	主张低并发下缓存策略 > 路由预测	同 VRAM 下最优分配	**vLLM drop-in 插件**；最高 1.95× vs 静态 offload[^5-45^]

表 5-2 解读。 该谱系呈现一条清晰的收敛路径：2023 年的端侧/消费级原型（EdgeMoE、Mixtral-offloading、SwapMoE）以”专家放外存、按需加载”建立可行性；

2024 年起竞争焦点转向**预测信号**——“router 即预言机”被反复验证：相邻层 gate 输入余弦相似度约 91.7% 是模型固有性质[^5-41^]，免训练跨层预测达 78.79%（Fate）、学习式预测器达 84.7%（ProMoE）、同层 pre-attention 预测达 93–97.6%[^5-42^][^5-41^][^5-43^]，专家热的可预测性已是社区共识（High 置信，多篇 arXiv 原文交叉一致）。评估指标也在收敛：ProMoE 提出的 GoodPred = Accuracy × FetchRate 把”预测准”与”来得及取”统一[^5-41^]。但必须同时呈现两条反向证据（Conflict Zone 双边陈述）：其一，WiSP（2026）证明在**低并发单流 decode** 场景下缓存策略的收益大于路由预测，router 信号的更大价值在于界定”最小安全常驻集”（内存信号）而非延迟信号[^5-45^]；其二，DuoServe-MoE 数据显示简单层级预测器在 Mixtral-8x7B/8x22B 这类**少专家粗粒度模型**上 top-2 准确率仅 54–67%[^5-43^]——“高可预测”结论主要对 DeepSeek/Qwen 类细粒度多专家模型成立。工程成熟度方面，MoE-Infinity 已走向 OpenAI 兼容服务化，是工程化程度最高的开源实现；但服务端主流路线是专家并行（EP+EPLB）“分布式摊平”而非 offload，offload+预取的主战场已收缩到个人机、边缘与端侧[^5-39^]。端侧 MoE 中 NPUMoE（2026-04）刚起步且只覆盖 prefill 卸载，“统一 KV+专家+激活记账”的工业级框架尚不存在（WiSP 的 MV-WSA 是首个统一建模尝试）[^5-44^][^5-45^]。

5.4 QoS 供给与 NPU 内存抽象

5.4.1 memory.min/low 双契约：服务端先例与移动端空白

cgroup v2 的 `memory.min`（硬保护，任何情况下不回收）与 `memory.low`（软保护，内存充足时不回收）构成供给保障的双契约语义。服务端已有成熟先例：Facebook resctl-demo 以 workload.slice 用 `memory.low` 软保主负载、hostcritical.slice 用 `memory.min` 硬保 768MB、sideload.slice 用 `memory.high` 限膨胀，形成三层契约[^5-46^]；Kubernetes Guaranteed 档以 `memory.low=request` 实现同类语义[^5-47^]。已知风险：`memory.min` 在全局无内存可回收时会卡死分配路径并触发系统 OOM，上游文档明示该语义[^5-47^]。会话级记账也有先例：systemd `session-N.scope` 是 15 年惯例，2026 年已有真实工程

（tmuxctl/PocketShell）为每个 agent 会话包 memory-capped scope（slice ≈46GB、每会话 ≈10GB）防止 OOM 级联[^5-48^]。

与此形成鲜明反差的是移动端空白：检索范围内未见 AOSP 将 `memory.min/low` 用作前台供给契约的证据——Android 的 per-app memcg 主要被 lmkd 用于统计与 thrashing 计算；Android 17 MemoryLimiter 是”封顶”而非”保底”[^5-7^]；App Standby Buckets 按使用行为分五桶但只管 job/alarm/网络、不管内存供给[^5-49^]。“移动端以 memory.min/low 做前台供给保障”在 2024–2026 年检索中未见系统研究或工业实践（Medium-High 置信的空白判断）。

5.4.2 用户注意力感知调度的最近邻

“QoS 跟用户注意力而非进程身份”的最近邻证据有四类：(a) iOS `CONFIG_SECLUDED_MEMORY` 前台专属内存池——最接近的工业先例，但以”是否前台”这一粗粒度注意力代理为据，无 cgroup 契约语义[^5-10^]；(b) Jetsam 的 use_probability/aging band——感知使用概率但仅用于查杀与老化[^5-11^]；(c) systemd-oomd 对延迟敏感的 `user@UID.service` 建议更低 PSI 阈值（40% vs system.slice 60%）——按会话身份差异化阈值[^5-50^]；(d) 学术界的预测式预载链：FALCON（MobiSys 2012，延迟 −50%、能耗 +2%）、TPP（DATE 2023，启动最高 −52.5%、预取仅 1.31MB）、DeepAPP（SenSys 2019，加载 −68.14%、平均预载 190.6MB），以及 AppFlow（arXiv 2026-03）的关键反面数据——MAPLE 用 LLM 预测下一 App 的命中率仅 52%、误预测浪费数百 MB，因此 AppFlow 将预载上限设为 100MB（<5% DRAM）且标记”压力下可被回收”[^5-51^]。这组证据支持的设计法则是：确定性事件（前台/可见/交互中）可签供给契约，结构性信号可做预取但不应占保底份额，行为概率预测只配驱动”可被回收的投机预载”。

5.4.3 内核 accel 子系统与 DMEM cgroup

NPU 内存抽象在内核侧出现唯一实质性收敛点：Linux accel 子系统（drivers/accel，2023 起）以 DRM 为基座承载 AI 加速器驱动（ivpu、habanalabs、amdxdna、qaic 等），上游强制要求以 GEM/BO（Graphics Execution Manager/Buffer Object）做内存管理，推荐 TTM 内存管理器与 drm_sched 调度器（维护者 2024-04 原话：“the minimal requirement is to use GEM/BOs for memory management”）[^5-52^]。DMEM cgroup（设备内存 cgroup 控制器）于 Linux 6.14（2025-03）合入主线：GPU 与驱动分配的 CPU 侧内存按 cgroup 记账、驱逐感知，提供 `dmem.current/max/min/low` 接口；NVIDIA MPS v3 已把 dmem 作为内核 ≥6.14 时的默认内存分区后端[^5-53^][^5-54^]。这是”设备内存”首次获得 cgroup 级记账/限额原语，也是统一记账底座唯一可依附的跨厂商事实标准（High 置信）。

5.4.4 NPU 隔离研究与移动 SoC 的现实约束

NPU 隔离研究在学术界活跃但无商用落地：NeuMMU（2019，奠基）发现 NPU 地址翻译流量呈突发特征，朴素 IOMMU 平均开销 95%，NeuMMU 降到 0.06%[^5-55^]；vNPU（HotInfra 2023）做硬件辅助多租户虚拟化[^5-56^]；sNPU（ISCA 2024）以 NPU Guarder 轻量 IOMMU+ID 粒度 scratchpad 隔离构建 TEE[^5-57^]；NXT（2025/26）打破 TEE-NPU 单租户绑定，利用率最高 3.49×、调度+隔离平均开销 6.38%[^5-57^]。开销数据（个位数百分比）表明细粒度隔离可行，但无任何商用 NPU 出货多租户隔离；2026 年才有媒体级 CVE 分析指出共享 NPU 计时侧信道可用于权重提取（Low 置信，线索级）[^5-58^]。移动端另有两重现实约束：其一，用户态跨厂商统一 NPU API 已被证伪一次——NNAPI 于 Android 15（2024）官方 deprecated，继任者 LiteRT 走 vendor delegate 路线，2026 年实测多家旗舰机消费级应用拿不到 NPU（媒体实测，Low-Medium 置信）[^5-59^]；其二，移动 SoC 为统一内存架构，NPU 无专用显存，dmem cgroup 不适用，“NPU 内存”实为系统 DRAM 经 dma-buf/AHardwareBuffer 的共享份额——Snapdragon

平台上 QNN 仅接受 DMA-BUF 形式的共享内存[^5-60^]，而 dmabuf memcg 记账如 5.1.5 节所述仍未合入主线且存在单一属主、fd 传递不改账两个公认缺陷[^5-14^]。

5.5 四种驱逐去向的成本模型评审

“KV 是纯缓存，驱逐去向有四种——换出（swap 到 CPU/磁盘）、重算（recompute）、上云（传输到远端）、摘要入库（压缩为语义摘要写入记忆库）——且可按统一成本模型定价”是本报告评审的核心立场之一。以下逐条给出证据评审，末段给出”3+1 结构”修订建议。

5.5.1 换出——成立，但须修订粒度假设

分层换出已是 2025–2026 年生产标配（HiCache L2/L3、LMCache、KVBM G2–G4、Mooncake），成本结构清晰可建模：PCIe 25–32GB/s 级、NVMe Gen5 x4 上限约 16GB/s（1GiB 会话 KV 重载 ≥67ms）、跨节点 RDMA 约 15GB/s/NIC[^5-61^][^5-62^]。但两点必须修订：(a) vLLM V1 已移除 GPU↔CPU swap、抢占默认改为 RECOMPUTE，官方口径是”V1 结构下重算开销小于换出”——说明**每请求私有 KV 的换出常常不划算**，换出价值高度依赖复用概率：共享前缀（多轮对话、system prompt、RAG 文档）换出回报高（LMCache 同 TTFT 下吞吐 2.3–14×），私有生成中间态换出后几乎不再被读[^5-63^][^5-28^]；(b) 硬件强相关——NVLink C2C（GB300/GH200 主机带宽 450GB/s）使 swap 成本下降一个量级，成本常数必须按平台在线拟合而非取固定值[^5-64^]。FastSwitch 另证明工程开销主要在 API 分发与块粒度：KV 复用机制可使 swap-out 量 −53%[^5-65^]。结论：成本模型成立，但”复用概率/共享度”必须升为一等变量。

5.5.2 重算——成立，但成本函数要含机会成本与攻击面

重算已被 vLLM V1 定为默认抢占策略（chunked prefill 摊薄后常低于 PCIe 往返）[^5-63^]；CacheBlend 将对非前缀缓存的重算降到 5–18% token[^5-66^]；CacheGen 在低带

宽时主动回退”传文本让 LLM 重算”——工业界已把重算当作可定价选项[^5-67^]。修订点有二：(a) 重算成本随被驱逐前缀长度近线性（注意力近二次）增长，且算力差异主导——Stream2LLM 实测同一重算在 H100 上 50ms、A40 上 200ms，并已对”重算 vs 换出”建立分段线性硬件成本模型[^5-64^]；(b) 重算消耗 prefill 算力预算，高负载下形成”重算颠簸”，已被 Latency-DoS 类攻击利用（反复顶爆 KV 池迫使受害者重算）[^5-63^]。结论：作为默认去向成立，但成本函数 = prefill 时延（按硬件拟合）×概率加权 + 拥塞外部性，不是常数；对 Mamba/GDN 类 recurrent state 还须分架构建模（重算意味着从头 fold 全序列）。

5.5.3 上云——成立，需加入压缩-解压干扰项与带宽分级

CacheGen 证明 KV 可作为码流在网络上传输（delta+算术编码，3.5–4.3× 更小码流、随带宽自适应调压缩级别、低带宽回退传文本重算）[^5-67^]；Mooncake/NIXL 证明集群内 RDMA 传 KV 是生产现实[^5-29^]；PD（Prefill/Decode）分离本质就是 KV 跨节点搬家[^5-28^]。修订点有三：(a) **解压与推理在 GPU 上双向干扰**——实测算术解码无法同时把解压与推理的减速压到 30% 以下，2025 年对策是把解压卸载到 DPU/SmartNIC，成本模型必须包含”解压占用的 GPU 计算份额”或 DPU 卸载项[^5-68^]；(b) 跨 WAN 上云与跨 RDMA 集群是两种经济：前者带宽低两个量级，只在”重算极贵（超长前缀）+带宽尚可+隐私允许”三条件同时成立时划算，CacheGen 自身亦承认高端 GPU+低带宽时不如直接传文本[^5-67^]；(c) 端侧上云叠加隐私与合规成本，非纯字节成本。结论：去向成立，成本模型需三段式：编码/压缩算力 + 传输带宽分级（RDMA/局域网/WAN）+ 解码干扰项。

5.5.4 摘要入库——挑战：这不是缓存驱逐，系统层证据链缺失

在 2024–2026 年 KV/系统文献中，**没有任何工作把”摘要入库”当作 KV 驱逐的标准去向并给出成本模型**。最接近的只有：(a) MemGPT 在文本层做递归摘要+向量库检索，成本为一次额外 LLM 推理+检索召回误差，且 paging 决策错误是**静默失败**（无异常、无

日志，长期累积）[^5-69^]；(b) 永久驱逐系（H2O/SnapKV）证明”不可逆丢弃”在精确召回与数学推理上系统性崩塌（AIME 57.1%→34.6%；needle-in-haystack 类任务−30~40%）[^5-32^][^5-17^]；(c) 2026 年 offloading 复测显示，即使保留全部 KV、仅用低秩 key 做选择，在 context-intensive 任务上也会失效（需加载 5–10% token 而非默认 1.56%）[^5-70^]。据此给出判断（推断，非文献事实）：摘要入库击穿了”KV 是纯缓存”的前提——摘要是**有损、不可重建、语义级**的派生数据，其成本结构（质量损失函数+一次写入推理+后续检索召回率）与前三个保真去向**不同构**，属于数据治理/记忆层而非内存层。

5.5.5 “3+1 结构”修订建议

综合 5.5.1–5.5.4，建议将”四种驱逐去向”修订为 **“3+1”结构**：

1. **保真驱逐三去向同层建模**：换出/重算/上云均为可无损恢复的纯缓存驱逐，适用统一的”带宽-算力-时延”成本模型，按硬件 profile 在线校准常数（Stream2LLM 方法论[^5-64^]），并显式区分复用概率（共享前缀 vs 私有中间态）。
2. **摘要入库单列**：作为”物化（materialization）去向”挂在记忆子系统，质量成本单独建模；若坚持与原三分法同层并列，至少须定义摘要保真度下界与适用场景白名单（闲聊/长程偏好可摘要；精确召回、合规、安全指令禁止）。
3. **概念框架空位**：现有文献无统一表述”保真驱逐（swap/recompute/cloud）与有损驱逐（evict/summarize）是两个范畴”——这是可抢占的概念框架位置；四去向统一成本模型（带宽/算力/时延/质量损失四维）在检索范围内不存在，属真实空位。

5.6 趋势判断与对我方立场评审

5.6.1 趋势判断

1. **压力信号收敛到 PSI 家族**（High）：lmkd（2019 起）、systemd-oomd、ChromeOS 均以 PSI some/full+持续时长为触发语义，上游持续扩维（PSI_IRQ 6.1）；但上游对新增 PSI 维度保守，openEuler 的 pressure.stat 细粒度扩展停在下游是前车之鉴[^5-3^][^5-50^]。
2. **回收器收敛到 MGLRU，供给手段从”杀”转向”压缩+上限+主动回收”**（High）：MGLRU 在 Android 14–17 全量默认[^5-4^]；MemoryLimiter（2026）、ESWAP、HarmonyOS 超空间内存、Honor memory.aging 共同表明查杀正被降级为兜底[^5-7^][^5-8^][^5-15^]。
3. **QoS 从”进程身份”向”使用行为”缓慢迁移，但全行业停在查杀/限流，未到”供给保障”**（Medium-High）：Jetsam use_probability、App Standby Buckets 都只走了一半；移动端 memory.min/low 供给契约无先例（5.4.1）。
4. **KV cache 成为跨请求、跨实例、分层持久化的一等资源**（High）：LMCache/HiCache/Mooncake/KVBM 的 L1–L4 层级已从论文走向生产[^5-28^][^5-29^][^5-30^]。
5. **NPU 内存抽象碎片化严重，内核侧是唯一收敛点**（High）：accel+GEM/TTM/drm_sched+DMEM cgroup（6.14）构成唯一跨厂商锚点；用户态标准化（NNAPI）已失败一次；移动 SoC 统一内存路径上 dmabuf 记账”有方向、无合入”[^5-52^][^5-53^][^5-14^]。

5.6.2 对我方立场的逐条评审

(1) 统一记账底座——支持，但移动端须自建归账原语。 内核 dmem cgroup（6.14）+accel 子系统 GEM/TTM 门槛+dmabuf memcg RFC 演进构成可依附的锚点,

NVIDIA MPS v3 跟进证明工业界接受该模型[^5-53^][^5-52^]。但移动 SoC 路径不能依赖 dmem（统一内存、无专用显存），dmabuf 记账 4 年 3 轮 RFC 未合主线且单一属主/fd 传递两缺陷未解[^5-14^]；同时 KV cache/权重驻留多为 anon/shmem，不在 dmabuf 口径内。修订建议：底座必须自建 **recharge-on-behalf（代分配归账转移）** 原语——在 dmabuf export/heap alloc 处挂钩（QNN 只接受 dmabuf 形式内存反而简化了挂点[^5-60^]）+ anon/shmem 自有追踪层，不等上游；厂商私有池（VTCM、驱动私有分配）无内核可见性，须 HAL 侧上报补充。该空白属结构性停滞的”持久空位”，先做的一方定义接口。

(2) 双策略域（传统内存域 × 模型内存域）——支持，有相邻先例。 ChromeOS VMMMS 在 ChromeOS↔ARCVM 间用 balloon+压力信号做跨域仲裁（Chrome tab 丢弃−50%、不触发 ARC++ 应用查杀、省电 15–20%、省约 750MB），是”双域驱逐互通”最接近的工业证据[^5-71^]；zswap 的 per-cgroup writeback 开关（6.8+）提供跨域”软驱逐”旋钮[^5-72^]。会话级 memcg 粒度有 systemd session scope 与 2026 年 agent 会话封顶工程背书[^5-48^]。交互-后台双契约（前台 memory.low 软保、后台 memory.high 封顶）在移动端为首创空白，差异化成立；前台契约应优先 memory.low 以保留极端回收弹性（memory.min 有卡死分配路径风险）[^5-47^]。配套要求：若做会话级硬上限，必须配套退出原因上报（参考 MemoryLimiter 的 `MemoryLimiter:AnonSwap` 与 Play vitals 4% 阈值机制），否则将重蹈其”静默终止”的生态阻力[^5-7^]。

(3) router 预告预取——支持（强证据），但须加三重限定。 证据链：相邻层 gate 输入余弦相似度 91.7%（模型固有性质）→免训练跨层预测 78.79%（Fate）→学习式 84.7%（ProMoE）→同层 pre-attention 93–97.6%[^5-41^][^5-42^][^5-43^]。限定一（时机）：GoodPred=准确率×及时率，建议”跨层粗预告+gate 完成时 early preemption 纠错”双级机制[^5-41^]。限定二（模型粒度）：**该结论对 DeepSeek/Qwen 类细粒度多专家模型成立，对 Mixtral 类少专家模型须保守——简单预测器在其上 top-2 准确率仅 54–67%**[^5-43^]；低并发单流 decode 场景下缓存策略收益大于预测（WiSP），router 信号应作为界定”最

小安全常驻集”的内存信号使用[^5-45^]。限定三（按层差异化）：浅层路由偏好模糊，需”浅层偏袒缓存”（Fate 以浅层全缓存把命中率拉到 99.08%）[^5-42^]。此外，依 5.4.2 的预测分层法则，router 预告预取所占内存应标记为”可回收”等级，不得挤占契约内存。

(4) KV 驱逐经济学——支持且为首要差异化论据，但须采用 5.5.5 的”3+1”修订。现有文献仅覆盖”重算 vs 换出”两路（Stream2LLM）[^5-64^]，四去向统一模型是真实空位；摘要入库应单列为物化去向并计入治理开销。时间窗判断（Medium）：相关学术空白预计 1–2 年内被填，属”即将被填的窗口”，先建模型/基准者定义问题。

本章来源

[^5-1^]: Android LMKD 服务深度解析（掘金），https://juejin.cn/post/7633644966019350580, 2026-04-28 [^5-2^]: lmkd/psi/oomadj 属性总结（CSDN，含 lmkd 源码 PSI 阈值表），https://blog.csdn.net/weixin_40214774/article/details/141687953, 2025-07-17 [^5-3^]: sched/psi: Add PSI_IRQ（tip 提交），https://patchew.org/linux/166273201263.401.14957314590742548008.tip-bot2@tip-bot2/, 2022-09-09 [^5-4^]: Android 14 默认启用 MGLRU（转 Mishaal Rahman + 2022 LPC 数据），https://xinsanban.10jqka.com.cn/20231018/c651361225.shtml, 2023-10-18 [^5-5^]: MGLRU Updates, LPC 2024 slides, https://lpc.events/event/18/contributions/1781/attachments/1592/3304/mglru-updates-lpc2024.pdf, 2024-09 [^5-6^]: What is to be done about MGLRU?, LWN, https://lwn.net/Articles/1072866/, 2026-05-20 [^5-7^]: Android 17 behavior changes checklist（MemoryLimiter），https://censuus.com/blog/for-developers/android-17-behavior-changes-target-sdk-37, 2026-10-01；另见 https://stora.sh/blog/2026-04-25-android-17-memory-limits-guide, 2026-04-25 [^5-8^]: OpenHarmony Enhanced SWAP 特性介绍（官方文档），

https://github.com/openharmony/docs/blob/master/zh-cn/device-dev/kernel/kernel-standard-mm-eswap.md, 持续更新（特性 2022-04 发布） [^5-9^]: 华为详解 HarmonyOS 7 超空间内存（IT 之家）, https://www.ithome.com/1/016/755.htm, 2026-10-22 [^5-10^]: XNU kern_memorystatus.h （优先级带/secluded memory）, https://fergofrog.com/code/codebrowser/xnu/bsd/sys/kern_memorystatus.h.html, xnu-12377 快照 [^5-11^]: iOS Jetsam 机制解析, https://blog.wyan.vip/2023/10/iOS_Jetsam.html, 2023-10 [^5-12^]: iOS memory entitlements 整理, https://zenn.dev/mtfum/articles/ios_memory_entitlements, 2026-06-18 [^5-13^]: [PATCH RFC v2 0/8] memcg: dma-buf cgroup accounting and charge transfer （lkml）, https://lore.landau.one/lkml/?t=20261021165104, 2026-10 [^5-14^]: dma-heap 记账补丁讨论与单一属主/fd 传递限制（kernsec 列表）, https://kernsec.org/pipermail/linux-security-module-archive/2026-May/057331.html, 2026-05 [^5-15^]: [RFC v2] mm/mglru: proactive aging via memory.aging （Honor, patchew）, https://patchew.org/linux/0a218053083e41c8bc7aacc552c7f38c@honor.com/, 2026-07 [^5-16^]: RetrievalAttention, arXiv 2409.10516（NeurIPS 2024）, https://arxiv.org/html/2409.10516v3, 2024-09 [^5-17^]: H2O, NeurIPS 2023, https://proceedings.neurips.cc/paper_files/paper/2023/file/6ceefa7b15572587b78ecfcebb2827f8-Paper-Conference.pdf, 2023 [^5-18^]: PagedAttention/vLLM（SOSP 2023）综述与论文, https://tensormesh.ai/learn/pagedattention/, 2023/2026 访问 [^5-19^]: vAttention, arXiv 2405.04437, https://arxiv.org/abs/2405.04437, 2024-05 [^5-20^]: SGLang RadixAttention, arXiv 2312.07104, https://arxiv.org/pdf/2312.07104, 2023-12 [^5-21^]: KIVI, arXiv 2402.02750（ICML 2024）, https://arxiv.org/html/2402.02750, 2024-02 [^5-22^]: KVQuant, arXiv 2401.18079, https://arxiv.org/html/2401.18079v4, 2024-01 [^5-23^]: ShadowKV, ICML 2025 （PMLR）, https://proceedings.mlr.press/v267/sun25b.html, 2025 [^5-24^]: StreamingLLM（ICLR 2024）精读, https://www.llms.blog/posts/streamingllm-and-attention-sinks-mathematical-foundations-of-softmax-normalization-artifacts-initial-token-anchoring-and-infinite-context-rolling-kv-cache-mechanics, 2023-09/2026-10 [^5-25^]: SnapKV, arXiv

2404.14469（NeurIPS 2024）, https://arxiv.org/pdf/2404.14469v2, 2024-04 [^5-26^]: Quest, arXiv 2406.10774（ICML 2024）, https://arxiv.org/html/2406.10774v1, 2024-06 [^5-27^]: FlexGen, arXiv 2303.06865（ICML 2023）, https://arxiv.org/abs/2303.06865, 2023-03 [^5-28^]: LMCache, arXiv 2510.09665, https://www.alphaxiv.org/abs/2510.09665, 2025-10 [^5-29^]: Mooncake（FAST 2025 最佳论文）官方站, https://kvcache-ai.github.io/Mooncake/, 2024-07/2026 访问 [^5-30^]: NVIDIA Dynamo KVBM 配置文档, https://docs.nvidia.com/dynamo/reference/components/kvbm-configuration, 2026 访问 [^5-31^]: HiCache 设计文档（SGLang 官方）, https://docs.sglang.ai/advanced_features/hicache_design.html, 2026-11-05 访问 [^5-32^]: KV Cache Compression and Its Infrastructure Problems, NVIDIA Research 官方博客, https://research.nvidia.com/labs/eai/blogs/kv-cache-compression-and-its-infra-problems/, 2026-06-12 [^5-33^]: Apple Foundation Models 2025 Updates, arXiv 2507.13575, https://arxiv.org/abs/2507.13575, 2025-07 [^5-34^]: EdgeMoE, arXiv 2308.14352 及 camera-ready, https://arxiv.org/abs/2308.14352 ; https://openreview.net/pdf?id=DDJeREha18, 2023-08/2024 [^5-35^]: Fast Inference of MoE Models with Offloading（Mixtral-offloading）, arXiv 2312.17238, https://arxiv.org/html/2312.17238v1, 2023-12 [^5-36^]: SwapMoE, ACL 2024, https://aclanthology.org/2024.acl-long.363/, 2024 [^5-37^]: Pre-gated MoE, arXiv 2308.12066（ISCA 2024）, https://arxiv.org/pdf/2308.12066, 2023-08 [^5-38^]: SiDA-MoE, MLSys 2024, https://proceedings.mlsys.org/paper_files/paper/2024/file/698cfaf72a208aef2e78bcac55b74328-Paper-Conference.pdf, 2024 [^5-39^]: MoE-Infinity, arXiv 2401.14361（MLSys 2025）及 GitHub, https://arxiv.org/pdf/2401.14361v2 ; https://github.com/efficientmoe/moe-infinity, 2024-01/2026 访问 [^5-40^]: MoE-Lightning, arXiv 2411.11217（ASPLOS 2025）, https://arxiv.org/abs/2411.11217, 2024-11 [^5-41^]: ProMoE, arXiv 2410.22134, https://arxiv.org/html/2410.22134, 2024-10 [^5-42^]: Fate, arXiv 2502.12224, https://arxiv.org/html/2502.12224v1, 2025-02 [^5-43^]: Pre-attention Expert Prediction（含 DuoServe-MoE 转引数据）, arXiv 2511.10676, https://arxiv.org/html/2511.10676v1, 2025-11

[^5-44^]: NPUMoE, arXiv 2604.18788, https://www.emergentmind.com/papers/2604.18788, 2026-04 [^5-45^]: WiSP/MV-WSA, arXiv 2606.21868, https://arxiv.org/pdf/2606.21868, 2026 [^5-46^]: Facebook Resource Control Demo（resctl-demo）文档, https://facebookmicrosites.github.io/resctl-demo-website/docs/demo_docs/res_protection/cgroup/, 持续维护 [^5-47^]: cgroup v2 memory controller 文档与 OCI runtime-spec issue #1005, https://facebookmicrosites.github.io/cgroup2/docs/memory-controller.html ; https://github.com/opencontainers/runtime-spec/issues/1005, 2019/ 持续 [^5-48^]: PocketShell issue #726（agent 会话 memory-capped scope）, https://github.com/alexeygrigorev/pocketshell/issues/726, 2026-06-12 [^5-49^]: App Standby Buckets（Android 官方文档）, https://developer.android.google.cn/topic/performance/appstandby, 2025-07-18 [^5-50^]: systemd-oomd.service(8) man page, https://manpages.debian.org/testing/systemd-oomd/systemd-oomd.service.8.en.html, 2026-07-23 [^5-51^]: AppFlow, arXiv 2603.17259, https://arxiv.org/html/2603.17259v1, 2026-03-18 ; FALCON（MobiSys 2012）, https://people.cs.umass.edu/~dganesan/papers/MobiSys12-Falcon.pdf [^5-52^]: ArmChina NPU 上游化讨论（accel 维护者 GEM/TTM 门槛）, linux-arm-kernel 列表, https://lists.infradead.org/pipermail/linux-arm-kernel/2024-April/917089.html, 2024-04 [^5-53^]: DMEM cgroup 合入 Linux 6.14 报道, https://www.phoronix.com/news/DMEM-cgroup-vRAM-Control ; https://kernelnewbies.org/Linux_6.14, 2025-01/2025-06 [^5-54^]: NVIDIA MPS v3 Memory Partitioning 文档, https://docs.nvidia.com/deploy/mps/latest/mpsv3-memory-partitioning.html, 2026 访问 [^5-55^]: NeuMMU, arXiv 1911.06859, https://ar5iv.labs.arxiv.org/html/1911.06859, 2019 [^5-56^]: vNPU, HotInfra 2023, https://hotinfra23.github.io/papers/hotinfra23-paper15.pdf, 2023 [^5-57^]: sNPU（ISCA 2024）与 NXT 收录页, https://dl.acm.org/doi/10.1145/3779307 ; https://www.scilit.com/scholars/3592815, 2024/2025-26 [^5-58^]: CVE-2026-1104 NPU 多租户侧信道分析（媒体，线索级）, https://techbytes.app/posts/cve-2026-1104-npu-side-channel-multi-tenant-exploit/, 2026 [^5-59^]: NNAPI deprecation（Android 官方口径转引）与旗舰机

NPU 实测, https://meetonfriday.com/posts/666bbf67/ ; https://gadgets.beebom.com/stories/i-tested-on-device-ai-on-android-and-iphone-results-not-even-close, 2024/2026-04 [^5-60^]: HeteroVDiff （Snapdragon 8 Elite 内存共享事实）与 QNN 官方内存文档, https://arxiv.org/html/2610.16244v1 ; https://docs.qualcomm.com/nav/home/lpai_backend_memory_allocations.html, 2026-09/ 持续 [^5-61^]: KV cache offloading 工程综述（PCIe/NVMe 带宽与 67ms 重载）, https://eurokommerz.at/blog/kv-cache-offloading-cpu-memory-nvme/, 2026-10 [^5-62^]: KV cache 相关工作综述（RDMA ~15GB/s/NIC）, arXiv 2607.27187, https://arxiv.org/pdf/2607.27187, 2026-07 [^5-63^]: vLLM V1 调度器与抢占（RECOMPUTE 默认、swap 移除）工程解读, https://labhub.hopto.org/blog/ai-platform/2026-08-12-vllm-scheduler-and-preemption?lang=en, 2026-08 [^5-64^]: Stream2LLM, arXiv 2604.16395, https://arxiv.org/pdf/2604.16395, 2026-04 [^5-65^]: FastSwitch, arXiv 2411.18424, https://arxiv.org/pdf/2411.18424, 2024-11 [^5-66^]: CacheBlend 等压缩/融合工作综述引证, arXiv 2607.27187, https://arxiv.org/pdf/2607.27187, 2026-07 [^5-67^]: CacheGen, arXiv 2310.07240（SIGCOMM 2024）, https://arxiv.org/html/2310.07240v4, 2023-10 [^5-68^]: KV 解压与推理 GPU 干扰实测, arXiv 2509.16857, https://www.arxiv.org/pdf/2509.16857, 2025-09 [^5-69^]: MemGPT, arXiv 2310.08560, https://arxiv.org/html/2310.08560, 2023-10 [^5-70^]: KV offloading 复测（ShadowKV 在 context-intensive 任务失效）, arXiv 2604.08426, https://arxiv.org/html/2604.08426v5, 2026-09 [^5-71^]: ChromeOS ARC++ VMMMS 官方博客, https://chromeos.dev/en/posts/improving-performance-with-new-arc-resource-management-features, 2024-07-12 [^5-72^]: Debunking zswap and zram myths （per-cgroup writeback）, Chris Down, https://chrisdown.name/2026/03/24/zswap-vs-zram-when-to-use-what.html, 2026-03-24

第 6 章 外部参照全景与立项差异化论据

> 本章为综合章：不重述第 2–5 章证据细节，只做跨组件合并、洞察提炼与立项决策落点。证据基础为四份组件章（见第 2–5 章）、跨维度洞察 I-01～I-10 全文[^6-1^] 与交叉验证报告（High 28 / Medium 35 / Low 14 / Conflict Zone 10 项）[^6-2^]。综合判断均标明证据链，置信度沿用交叉验证口径。

6.1 AgentOS 外部参照全景：四组件技术谱系合并总表

表 6-1 合并第 2–5 章谱系为「组件 × 技术路线 × 代表玩家/工作 × 收敛状态」总表。收敛状态分四档：**已收敛**（存在事实标准或跨厂商一致选择）、**演进中**（方向已定、形态未定）、**起步**（有种子无产品）、**空白**（无产业实现）。

表 6-1 四组件技术谱系合并总表（截至 2026-11）

组件	技术路线	代表玩家/工作	收敛状态
推理	模型即系统服务	AICore、Apple Foundation Models、M4、华为小艺	**已收敛**（前台限制+配额+降级面为标配）（见 2.1）[^6-3^]
推理	NPU 抽象	NNAPI（弃用）→ LiteRT/ExecuTorch → Android 17 NpuManager	框架层**已收敛**；OS 级调度**起步**（best-effort、@SystemApi 封闭）[^6-3^]
推理	端云路由	Apple PCC、Firebase Hybri	请求级**已收敛**；隐私分级与阶段级路由**空白**[^6-3^]

组件	技术路线	代表玩家/工作	收敛状态
		d、OpenShell；学术 RouteLLM/MinionS	
推理	LoRA 生态	S-LoRA/ Punica、AFM adapte r、EdgeLoRA/Mobi LoRA、Qualcomm/ MTK	热插拔**已收敛**（四层独立收敛）；端侧多租户 serving **演进中**[^6-3^]
沙箱	隔离底座	Firecracke r、gVisor、Kata、V 8 isolate	**已收敛**到具名原语；编排层≠隔离层（K8s 四 CRD）[^6-4^]
沙箱	生命周期原语	E2B/Daytona/ Modal/Blaxel/ Morph/CubeSandbox	**已收敛**（快照/分叉/休眠标配化）；dry-run/undo/幂等键无一等接口[^6-4^]
沙箱	策略与授权	OPA → Ceda r（AgentCore）→ Dogwood（时序）→ OpenShell prover（形式化）	**演进中**（点判→时序→形式化；验证粒度落后于执行粒度）[^6-4^]
沙箱	凭证经纪人	E2B Secret	**已收敛**（占位符+出口代理+响应脱敏三

组件	技术路线	代表玩家/工作	收敛状态
		s、CubeEgress、OpenShell Provider、Claude Managed Agents	段式，成入场券）[^6-4^]
沙箱	端侧会话级沙箱	microsandbox/srt/ Codex（先行者）	**空白**（无托管产品；空白形态是「隔离之上的接口装配层」）[^6-4^]
记忆	架构主线	MemGPT/ Letta、Mem0/Zep/ Cognee、MemOS/ AIOS	三派分化**演进中**；机制/策略分离无同名先例[^6-5^]
记忆	压缩与遗忘	Rsum、LLMLingua、H2O/ SnapKV、Mooncake/ HiCache、Slipstream	推理侧与记忆侧**互不连通**；驱逐→入库接缝**空白**[^6-5^]
记忆	评测基准	LoCoMo/ LongMemEval → FAMA/STALE/GroupMemBench/LME-V2	**演进中**（转向失效处理；跨 harness 分差 45 分，厂商分数不可引）[^6-5^]
记忆	端侧个人语义索引	Recall、Apple personal	索引存在但**第一方锁定**；第三方细粒

组件	技术路线	代表玩家/工作	收敛状态
		context、Magic Cue、小艺	度语义授权**空白**（窗口 12–24 月）[^6-5^]
内存	回收与查杀	LMKD+PSI、MGLRU、MemoryLimiter、Jetsam、ESWAP	**已收敛**（PSI+MGLRU 事实标准；从「杀」转向「压缩+上限+主动回收」）[^6-6^]
内存	QoS 供给契约	resctl（min/low/high）、systemd session scope	服务端**已收敛**；移动端供给保障**空白**（MemoryLimiter 只封顶不保底）[^6-6^]
内存	KV 管理	PagedAttention、RadixAttention、KIVI、LMCache/Mooncake/KVBM	块化与分层**已收敛**；永久驱逐被 reasoning 负载证伪、并入卸载路线 [^6-6^]
内存	MoE 专家管理	Pre-gated MoE、ProMoE 84.7%、Fate 78.79%、pre-attention 93–	「router 即预言机」对细粒度多专家模型**已收敛**；少专家模型（54–67%）为

组件	技术路线	代表玩家/工作	收敛状态
		97.6%、WiSP	限定例外[^6-6^]
内存	统一记账底座	DMEM cgrou p（6.14）、dmabuf memcg（RFC v2）	移动 SoC 路径**空白且结构性停滞**（4 年未合主线、两本质缺陷未解）[^6-6^]
内存	NPU 隔离/多租户	NeuMM U、vNPU、sNPU、 NXT、V10	学术证据齐备（开销个位数 %），商用 SoC **空白**[^6-3^] [^6-6^]

表 6-1 的总读法：**收敛发生在「云端+框架层」，空白集中在「端侧+接缝处」**。凡云端有规模经济动机的问题（隔离底座、凭证经纪人、KV 分层、模型服务化）均已收敛；凡需跨组件协调或端侧专属约束（8–16GB DRAM、统一内存、封闭 NPU 固件）的问题——统一记账、移动端 QoS 供给、端侧会话沙箱、驱逐-记忆接缝——全部无人覆盖。这一分布本身就是立项定位地图。

6.2 十大跨维度洞察（I-01～I-10）

十条洞察均由 ⩾2 个维度证据交叉得出（全文见[^6-1^]），按立项相关性排序，每条按「陈述 + 证据链 + 对立项的含义」压缩呈现。

I-03 驱逐经济学：四去向统一成本模型是真实空位，与负载建模/仿真能力精确对口（high）。 证据链：驱逐失败代价已量化（AIME 57.1%→34.6%，见 5.2）；现有模型仅「重算 vs 换出」两路（见 5.5）；「摘要入库」质量成本与前三去向不同构、「上云」叠加隐私溢价（见 4.5-②、2.4）。含义：完整成本函数 eviction_cost = f(字节/带宽, 重算算

力, 时延, 质量损失, 隐私溢价) 无人建，恰是负载建模+仿真的本职工作——立项第一差异化论据，交付物为驱逐经济学模拟器。

I-07 战略窗口矩阵：四类空白分属四类时间窗，必须分开下注（medium，时间锚点high）。 证据链：语义索引授权窗口 12–24 月（DMA 压力，见 4.4.4）；驱逐→入库学术空白 1–2 年（见 4.5-②）；dmabuf 记账 4 年 3 轮 RFC 未合主线属结构性停滞[^6-2^]。含义：快关闭窗做冲刺项、持久空位做护城河、已收敛区明确「不做」——立项排序主论据（展开见 6.3）。

I-08 验证粒度系统性落后于执行粒度是四组件共有的行业结构病（high）。 证据链：OpenShell prover 不建模 GraphQL/MCP 规则（见 3.3.1）；12 个防御自适应攻击下 ASR >90%（见 3.4.1）；同名基准跨 harness 分差 45 分（见 4.3.2）；疑似虚构基准长期无人复核[^6-2^]。含义：「可验证性作为产品指标」无人占据，我方测量能力可变现为护城河（见 6.4-④）。

I-01 缓存键代数：一切改变 K/V 值的可变对象都必须进入 KV 缓存身份（high）。 证据链：llama.cpp 切 LoRA 必须清 KV；SGLang 把 adapter 标识写入前缀缓存键；AFM adapter 与基座版本绑定（见 2.6-②）。含义：分页池管理的不是字节而是「带身份的字节」；cache key = (base_model_version, adapter_id, adapter_version, quant_tier, position_scheme) 键模式规范应作为立项交付物——产业界仅做了 adapter 一维，端侧无人做全维。

I-02 「可休眠内存配额」是沙箱与内存两域会师处的无人接缝（high）。 证据链：云端卖沙箱休眠（Blaxel 待机 $0、恢复 <25ms，前提是内存不驱逐），内核社区卖 per-cgroup 内存契约（min/low/high+zswap），两个市场互不知道对方存在（见 3.2、5.4.1）。含义：设计产物为「sandbox 状态 → memcg 契约映射表」（standby 态内存必须可回收）；「休眠经济学」在端侧 DRAM 约束下是云端厂商从未解过的仿真题。

I-06 有损驱逐入库是三重断点缝合处：入库记录必须强制携带治理元数据（high）。 证据链：信息在这里丢（compaction 理论）、约束在这里丢（Governance Decay 违规率 0%→30%）、污点在这里跨会话续存（MemoryGraft PRP 47.9%）（见 4.5-②、3.5.2）。含义：驱逐入库不是缓存机制而是治理检查点；最小 schema = {摘要载荷, provenance 回指, 污点标签, 钉住的安全约束, ACL+TTL+敏感度}，不可裁剪；治理开销计入 I-03 成本函数。

I-05 风险定档与资源定档同构：一次会话分类驱动四个执行面（medium-high）。 证据链：沙箱按能力组合、内存按前台状态、推理按 SLO 弹性、路由按复杂度——四个子系统各判一次、语义互不一致（见 3.5.2、5.4、2.4）。含义：「产业界有四个各自为政的分级器，我们有一个分类器」是「OS 化」最有力的具体化；需仿真验证动态降档震荡。

I-09 模型即系统服务造成代持内存归账断裂：recharge-on-behalf 是必备缺失原语（high）。 证据链：AICore 底座常驻 4GB+ 为全体应用代持（见 2.6-①）；MemoryLimiter 杀的是被归账进程而非内存驱动者（见 5.1.3）；上游 charge_pid_fd RFC 证明内核社区也看见此缝但 4 年未合入[^6-2^]。含义：记账底座必须自建「代分配归账转移」uAPI，不等上游；持久空位，先做的定义接口。

I-04 预测信号分层定律：结构性信号可进契约，行为概率只配做提示（high）。 证据链：模型内生信号由架构保证（gate 相似度 91.7%、pre-attention 93–97.6%）；负载相位信号由程序结构保证（冷启动静态 I/O 97.2%）；用户行为信号不可靠（MAPLE 52%）（见 5.3、5.4.2）。含义：确定性事件签供给契约、router 预告做预取但占「可回收」等级、行为预测只驱动可投机回收预载；MAPLE 52% 是「为什么不用学习型下一 App 预测」的现成量化辩护。

I-10 阶段不对称硬件 × 休眠经济学：分阶段路由+注意力感知挂起是端云路由未探索组合（exploratory）。 证据链：NPU prefill 强 decode 弱（三源交叉，见 2.3）；生产路由全是请求级（见 2.4）；沙箱休眠经济学已验证（见 3.2）；decode 是带宽争用热点。

含义：列二期探索方向，一期先建仿真（分阶段路由 vs 单端执行尾延迟对比）；若成立，是相对三家请求级路由的硬差异化。

汇总判断：I-03/I-07/I-08 直接以「负载建模与系统仿真」为交付形态，构成立项差异化主轴；I-01/I-02/I-06/I-09 是接缝问题的具体设计答案，构成架构结构性卖点；I-04/I-05/I-10 为设计规则与探索方向[^6-1^]。

6.3 空白点窗口矩阵

把全部空白点按「填充速度」重新排列、分三档管理（表 6-2）。该矩阵是给决策层的核心排序图。

表 6-2 空白点窗口矩阵（档位 × 空白点 × 填充证据 × 我方策略）

档位	空白点	收敛/填充证据	我方策略
已收敛，勿正面竞争	模型即系统服务	AICore/AFM 量产落地，SenSys'26 直接命名该范式（见 2.6-①）	借用形态、预留同样的前台限制+配额降级面；差异化只做代持归账（I-09）
同上	LoRA 热插拔	云端 S-LoRA、OS 侧 AFM、芯片侧 Qualcomm/MTK 四层收敛（见 2.5）	不自建热插拔机制；差异化做端侧缓存键代数（I-01）与版本治理
同上	凭证经纪人	三段式五家同构，已成入场券（见 3.3.2）	直接采用收敛形态；差异化在其上的业务级定档（凭证经纪人≠授权）

档位	空白点	收敛/填充证据	我方策略
同上	云端沙箱接口	K8s 四 CRD + E2B SDK 兼容层 + OpenAI 七家托管商（见 3.2）	不做云端沙箱托管；端侧只借「具名隔离底座+准入清单」
快关闭窗口（12–24 月）	端侧语义索引细粒度授权	四大平台索引第一方锁定；DMA 正迫 Apple 向 OS 中介层演进，最快填坑者已在路上（见 4.4.4）	18 个月内出原型：Picker 式语义谓词授权 + TEE 可验证最小化
同上	KV 驱逐–记忆入库接缝	无任何系统把被逐 KV 转为可检索记忆条目；2026 年论文密度急升，学术空白 1–2 年内被填（见 4.5-②）	先发文/先建基准者定义问题：驱逐经济学模拟器 + 治理元数据 schema（I-03+I-06）
持久空位（结构性停滞）	移动 SoC 统一记账底座	dmabuf memcg 4 年 3 轮 RFC 未合主线，单一属主/fd 传递两缺陷未解；厂商私有栈割裂（QNN dmabuf-only、ANE	自建 recharge-on-behalf 原语，不等上游；先做者定义接口

档位	空白点	收敛/填充证据	我方策略
		IOSurface）（见 5.1.5、5.6.2）	
同上	沙箱 × 内存 QoS 接缝	云端休眠经济学与内核内存契约两个市场互不知对方存在；无任何起步者[^6-2^]	会话级「可休眠内存配额」+ 状态→契约映射表（I-02）；休眠经济学仿真是端侧独占题
同上	多租户 NPU 隔离/记账	商用 SoC 均无多租户/抢占接口；学术（V10/sNPU/NXT）证明开销个位数 % 可行；Android 17 仅 best-effort 种子（见 2.2、5.4.4）	与平台共演进：往 AOSP/accel 上游送补丁卡位；短期在系统服务层排队+抢占，不碰固件

窗口判断整体置信度 medium（含推断），各时间锚点证据为 high[^6-1^][^6-2^]。排序结论：**冲刺项**（语义索引授权原型、驱逐经济学模拟器）18 个月内出成果；**护城河项**（记账底座、沙箱×内存接缝）长期建设；「**不做**」**清单**（云端沙箱托管、热插拔机制、凭证经纪人）写入立项书以聚焦。

6.4 立项差异化论据最终版

四条论据均与我部门负载建模/系统仿真能力直接交叉，按「主张—凭什么赢—交付物」呈现。

① **四去向驱逐经济学统一成本模型（学术窗 1–2 年）**。 主张：KV 驱逐是可定价的工程决策，eviction_cost = f(字节/带宽, 重算算力, 时延, 质量损失, 隐私溢价)，质量损失仅在「摘要入库」非零、隐私溢价仅在「上云」非零——「保真驱逐与有损驱逐是两个范畴」是成本函数的结构性质（见 5.5.5）。凭什么赢：现有文献只有两路模型（Stream2LLM），四去向统一模型属真实空位；按硬件 profile 在线校准常数、输入真实注意力 trace、输出 Pareto 前沿，正是负载建模+仿真的标准动作。交付物：驱逐经济学模拟器（端侧 SoC 校准版）+ 配套基准；治理开销（pinning、judge 校验）作为质量损失项实测校准源（联动 I-06）。先建模型者定义问题。

② **覆盖率驱动的接口清单与 L0 逃生率度量**。 主张：接口面安全不是堆防御，而是「每个格子可证、可测、可复现」——七要素 × 三维定档（3+1）动作矩阵，每格标注「有执行/有验证/有攻击实证」三态（I-08）。凭什么赢：行业结构病是验证粒度系统性落后于执行粒度（见 3.4、3.6），我方覆盖率方法与评测纪律恰好补缺。交付物：接口覆盖矩阵 + 自适应攻击评测 harness + 私有 30–100 条带答案评测集（回应跨 harness 分差 45 分的评测生态现实）；L0 逃生率（最内层隔离被穿透比例）作为北极星安全度量，禁止只报固定攻击集 ASR。

③ **用户注意力 QoS 的仿真验证方法**。 主张：「QoS 跟用户注意力而非进程身份」在移动端无先例（MemoryLimiter 只封顶、Jetsam 只管杀，见 5.4），直接工程上线风险高，应仿真先行。凭什么赢：预测信号分层定律（I-04）给出明确待验假设——确定性事件签 memory.low 契约、router 预告预取占可回收等级、行为预测（52% 命中率）只配投机预载；误预测成本分层仿真、降档震荡仿真（I-05）、休眠经济学仿真（I-02）都是系统仿真对口题，MAPLE 52%、AppFlow 79% 带宽空闲等关键常数已有公开锚点。交付物：注意力 QoS 仿真器（双契约+三态信号源+真实 trace 回放），输出契约参数推荐与反事实对比。

④ **「可验证性即产品」：验证粒度落后于执行粒度，测量能力即变现通道。** 主张：执行面永远跑在验证面之前不是各家失误，而是「验证未成一等工程指标」的产业级缺口；测量/验证能力是护城河而非开销（I-08）。凭什么赢：四组件独立报告同一种病；①②③组合即「AgentOS 验证工具链」——没有厂商提供「接口面每个格子都可证」的产品；HarmonyOS 全栈测量空白（交叉验证确认的覆盖缺口）可作首个外部靶标，产出独家测量数据[^6-2^]。交付物：验证工具链（覆盖矩阵+评测 harness+驱逐经济学模拟器合并发布），对内支撑设计迭代、对外成为独家数据来源。

四论据的依赖关系：①是学术卡位（最快发表），②④是工程护城河（随实现累积），③是①②在端侧场景的应用出口。四者共用同一底座——负载建模与系统仿真能力，这正是立项相对纯系统团队或纯安全团队的结构性优势。

6.5 两份设计文档修订点映射清单

表 6-3、6-4 把第 2–5 章评审结论与跨维度洞察落成对两份设计文档的逐条修订指令（P0 = 不修则有已公开论证的绕过/失效路径或已证伪口径；P1 = 不修则丧失差异化或正确性；P2 = 增强项）。

表 6-3 《AgentOS 沙箱系统设计》修订点清单（修订点 × 依据来源 × 优先级）

#	修订点	依据来源	优先级
S1	七要素评审结论整体吸收：schema/幂等/异步/结构化拒绝维持；效果描述须与可机检效果声明分离（自然语言不进形式模型）	3.5.1；Cedar schema 自动生成、MCP 注解四元组、OpenShell prover 边界教训[^6-4^]	P1
S2	dry-run 降承诺分档：落地为「估算+结构化预览+人工确认」三步，不承诺语义模拟	3.5.1；动作级 dry-run 无先例 + CVE-2025-59536 证明确认对话框非完整性控制[^6-4^]	P1
S3	undo 降承诺分档：改「可逆性分级声明」（reversible/compensatable/irreversible），仅前两档提供机制，底层复用快照/分叉原语	3.5.1；App Intents undo 先例 + CubeSandbox 毫秒级回滚[^6-4^]	P1
S4	三维定档修订为「3+1」：增加第四维「持久写入（记忆/文件）」；会话	3.5.2；跨会话攻击证据链（FragFuse/AgentPoison/MemoryGraft）[^6-	P0

#	修订点	依据来源	优先级
	定义为隔离与污点的双重边界	4^]	
S5	跨会话污点追踪：跨链不升级之外补数据链定档（taint provenance），摄入不可信内容即打标、标签随数据流动	3.5.2；I-06；「权限链挡不住数据带毒」已被公开演示[^6-1^][^6-4^]	P0
S6	额度维时序化：会话事件日志+窗口聚合（Dogwood 模式），额度判定计入已提交+在途请求；补绝对时间窗与时序推理作差异化	3.5.2；Dogwood concurrency loophole 已公开论证[^6-4^]	P0
S7	结构化拒绝接 advisor 通道：命中策略标识+可申请收窄路径+fail-closed；「削弱隔离/策略的动作」定最高风险	3.5.1；OpenShell advisor 先例 + Claude Code 自我禁用事件[^6-4^]	P0

#	修订点	依据来源	优先级
	档默认拒绝		
S8	第零层准入清单：仅接受具名隔离机制（microVM/ gVisor/Kata/具名 OS 原语），高危档强制 microVM 级；边界参数宿主侧确定性计算，模型输出不得参与	3.1/3.4.2；CVE-2025-59532（cwd 由模型生成致逃逸）[^6-4^]	P0
S9	沙箱状态 → memcg 契约映射表：standby 态内存必须可回收（memory.high 封顶 +zswap 回写许可），resume 由 router 预告预取复用	I-02；5.4.1；休眠经济学在端侧 DRAM 约束下无现成解[^6-1^][^6-6^]	P1
S10	评测纪律内置：任何防御声称配自适应攻击评测；禁止只报固定攻击集 ASR；L0 逃生率纳	3.6；The Attacker Moves Second（>90%）+ SandboxEscapeBench 两月打满[^6-4^]	P0

#	修订点	依据来源	优先级
	入度量		
S11	凭证进快照列为禁止项；销毁扩展为 fail-closed 全生命周期（启动前校验、断连冻结、凭证不残留）	3.5.2；OpenShell 顺序规则 + 凭证泄漏事故复盘[^6-4^]	P1

表 6-4 《AgentOS 内存管理设计》修订点清单（修订点 × 依据来源 × 优先级）

#	修订点	依据来源	优先级
M1	「四种驱逐去向」修订为「3+1」结构：换出/重算/上云三保真去向同层建模；摘要入库单列为物化去向挂记忆子系统，质量成本单独建模	5.5.5；摘要入库击穿「KV 是纯缓存」前提（有损、不可重建、不同构）[^6-6^]	P0
M2	驱逐入库强制治理元数据 schema：{摘要载荷, provenance 回指, 污点标签, 钉住的安全约束,	I-06；4.5-②；Governance Decay 0%→30%[^6-1^][^6-5^]	P0

#	修订点	依据来源	优先级
	ACL+TTL+敏感度}不可裁剪；入库前 constraint pinning + 异步 judge 校验必选		
M3	分页池缓存键代数：cache key = (base_model_version, adapter_id, adapter_version, quant_tier, position_scheme)；跨 adapter/精度/版本复用正确性测试矩阵	I-01；2.6-②；llama.cpp 切 LoRA 清 KV、SGLang adapter 键先例[^6-1^][^6-3^]	P0
M4	分页池对象扩容：覆盖基座权重、adapter 权重、KV cache 三类；NPU 后端采用 chunk-and-pad+图内重算，不照搬 vLLM 分页	2.6-⑤；S-LoRA Unified Paging 先例 + NPU 静态图约束[^6-3^]	P1
M5	recharge-on-behalf 原语自建：dmabuf	I-09；5.1.5/5.6.2；交叉验证 C2 裁决口	P1

#	修订点	依据来源	优先级
	export/heap alloc 挂钩 + anon/shmem 自有追踪层 + HAL 侧上报；不等上游	径[^6-1^][^6-2^][^6-6^]	
M6	dmabuf 记账正确口径入文档：主线截至 2026-10 仍为 RFC v2、Android GKI 下游携带；删除任何「上游已合入」表述	交叉验证 C2 裁决（证伪错引）[^6-2^]	P0
M7	KV 规模口径修正：Llama-3-8B（GQA）FP16 ≈0.125MB/token；删除「0.5MB/token（Llama-3-8B）」错标（该值对应 MHA 7B 级）	交叉验证 C10 标记 MISQUOTED[^6-2^]	P0
M8	交互-后台双契约：前台 memory.low 软保（优先 low 而非 min，min 有卡死分	5.4.1/5.6.2；I-04 预测信号分层定律[^6-6^][^6-1^]	P1

#	修订点	依据来源	优先级
	配路径风险）、后台 memory.high 封顶+zswap 回写许可；router 预告预取内存标记「可回收」等级		
M9	少专家模型限定：router 高可预测性仅对 DeepSeek/Qwen 类细粒度多专家模型成立；Mixtral 类 top-2 仅 54–67%，预取策略须保守、以缓存主导（WiSP）	5.3/5.6.2；DuoServe-MoE 与 WiSP 反向证据[^6-6^]	P1
M10	会话级硬上限配套退出原因上报（参考 MemoryLimiter:AnonSwap 与 Play vitals 4% 机制），避免重蹈「静默终止」生态阻力	5.1.3/5.6.2[^6-6^]	P2

#	修订点	依据来源	优先级
M11	QoS 仿真先行：上线前以注意力 QoS 仿真器验证契约参数（双契约+三态信号+真实 trace），降档震荡须仿真验证	6.4-③；I-05 风险登记[^6-1^]	P2
M12	驱逐成本常数按硬件 profile 在线拟合：NVLink 450GB/s 等平台差异可使成本差一个量级；「复用概率/共享度」升为一等变量	5.5.1/5.5.2；Stream2LLM 方法论[^6-6^]	P1

两清单合计 23 条修订点，其中 P0 共 11 条（沙箱 6、内存 5），均为「不修订则存在已公开论证的绕过路径或已被交叉验证证伪的错误口径」，建议作为下一版设计文档的阻断项。

本章来源

[^6-1^]: agentos_insight.md（跨维度洞察 I-01～I-10 全文及洞察→组件映射表），/mnt/agents/output/research/agentos_insight.md, 2026-11-06 [^6-2^]: agentos_cross_verification.md（四级置信度分类、Conflict Zone 裁决 C1–C10、覆盖缺口清

单）, /mnt/agents/output/research/agentos_cross_verification.md, 2026-11-06 [^6-3^]: 本报告第 2 章《推理框架与推理能力》（技术谱系、端云路由对比、五条立场评审）, agentos_research_report_sec02.md [^6-4^]: 本报告第 3 章《沙箱框架与执行能力》（能力矩阵、策略/凭证收敛、七要素与三维定档评审、修订建议七条）, agentos_research_report_sec03.md [^6-5^]: 本报告第 4 章《记忆框架与记忆能力》（架构主线、评测失效模式、端侧语义索引空白 G1–G7、立场评审）, agentos_research_report_sec04.md [^6-6^]: 本报告第 5 章《内存管理：传统内存与模型内存的双域治理》（KV/MoE 谱系、QoS 契约、四去向成本模型评审与「3+1」修订）, agentos_research_report_sec05.md

> **证据链说明**：本章「空白/空位」判断均满足以下之一——(a) 两份以上维度报告独立得出同一结论并经交叉验证列为 High（如端侧会话级沙箱）；(b) 交叉验证确认的结构性停滞事实（如 dmabuf memcg RFC 状态）；(c) 显式标注为推断（如窗口时长、I-10 探索方向）。「已收敛」判断均有 ≥2 个独立产业实现佐证。被标记 HALLUCINATED/UNVERIFIED 的条目（AMemBench、OSDN、memory.pressure_level 等）本章未使用。